

TRƯỜNG ĐẠI HỌC NAM CẦN THƠ
KHOA CÔNG NGHỆ THÔNG TIN



KIẾN THÀNH LONG – 221909

**XÂY DỰNG HỆ THỐNG PHÁT HIỆN SÂU
RĂNG TRÊN ẢNH X-QUANG**

BÁO CÁO ĐỒ ÁN 2

Ngành: Công nghệ thông tin

Mã số ngành: 7480201

Tháng 3 - năm 2026

TRƯỜNG ĐẠI HỌC NAM CẦN THƠ
KHOA CÔNG NGHỆ THÔNG TIN

KIẾN THÀNH LONG – 221909

**XÂY DỰNG HỆ THỐNG PHÁT HIỆN SÂU
RĂNG TRÊN ẢNH X-QUANG**

BÁO CÁO ĐỒ ÁN 2

Ngành: Công nghệ thông tin

Mã số ngành: 7480201

GIẢNG VIÊN HƯỚNG DẪN

TRẦN VĂN THIỆN

Tháng 3 - năm 2026

LỜI CẢM TẠ

Em xin bày tỏ lòng biết ơn sâu sắc đến Quý Thầy/Cô thuộc Khoa Công nghệ Thông tin, Trường Đại học Nam Cần Thơ đã tận tình giảng dạy, truyền đạt kiến thức chuyên môn và tạo điều kiện thuận lợi cho em trong suốt quá trình học tập và thực hiện Đồ án 2.

Đặc biệt, em xin gửi lời cảm ơn chân thành đến Thầy Trần Văn Thiện – giảng viên hướng dẫn, người đã trực tiếp định hướng, góp ý và hỗ trợ em trong suốt quá trình nghiên cứu và triển khai đề tài. Những ý kiến đóng góp quý báu của Thầy là cơ sở quan trọng giúp em hoàn thiện nội dung và nâng cao chất lượng của đồ án.

Thông qua quá trình thực hiện Đồ án 2, em đã có cơ hội vận dụng các kiến thức đã học vào thực tiễn, đồng thời tích lũy thêm kinh nghiệm trong việc xây dựng và phát triển một hệ thống ứng dụng trí tuệ nhân tạo. Đây là nền tảng quan trọng giúp em định hướng và phát triển trong học tập cũng như công việc trong tương lai.

Mặc dù đã có nhiều cố gắng, nhưng do hạn chế về thời gian và kinh nghiệm, đồ án khó tránh khỏi những thiếu sót. Em rất mong nhận được sự đóng góp ý kiến từ Quý Thầy/Cô để đề tài được hoàn thiện hơn.

Em xin chân thành cảm ơn!

Cần Thơ, ngày tháng năm 2026

Người thực hiện

KIẾN THÀNH LONG

LỜI CAM KẾT

Em xin cam kết rằng báo cáo Đồ án 2 này là kết quả của quá trình học tập, nghiên cứu và thực hiện độc lập của bản thân em dưới sự hướng dẫn của giảng viên. Toàn bộ nội dung trong báo cáo được xây dựng dựa trên kiến thức đã học, tài liệu tham khảo có chọn lọc và quá trình triển khai thực tế của đề tài.

Em cam đoan rằng các kết quả, phân tích và nội dung trình bày trong báo cáo là trung thực, chính xác và chưa từng được công bố hoặc sử dụng trong bất kỳ công trình hay báo cáo nào trước đây.

Em xin hoàn toàn chịu trách nhiệm về tính trung thực, tính chính xác cũng như tính nguyên bản của toàn bộ nội dung trong báo cáo này.

Em xin chân thành cảm ơn!

Cần Thơ, ngày tháng năm 2026

Người thực hiện

KIẾN THÀNH LONG

NHẬN XÉT CỦA GIẢNG VIÊN HƯỚNG DẪN

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

Cần Thơ, ngày tháng năm 2026

Giảng viên hướng dẫn

Trần Văn Thiện

MỤC LỤC

CHƯƠNG 1 MỞ ĐẦU	1
1.1 LÝ DO CHỌN ĐỀ TÀI	1
1.2 TÍNH CẤP THIẾT CỦA ĐỀ TÀI	2
1.3 MỤC TIÊU CỦA ĐỀ TÀI	3
1.3.1 Mục tiêu chung.....	3
1.3.2 Mục tiêu cụ thể.....	3
1.4 ĐỐI TƯỢNG VÀ PHẠM VI NGHIÊN CỨU	4
1.4.1 Phạm vi không gian.....	4
1.4.2 Phạm vi thời gian	4
1.4.3 Đối tượng nghiên cứu.....	5
1.5 PHƯƠNG PHÁP NGHIÊN CỨU.....	5
1.6 CÔNG CỤ VÀ MÔI TRƯỜNG PHÁT TRIỂN	6
1.7 Ý NGHĨA CỦA ĐỀ TÀI.....	7
1.8 BỐ CỤC CỦA BÁO CÁO.....	8
CHƯƠNG 2 CƠ SỞ LÝ THUYẾT	10
2.1 TỔNG QUAN NGHIÊN CỨU VỀ SÂU RĂNG	10
2.1.1 Khái niệm sâu răng.....	10
2.1.2 Nguyên nhân và yếu tố ảnh hưởng.....	10
2.1.3 Các mức độ sâu răng	11
2.1.4 Tầm quan trọng phát hiện sớm.....	12
2.2 ẢNH X-QUANG NHA KHOA	13
2.2.1 Khái niệm và phân loại	13
2.2.2 Đặc điểm kỹ thuật	14
2.2.3 Ý nghĩa lâm sàng.....	14
2.2.4 Các bất thường thường gặp	15
2.3 TIỀN XỬ LÝ VÀ XỬ LÝ ẢNH X-QUANG NHA KHOA	16
2.3.1 Các loại nhiễu trong ảnh	16
2.3.2 Chuẩn hóa và cải thiện chất lượng ảnh	17
2.3.3. Biến đổi dữ liệu (Data Augmentation).....	18

2.3.4. Chuẩn bị dữ liệu cho mô hình học sâu.....	18
2.4 HỌC MÁY VÀ HỌC SÂU TRONG PHÂN TÍCH ẢNH X-QUANG	19
2.4.1. Phương pháp truyền thống vs Deep Learning.....	19
2.4.2. Ứng dụng trong phân tích ảnh y sinh.....	20
2.4.3. Bài toán phát hiện và phân loại	21
2.5 MÔ HÌNH YOLOv8	22
2.5.1 Giới thiệu YOLOv8	22
2.5.2 Nguyên lý hoạt động	23
2.5.3. Kiến trúc mô hình.....	24
2.5.4. Ưu điểm và ứng dụng trong phát hiện sâu răng	25
2.6 MÔ HÌNH NƠ-RON TÍCH CHẬP (CNN).....	26
2.6.1 Giới thiệu CNN	26
2.6.2. Kiến trúc CNN và các thành phần	27
2.6.3. Ứng dụng trong phân loại bệnh lý	28
2.6.4. Vai trò trong phân loại mức độ sâu răng.....	29
2.7 CÁC NGHIÊN CỨU LIÊN QUAN.....	30
2.7.1. Nghiên cứu sử dụng Deep Learning trong phân đoạn sâu răng.....	30
2.7.2. Nghiên cứu phát hiện sâu răng trên ảnh X-quang.....	30
2.7.3. Nghiên cứu phân loại mức độ sâu răng.....	30
2.7.4. Hạn chế của các nghiên cứu hiện tại và hướng tiếp cận của đề tài.....	31
2.8. KẾT HỢP YOLOv8 VÀ CNN TRONG HỆ THỐNG	31
2.8.1. Kiến trúc pipeline hai bước	31
2.8.2. Luồng xử lý dữ liệu	32
2.9. CÁC ĐỘ ĐO ĐÁNH GIÁ MÔ HÌNH.....	33
2.9.1. Accuracy	33
2.9.2. Precision, Recall.....	34
2.9.3. F1-score.....	35
2.9.4. Confusion Matrix	35
2.9.5. mAP (Mean Average Precision)	36
2.10. CÔNG NGHỆ VÀ CÔNG CỤ XÂY DỰNG HỆ THỐNG.....	37
2.10.1. Ngôn ngữ lập trình (Python)	37

2.10.2. Framework AI (Ultralytics YOLOv8, TensorFlow/Keras)	38
2.10.3. Backend (Flask)	39
2.10.4. Frontend (HTML, CSS, JavaScript)	39
2.10.5. Các thư viện hỗ trợ	40
CHƯƠNG 3 PHÂN TÍCH VÀ THIẾT KẾ HỆ THỐNG	41
3.1 PHÂN TÍCH YÊU CẦU	41
3.1.1. Yêu cầu chức năng	41
3.1.2. Yêu cầu phi chức năng	42
3.2 KIẾN TRÚC TỔNG THỂ HỆ THỐNG	43
3.2.1. Sơ đồ Use Case	43
3.2.2. Sơ đồ kiến trúc (Frontend – Backend – ML Models)	44
3.2.3. Luồng xử lý dữ liệu	45
Hình 3.3: Sơ đồ DFD cấp 1	46
3.3 THIẾT KẾ PIPELINE XỬ LÝ DỮ LIỆU	47
3.3.1. Phát hiện vùng sâu bằng YOLOv8	47
3.3.2. Phân loại mức độ sâu bằng CNN	49
3.3.3. Tổng hợp kết quả	50
3.4 THIẾT KẾ BACKEND	51
3.4.1. Cấu trúc API chính	51
3.4.2. Các endpoint API	52
3.5 THIẾT KẾ FRONTEND	54
3.5.1. Giao diện chính	54
3.5.2. Luồng tương tác người dùng	55
3.6 THIẾT KẾ LƯU TRỮ DỮ LIỆU	56
3.6.1. Lưu ảnh upload	56
3.6.2. Lưu ảnh kết quả	57
3.6.3. Không sử dụng database	58
CHƯƠNG 4 XÂY DỰNG VÀ HUẤN LUYỆN MÔ HÌNH	60
4.1 BỘ DỮ LIỆU	60
4.1.1. Nguồn dữ liệu	60
4.1.2. Định dạng dữ liệu (YOLO format)	61

4.1.3. Kích thước và phân phối dữ liệu.....	63
4.1.4. Cách gán nhãn.....	64
4.2 TIỀN XỬ LÝ DỮ LIỆU	65
4.2.1. Chuẩn hóa kích thước ảnh.....	65
4.2.2. Chuẩn hóa giá trị pixel	66
4.2.3. Data Augmentation	67
4.2.4. Chia tập train/validation/test	68
4.3 HUẤN LUYỆN MÔ HÌNH YOLOv8	69
4.3.1. Cấu hình tham số.....	69
4.3.2. Quá trình huấn luyện.....	70
4.3.3. Kết quả huấn luyện.....	71
4.4 HUẤN LUYỆN MÔ HÌNH CNN.....	72
4.4.1. Cấu hình mô hình	72
4.4.2. Cấu hình tham số.....	73
4.4.3. Quá trình huấn luyện.....	74
4.4.4. Kết quả huấn luyện.....	75
4.5 ĐÁNH GIÁ HIỆU SUẤT MÔ HÌNH.....	76
4.5.1. Kết quả trên tập validation	76
4.5.2. Kết quả trên tập test.....	77
4.5.3. Phân tích độ chính xác và sai sót	78
4.5.4. Confusion Matrix	80
4.6 NHẬN XÉT MÔ HÌNH.....	80
CHƯƠNG 5 XÂY DỰNG HỆ THỐNG WEB.....	82
5.1 CẤU TRÚC DỰ ÁN.....	82
5.1.1. Tổ chức thư mục	82
5.1.2. Vai trò của các module.....	83
5.2 BACKEND (FLASK)	85
5.2.1. Cấu hình Flask.....	85
5.2.2. Các API endpoint chính	85
5.2.3. Tích hợp mô hình ML	86
5.2.4. Xử lý file ảnh đầu vào	87

5.2.5. Kiểm thử API bằng Postman.....	88
5.3 FRONTEND	89
5.3.1. Trang chủ	89
5.3.2. Phần upload ảnh	90
5.3.3. Hiển thị kết quả phân tích	90
5.3.4. Xuất báo cáo PDF	91
5.4 MINH HỌA GIAO DIỆN.....	92
5.4.1. Ảnh chụp các màn hình chính.....	92
5.4.2. Luồng thao tác người dùng	98
CHƯƠNG 6 KIỂM THỬ VÀ ĐÁNH GIÁ	99
6.1 KIỂM THỬ CHỨC NĂNG	99
6.1.1. Kế hoạch kiểm thử	99
6.1.2. Các test case chính	99
6.1.3. Kết quả kiểm thử.....	100
6.2 KIỂM THỬ HIỆU NĂNG	102
6.2.1. Hiệu suất mô hình trên dữ liệu thực.....	102
6.2.2. Thời gian xử lý	103
6.2.3. Nhận xét hiệu suất mô hình.....	104
6.3 ĐÁNH GIÁ TỔNG THỂ HỆ THỐNG.....	105
6.3.1. Những điểm mạnh.....	105
6.3.2. Hạn chế còn tồn tại.....	106
6.3.3. Nhận xét chung	107
CHƯƠNG 7 KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN.....	108
7.1 KẾT LUẬN	108
7.1.1. Tóm tắt những kết quả đạt được	108
7.1.2. Đánh giá mức độ đạt mục tiêu	109
7.2 HẠN CHẾ HIỆN TẠI.....	110
7.2.1. Các hạn chế về mô hình và dữ liệu	110
7.2.2. Các hạn chế về hệ thống và triển khai	110
7.3 HƯỚNG PHÁT TRIỂN.....	111
7.3.1. Cải thiện độ chính xác mô hình	111

7.3.2. Mở rộng chức năng	112
7.3.3. Triển khai thực tế	113
7.3.4. Tích hợp các tính năng bổ sung	115
TÀI LIỆU THAM KHẢO.....	117

DANH MỤC BIỂU BẢNG

Bảng 4.1: Phân phối dữ liệu giữa các tập huấn luyện, validation và test	63
Bảng 4.2: tóm tắt các chỉ số đánh giá chính của mô hình.....	72
Bảng 4.3: chi tiết các chỉ số đánh giá theo từng lớp	76
Bảng 4.4: tóm tắt kết quả đánh giá trên tập validation	77
Bảng 4.5: so sánh kết quả giữa tập validation và tập test	78

DANH MỤC HÌNH

Hình 2.1: Minh họa vùng sâu răng trên ảnh X-quang nha khoa	10
Hình 2.2: Các mức độ phát triển của sâu răng	12
Hình 2.3: Một số loại ảnh X-quang nha khoa phổ biến	13
Hình 2.4: Các loại nhiễu thường gặp trong ảnh X-quang nha khoa	16
Hình 2.5: Ảnh trước và sau khi cải thiện chất lượng ảnh X-quang	17
Hình 2.6: Quy trình trích xuất ROI từ YOLOv8 và phân loại bằng CNN.....	19
Hình 2.7: Minh họa sự khác biệt giữa bài toán phát hiện và phân loại trên ảnh X-quang nha khoa	22
Hình 2.8: Nguyên lý hoạt động của mô hình YOLOv8 trong phát hiện đối tượng ..	24
Hình 2.9: Kết quả phát hiện vùng sâu răng trên ảnh X-quang bằng YOLOv8.....	26
Hình 2.10: Kiến trúc cơ bản của mạng nơ-ron tích chập (CNN)	27
Hình 2.11: Mô hình CNN thực hiện phân loại mức độ sâu răng từ các vùng ROI...	29
Hình 3.1. Sơ đồ Use Case của hệ thống.....	43
Hình 3.2: Sơ đồ DFD cấp 0.....	45
Hình 3.3: Sơ đồ DFD cấp 1.....	46
Hình 4.1: Một số mẫu ảnh X-quang nha khoa trong bộ dữ liệu	60
Hình 4.2: Minh họa định dạng nhãn YOLO với bounding box chuẩn hóa.....	62
Hình 4.3: Ví dụ gán nhãn bounding box cho vùng sâu răng trên ảnh X-quang.....	64
Hình 5.1: Cấu trúc thư mục chính của dự án được tổ chức	82
Hình 5.2: Sơ đồ các module trong hệ thống.....	83
Hình 5.3: Giao diện trang chủ	93
Hình 5.4: Giao diện upload ảnh	93
Hình 5.5: Giao diện các chức năng chính của hệ thống.....	94
Hình 5.6: Giao diện “Về chúng tôi” của hệ thống	95
Hình 5.7. Giao diện “Liên hệ & Hỗ trợ” của hệ thống	96
Hình 5.8. Giao diện hiển thị kết quả phân tích và xuất PDF	97

DANH MỤC CÁC TỪ VIẾT TẮT

STT	Viết tắt	Viết đầy đủ
1	AI	Artificial Intelligence
2	DL	Deep Learning
3	ML	Machine Learning
4	CNN	Convolutional Neural Network
5	YOLO	You Only Look Once
6	YOLOv8	YOLO version 8
7	ROI	Region of Interest
8	API	Application Programming Interface
9	mAP	Mean Average Precision
10	TP	True Positive
11	TN	True Negative
12	FP	False Positive
13	FN	False Negative
14	F1-score	F1 Score
15	DFD	Data Flow Diagram
16	UI	User Interface
17	HTML	HyperText Markup Language
18	CSS	Cascading Style Sheets
19	JS	JavaScript
20	Flask	Flask Framework

CHƯƠNG 1

MỞ ĐẦU

1.1 LÝ DO CHỌN ĐỀ TÀI

Sâu răng là một trong những bệnh lý răng miệng phổ biến, ảnh hưởng lớn đến sức khỏe và chất lượng cuộc sống của con người. Việc phát hiện sớm và đánh giá chính xác mức độ tổn thương đóng vai trò quan trọng trong quá trình điều trị và phòng ngừa các biến chứng nghiêm trọng. Trong thực tế, ảnh X-quang nha khoa là công cụ chẩn đoán hiệu quả, cho phép quan sát cấu trúc bên trong của răng và phát hiện các tổn thương mà phương pháp quan sát trực tiếp khó nhận biết. Tuy nhiên, quá trình phân tích ảnh X-quang thường phụ thuộc nhiều vào kinh nghiệm của bác sĩ, dễ dẫn đến sai sót hoặc không nhất quán trong đánh giá.

Trong bối cảnh đó, sự phát triển mạnh mẽ của trí tuệ nhân tạo, đặc biệt là các phương pháp học sâu (Deep Learning), đã mở ra nhiều cơ hội trong lĩnh vực phân tích ảnh y tế. Các mô hình học sâu có khả năng tự động học và trích xuất đặc trưng từ dữ liệu, từ đó hỗ trợ phát hiện và phân tích các bất thường với độ chính xác cao. Việc ứng dụng Deep Learning vào bài toán phát hiện sâu răng trên ảnh X-quang không chỉ giúp nâng cao hiệu quả chẩn đoán mà còn góp phần giảm tải cho các chuyên gia y tế.

Xuất phát từ nhu cầu thực tiễn và tiềm năng của công nghệ, đề tài “Nghiên cứu và xây dựng hệ thống hỗ trợ phát hiện và phân loại sâu răng trên ảnh X-quang nha khoa bằng Deep Learning (kết hợp YOLOv8 và CNN)” được đề xuất. Đề tài hướng đến việc xây dựng một hệ thống có khả năng tự động phát hiện các vùng nghi ngờ sâu răng và phân loại mức độ tổn thương, từ đó hỗ trợ bác sĩ trong quá trình chẩn đoán.

Về mặt kỹ thuật, đề tài lựa chọn kết hợp giữa mô hình YOLOv8 và mạng nơ-ron tích chập (CNN). Trong đó, YOLOv8 được sử dụng để phát hiện và định vị nhanh các vùng nghi ngờ sâu răng trên ảnh X-quang, còn CNN đảm nhiệm vai trò phân loại mức độ tổn thương dựa trên các vùng ảnh được trích xuất. Cách tiếp cận này giúp tận dụng ưu điểm của từng mô hình, đồng thời nâng cao độ chính xác và hiệu quả xử lý của hệ thống.

Ngoài ra, đề tài không chỉ dừng lại ở việc nghiên cứu mô hình mà còn hướng đến xây dựng một hệ thống hoàn chỉnh với kiến trúc frontend – backend, cho phép người dùng tải ảnh, thực hiện phân tích và nhận kết quả một cách trực quan thông qua giao diện web. Điều này góp phần tăng tính ứng dụng thực tiễn và khả năng triển khai trong môi trường thực tế.

Từ những lý do trên, việc nghiên cứu và xây dựng hệ thống hỗ trợ phát hiện và

phân loại sâu răng trên ảnh X-quang nha khoa bằng Deep Learning là cần thiết, có ý nghĩa cả về mặt khoa học và thực tiễn, đồng thời phù hợp với xu hướng phát triển của lĩnh vực y tế số hiện nay.

1.2 TÍNH CẤP THIẾT CỦA ĐỀ TÀI

Sâu răng là một trong những bệnh lý răng miệng phổ biến nhất trên toàn thế giới, ảnh hưởng đến nhiều nhóm đối tượng khác nhau, từ trẻ em đến người trưởng thành. Theo các nghiên cứu y học, nếu không được phát hiện và điều trị kịp thời, sâu răng có thể dẫn đến nhiều biến chứng nghiêm trọng như viêm tủy, nhiễm trùng, áp xe răng hoặc thậm chí mất răng hoàn toàn. Những hậu quả này không chỉ ảnh hưởng đến chức năng ăn nhai, thẩm mỹ mà còn tác động tiêu cực đến sức khỏe tổng thể và chất lượng cuộc sống của người bệnh.

Trong thực tế lâm sàng, ảnh X-quang nha khoa đóng vai trò quan trọng trong việc hỗ trợ chẩn đoán, cho phép bác sĩ quan sát cấu trúc bên trong của răng và phát hiện các tổn thương mà mắt thường khó nhận biết. Tuy nhiên, quá trình phân tích ảnh X-quang hiện nay vẫn phụ thuộc nhiều vào kinh nghiệm và khả năng quan sát chủ quan của bác sĩ. Điều này có thể dẫn đến sự không đồng nhất trong kết quả chẩn đoán, đặc biệt đối với các trường hợp tổn thương nhỏ, giai đoạn sớm hoặc nằm ở các vị trí khó quan sát như vùng kẽ răng. Bên cạnh đó, áp lực công việc và khối lượng bệnh nhân lớn trong môi trường lâm sàng cũng làm tăng nguy cơ bỏ sót hoặc đánh giá chưa chính xác tình trạng bệnh.

Trong bối cảnh đó, sự phát triển mạnh mẽ của trí tuệ nhân tạo, đặc biệt là các kỹ thuật học sâu (Deep Learning), đã mở ra nhiều hướng tiếp cận mới trong lĩnh vực phân tích ảnh y sinh. Các mô hình học sâu có khả năng tự động học và trích xuất đặc trưng từ dữ liệu ảnh với độ chính xác cao, từ đó hỗ trợ hiệu quả cho các bài toán phát hiện và phân loại bệnh lý. Đặc biệt, các mô hình phát hiện đối tượng như YOLOv8 có thể xác định nhanh chóng vị trí tổn thương, trong khi các mô hình mạng nơ-ron tích chập (CNN) có khả năng phân loại chi tiết mức độ bệnh.

Việc kết hợp các mô hình học sâu trong xây dựng hệ thống hỗ trợ chẩn đoán không chỉ giúp nâng cao độ chính xác mà còn góp phần giảm tải cho bác sĩ, rút ngắn thời gian xử lý và tăng tính nhất quán trong kết quả đánh giá. Đồng thời, với sự phát triển của các nền tảng web, việc triển khai hệ thống dưới dạng ứng dụng trực tuyến giúp người dùng dễ dàng tiếp cận, sử dụng và tích hợp vào các hệ thống quản lý y tế hiện có.

Từ những lý do trên, việc nghiên cứu và xây dựng hệ thống hỗ trợ phát hiện và phân loại sâu răng trên ảnh X-quang nha khoa bằng Deep Learning là hết sức cần thiết. Đề tài không chỉ mang ý nghĩa khoa học trong việc ứng dụng trí tuệ nhân tạo vào xử lý ảnh y sinh mà còn có giá trị thực tiễn cao, góp phần nâng cao hiệu quả

chẩn đoán và hướng tới xây dựng các hệ thống chăm sóc sức khỏe thông minh trong tương lai.

1.3 MỤC TIÊU CỦA ĐỀ TÀI

1.3.1 Mục tiêu chung

Mục tiêu tổng quát của đề tài là ứng dụng các kỹ thuật học sâu (Deep Learning) nhằm nghiên cứu và xây dựng một hệ thống hỗ trợ phát hiện và phân loại sâu răng trên ảnh X-quang nha khoa. Hệ thống được thiết kế như một công cụ hỗ trợ bác sĩ trong quá trình chẩn đoán, góp phần nâng cao độ chính xác, giảm thiểu sai sót và tối ưu hóa thời gian xử lý trong môi trường lâm sàng.

Bên cạnh đó, đề tài hướng đến việc kết hợp các mô hình học sâu hiện đại để giải quyết đồng thời hai bài toán quan trọng trong phân tích ảnh y sinh, bao gồm phát hiện vị trí tổn thương và phân loại mức độ bệnh lý. Thông qua việc xây dựng một hệ thống hoàn chỉnh có khả năng hoạt động trên nền tảng web, đề tài không chỉ dừng lại ở nghiên cứu mô hình mà còn hướng đến khả năng ứng dụng thực tiễn, góp phần đưa công nghệ trí tuệ nhân tạo vào lĩnh vực chăm sóc sức khỏe răng miệng.

Hệ thống được xây dựng với vai trò hỗ trợ, không thay thế hoàn toàn chuyên môn của bác sĩ, mà đóng vai trò như một công cụ hỗ trợ thông minh trong quá trình chẩn đoán.

1.3.2 Mục tiêu cụ thể

Để đạt được mục tiêu chung đã đề ra, đề tài tập trung thực hiện một số mục tiêu cụ thể. Trước hết, tiến hành nghiên cứu cơ sở lý thuyết về xử lý ảnh y sinh và các phương pháp học sâu, đặc biệt là các mô hình phát hiện đối tượng và phân loại ảnh trong lĩnh vực thị giác máy tính. Trên cơ sở đó, xây dựng và huấn luyện mô hình YOLOv8 nhằm phát hiện và định vị các vùng nghi ngờ sâu răng trên ảnh X-quang nha khoa, đảm bảo khả năng nhận diện nhanh và chính xác.

Song song với đó, thiết kế và huấn luyện mô hình mạng nơ-ron tích chập (CNN) để thực hiện phân loại mức độ sâu răng thành các nhóm như không sâu, sâu nhẹ, sâu vừa và sâu nặng dựa trên các vùng ảnh đã được trích xuất. Đồng thời, xây dựng pipeline xử lý hoàn chỉnh bao gồm các bước tiền xử lý dữ liệu, phát hiện vùng bằng YOLOv8, trích xuất vùng ảnh (ROI) và phân loại bằng CNN, từ đó tạo ra kết quả đầu ra có ý nghĩa thực tiễn.

Bên cạnh việc xây dựng mô hình, đề tài còn tập trung phát triển hệ thống ứng dụng web theo kiến trúc frontend – backend, cho phép người dùng tải ảnh X-quang, thực hiện phân tích tự động và hiển thị kết quả một cách trực quan dưới dạng hình ảnh và thống kê. Đồng thời, xây dựng các API phục vụ cho việc giao tiếp giữa frontend và backend, hỗ trợ khả năng tích hợp hệ thống với các nền tảng khác trong

tương lai.

Ngoài ra, đề tài tiến hành đánh giá hiệu suất của mô hình thông qua các độ đo như Accuracy, Precision, Recall, F1-score và mAP, từ đó phân tích và nhận xét kết quả đạt được. Cuối cùng, đề xuất các hướng cải tiến và phát triển hệ thống trong tương lai nhằm nâng cao độ chính xác, hiệu năng cũng như khả năng ứng dụng thực tế của hệ thống.

1.4 ĐỐI TƯỢNG VÀ PHẠM VI NGHIÊN CỨU

1.4.1 Phạm vi không gian

Đề án được nghiên cứu và thực hiện trên cơ sở lý thuyết của các môn học thuộc chương trình đào tạo tại Trường Đại học Nam Cần Thơ, đặc biệt trong lĩnh vực công nghệ thông tin và trí tuệ nhân tạo. Đề tài được triển khai trong môi trường công nghệ thông tin dưới dạng một hệ thống ứng dụng web phục vụ cho việc phân tích ảnh X-quang nha khoa.

Hệ thống được xây dựng theo kiến trúc frontend – backend, trong đó frontend đảm nhiệm vai trò cung cấp giao diện tương tác trực quan cho người dùng, còn backend thực hiện xử lý dữ liệu và tích hợp các mô hình học sâu. Người dùng có thể truy cập hệ thống thông qua trình duyệt web để tải lên ảnh X-quang, thực hiện phân tích và quan sát kết quả một cách trực quan.

Ngoài ra, hệ thống còn được thiết kế dưới dạng dịch vụ thông qua các API, cho phép tích hợp với các nền tảng khác trong tương lai. Tuy nhiên, trong phạm vi của đề án, hệ thống chủ yếu được xây dựng và triển khai ở mức thử nghiệm trong môi trường cục bộ (localhost), chưa triển khai trên hạ tầng thực tế hoặc kết nối trực tiếp với các hệ thống y tế.

Như vậy, phạm vi không gian của đề tài tập trung vào việc xây dựng và kiểm thử một hệ thống ứng dụng web trong môi trường phát triển, đồng thời định hướng khả năng mở rộng và triển khai trong các hệ thống hỗ trợ chẩn đoán nha khoa trong tương lai.

1.4.2 Phạm vi thời gian

Đề tài được thực hiện trong khuôn khổ thời gian của học phần đề án, kéo dài từ tháng 02/2026 đến tháng 03/2026, bao gồm các giai đoạn chính như nghiên cứu lý thuyết, thu thập và xử lý dữ liệu, xây dựng và huấn luyện mô hình, phát triển hệ thống và đánh giá kết quả.

Trong khoảng thời gian này, đề tài tập trung hoàn thiện một phiên bản hệ thống có khả năng hoạt động ổn định, đáp ứng các yêu cầu cơ bản về chức năng và hiệu năng. Hệ thống được xây dựng nhằm hỗ trợ phát hiện và phân loại sâu răng trên ảnh X-quang nha khoa thông qua việc ứng dụng các mô hình học sâu.

Do giới hạn về thời gian và nguồn lực, một số nội dung nâng cao như tối ưu hóa mô hình ở mức độ chuyên sâu, mở rộng quy mô dữ liệu, triển khai hệ thống trên môi trường thực tế hoặc tích hợp trực tiếp với các hệ thống y tế chưa được thực hiện đầy đủ. Những nội dung này được định hướng là các hướng phát triển trong tương lai nhằm hoàn thiện và nâng cao hiệu quả của hệ thống.

1.4.3 Đối tượng nghiên cứu

Đối tượng nghiên cứu của đề tài bao gồm dữ liệu ảnh X-quang nha khoa hai chiều, trong đó tập trung chủ yếu vào các loại ảnh phổ biến như bitewing và periapical. Đây là các loại ảnh thường được sử dụng trong chẩn đoán sâu răng, chứa thông tin quan trọng về cấu trúc răng và các vùng tổn thương. Các vùng sâu răng trên ảnh thường biểu hiện dưới dạng các vùng có độ sáng thấp hơn so với mô răng lành, là đối tượng chính để hệ thống phát hiện và phân tích.

Bên cạnh dữ liệu ảnh, đề tài còn tập trung nghiên cứu và ứng dụng các mô hình học sâu trong lĩnh vực thị giác máy tính, cụ thể là mô hình YOLOv8 cho bài toán phát hiện đối tượng và mạng nơ-ron tích chập (CNN) cho bài toán phân loại. Hai mô hình này được kết hợp trong một pipeline xử lý nhằm thực hiện đồng thời việc xác định vị trí và đánh giá mức độ sâu răng.

Ngoài ra, hệ thống phần mềm cũng là một đối tượng nghiên cứu quan trọng. Hệ thống bao gồm backend xử lý và tích hợp mô hình học sâu, frontend hiển thị giao diện người dùng, cùng với các API phục vụ cho việc giao tiếp và mở rộng hệ thống. Việc nghiên cứu không chỉ dừng lại ở mô hình mà còn bao gồm thiết kế và triển khai một hệ thống hoàn chỉnh có khả năng ứng dụng thực tiễn.

Phạm vi nghiên cứu của đề tài được giới hạn ở việc phát hiện và phân loại các vùng sâu răng trên ảnh X-quang nha khoa hai chiều. Đề tài không đi sâu vào các phương pháp phân đoạn chi tiết (segmentation), cũng như không đề cập đến các vấn đề liên quan đến điều trị y khoa. Hệ thống được xây dựng với mục tiêu hỗ trợ phát hiện và cung cấp thông tin tham khảo cho bác sĩ, đóng vai trò như một công cụ hỗ trợ chẩn đoán nhằm nâng cao hiệu quả và độ chính xác trong quá trình phân tích ảnh.

1.5 PHƯƠNG PHÁP NGHIÊN CỨU

Đề tài được thực hiện dựa trên sự kết hợp giữa phương pháp nghiên cứu lý thuyết, phương pháp thực nghiệm và phương pháp xây dựng hệ thống phần mềm, nhằm đảm bảo tính khoa học cũng như khả năng ứng dụng thực tiễn của hệ thống đề xuất.

Về phương pháp nghiên cứu lý thuyết, đề tài tiến hành thu thập, phân tích và tổng hợp các tài liệu khoa học, bài báo và công trình nghiên cứu liên quan đến lĩnh vực trí tuệ nhân tạo, đặc biệt là học sâu (Deep Learning) và thị giác máy tính trong

xử lý ảnh y sinh. Các nội dung trọng tâm bao gồm đặc điểm của ảnh X-quang nha khoa, các phương pháp phát hiện đối tượng và phân loại ảnh, cũng như các mô hình tiêu biểu như YOLO và mạng nơ-ron tích chập (CNN). Quá trình này giúp xây dựng cơ sở lý luận vững chắc, làm nền tảng cho việc lựa chọn mô hình và thiết kế hệ thống phù hợp với bài toán phát hiện sâu răng.

Trên cơ sở đó, phương pháp thực nghiệm được triển khai thông qua việc xây dựng và huấn luyện các mô hình học sâu trên dữ liệu ảnh X-quang nha khoa đã được gán nhãn. Cụ thể, mô hình YOLOv8 được sử dụng để thực hiện bài toán phát hiện và định vị các vùng nghi ngờ sâu răng trên ảnh, trong khi mô hình CNN được áp dụng để phân loại mức độ tổn thương dựa trên các vùng ảnh được trích xuất. Quá trình thực nghiệm bao gồm các bước như tiền xử lý dữ liệu, huấn luyện mô hình, tinh chỉnh tham số và đánh giá kết quả nhằm tối ưu hiệu suất của hệ thống.

Bên cạnh đó, đề tài áp dụng phương pháp xây dựng hệ thống phần mềm bằng cách tích hợp các mô hình học sâu vào backend sử dụng Flask để tạo thành một hệ thống hoàn chỉnh. Hệ thống cho phép người dùng tải lên ảnh X-quang, thực hiện phân tích tự động và hiển thị kết quả thông qua giao diện web. Việc thiết kế hệ thống theo kiến trúc frontend – backend kết hợp với các API giúp đảm bảo tính linh hoạt, khả năng mở rộng và dễ dàng triển khai trong thực tế.

Kết quả nghiên cứu được đánh giá thông qua các chỉ số định lượng như Accuracy, Precision, Recall và F1-score đối với mô hình phân loại, cũng như mAP (Mean Average Precision) đối với mô hình phát hiện đối tượng. Các chỉ số này giúp đo lường hiệu suất của hệ thống một cách khách quan, từ đó đưa ra nhận xét và đánh giá về độ chính xác cũng như tính hiệu quả của phương pháp đề xuất.

1.6 CÔNG CỤ VÀ MÔI TRƯỜNG PHÁT TRIỂN

Để triển khai hệ thống phân tích sâu răng trên ảnh X-quang nha khoa, đề tài sử dụng kết hợp nhiều công cụ và môi trường phát triển khác nhau, bao gồm ngôn ngữ lập trình, thư viện học sâu và các công nghệ xây dựng ứng dụng web. Việc lựa chọn các công cụ này nhằm đảm bảo tính linh hoạt, hiệu quả cũng như khả năng triển khai thực tế của hệ thống.

Ngôn ngữ lập trình chính được sử dụng trong đề tài là Python, do đây là ngôn ngữ phổ biến trong lĩnh vực trí tuệ nhân tạo và xử lý ảnh. Python cung cấp nhiều thư viện mạnh mẽ hỗ trợ xây dựng và huấn luyện mô hình học sâu, đồng thời dễ dàng tích hợp với các hệ thống backend.

Về mô hình trí tuệ nhân tạo, đề tài sử dụng thư viện Ultralytics YOLOv8 để xây dựng mô hình phát hiện đối tượng, cho phép xác định nhanh chóng và chính xác các vùng nghi ngờ sâu răng trên ảnh X-quang. Bên cạnh đó, mô hình mạng nơ-ron tích chập (CNN) được triển khai thông qua các thư viện như TensorFlow hoặc

PyTorch nhằm thực hiện bài toán phân loại mức độ sâu răng. Sự kết hợp này giúp hệ thống giải quyết hiệu quả cả hai bài toán phát hiện và phân loại.

Hệ thống backend được phát triển bằng framework Flask, đóng vai trò xử lý các yêu cầu từ phía người dùng và tích hợp các mô hình học sâu vào pipeline xử lý. Flask cho phép xây dựng các API như `/api/analyze`, `/api/health` và `/api/test-models`, giúp hệ thống có khả năng giao tiếp linh hoạt giữa frontend và backend, đồng thời hỗ trợ mở rộng trong tương lai.

Phần frontend của hệ thống được xây dựng bằng các công nghệ web cơ bản như HTML, CSS và JavaScript. Giao diện được thiết kế theo hướng đơn giản, trực quan, cho phép người dùng dễ dàng tải ảnh X-quang, theo dõi quá trình phân tích và xem kết quả hiển thị. Kết quả được trình bày dưới dạng hình ảnh có đánh dấu bounding box, kèm theo thông tin phân loại và thống kê, đồng thời hỗ trợ xuất báo cáo PDF phục vụ lưu trữ và tham khảo.

Về môi trường phát triển, hệ thống được triển khai trên máy tính cá nhân với cấu hình tối thiểu bao gồm Python phiên bản 3.8 trở lên, RAM từ 4GB và dung lượng lưu trữ phù hợp để chứa dữ liệu và mô hình. Trong trường hợp có GPU hỗ trợ CUDA, quá trình huấn luyện và suy luận mô hình có thể được tăng tốc đáng kể. Ngoài ra, môi trường ảo (virtual environment) được sử dụng để quản lý các thư viện và đảm bảo tính nhất quán trong quá trình phát triển.

Nhìn chung, việc kết hợp các công cụ và môi trường phát triển nêu trên đã tạo điều kiện thuận lợi cho việc xây dựng một hệ thống hoàn chỉnh, có khả năng phân tích ảnh X-quang nha khoa, phát hiện và phân loại sâu răng một cách hiệu quả, đồng thời đảm bảo tính mở rộng và khả năng ứng dụng trong thực tế.

1.7 Ý NGHĨA CỦA ĐỀ TÀI

Về mặt khoa học, đề tài không chỉ dừng lại ở việc nghiên cứu lý thuyết mà tập trung vào việc hiện thực hóa các phương pháp học sâu trong bài toán phân tích ảnh y sinh, cụ thể là ảnh X-quang nha khoa. Thông qua việc kết hợp mô hình YOLOv8 trong bài toán phát hiện đối tượng và mạng nơ-ron tích chập (CNN) trong bài toán phân loại, đề tài góp phần làm rõ khả năng ứng dụng của Deep Learning trong việc nhận dạng và đánh giá tổn thương sâu răng một cách tự động.

Kết quả nghiên cứu cho thấy việc áp dụng các mô hình học sâu hiện đại có thể nâng cao hiệu quả xử lý ảnh, cải thiện độ chính xác trong phát hiện và phân loại tổn thương, đồng thời mở ra hướng tiếp cận mới trong việc giải quyết các bài toán phức tạp trong lĩnh vực y sinh. Qua đó, đề tài góp phần khẳng định tính khả thi cũng như tiềm năng phát triển của trí tuệ nhân tạo trong việc hỗ trợ chẩn đoán y khoa.

Về mặt thực tiễn, đề tài hướng đến việc xây dựng một hệ thống hoàn chỉnh có khả năng ứng dụng trực tiếp trong môi trường thực tế. Hệ thống được triển khai dưới dạng ứng dụng web, cho phép người dùng tải lên ảnh X-quang, thực hiện phân tích tự động và nhận kết quả trực quan bao gồm các vùng được phát hiện cùng với thông tin phân loại mức độ sâu răng. Ngoài ra, hệ thống còn hỗ trợ xuất báo cáo và cung cấp các API để tích hợp với các nền tảng khác, góp phần nâng cao tính linh hoạt và khả năng mở rộng.

Sản phẩm của đề tài có thể hỗ trợ đội ngũ y bác sĩ rút ngắn thời gian đọc phim, giảm thiểu sai sót và nâng cao độ chính xác trong quá trình chẩn đoán. Đồng thời, hệ thống đóng vai trò như một công cụ hỗ trợ thông minh, không thay thế bác sĩ mà cung cấp thêm một nguồn thông tin tham khảo đáng tin cậy, góp phần tăng tính nhất quán trong chẩn đoán, đặc biệt trong các trường hợp tổn thương nhỏ hoặc khó quan sát.

Bên cạnh đó, đề tài còn tạo tiền đề cho việc phát triển các hệ thống hỗ trợ chẩn đoán thông minh trong tương lai, góp phần hiện đại hóa quy trình khám chữa bệnh và thúc đẩy quá trình chuyển đổi số trong lĩnh vực y tế.

1.8 BỐ CỤC CỦA BÁO CÁO

Báo cáo đồ án được tổ chức thành bảy chương chính, đảm bảo trình bày một cách đầy đủ và hệ thống từ cơ sở lý thuyết đến quá trình xây dựng, triển khai và đánh giá hệ thống.

Chương 1 giới thiệu tổng quan về đề tài, bao gồm lý do chọn đề tài, mục tiêu nghiên cứu, đối tượng và phạm vi nghiên cứu, phương pháp thực hiện, công cụ phát triển cũng như ý nghĩa của đề tài. Nội dung chương này giúp định hướng và làm rõ mục tiêu mà đồ án hướng đến.

Chương 2 trình bày các cơ sở lý thuyết liên quan, bao gồm tổng quan về sâu răng, đặc điểm của ảnh X-quang nha khoa, các phương pháp xử lý ảnh và các mô hình học sâu như YOLOv8 và CNN. Đây là nền tảng quan trọng cho việc xây dựng mô hình và hệ thống trong các chương tiếp theo.

Chương 3 tập trung vào việc phân tích và thiết kế hệ thống, bao gồm xác định yêu cầu, xây dựng kiến trúc tổng thể, thiết kế pipeline xử lý ảnh cũng như thiết kế giao diện người dùng. Chương này đóng vai trò định hình cấu trúc và cách thức hoạt động của hệ thống.

Chương 4 trình bày quá trình xây dựng và huấn luyện mô hình học sâu, bao gồm mô tả bộ dữ liệu, các bước tiền xử lý, quá trình huấn luyện mô hình YOLOv8 và CNN, cùng với các phương pháp đánh giá hiệu suất mô hình.

Chương 5 mô tả việc xây dựng hệ thống ứng dụng web, bao gồm cấu trúc dự án, triển khai backend bằng Flask, xây dựng frontend và tích hợp các mô hình học

sâu vào hệ thống. Đồng thời, chương này cũng giới thiệu giao diện và luồng hoạt động của hệ thống.

Chương 6 trình bày quá trình kiểm thử và đánh giá hệ thống, bao gồm kiểm thử chức năng, đánh giá hiệu năng mô hình trên dữ liệu thực tế và đưa ra nhận xét tổng thể về kết quả đạt được cũng như các hạn chế còn tồn tại.

Chương 7 là phần kết luận và hướng phát triển, tổng kết những kết quả đạt được của đề tài, đồng thời đề xuất các hướng cải tiến và mở rộng hệ thống trong tương lai.


CHƯƠNG 2

CƠ SỞ LÝ THUYẾT

2.1 TỔNG QUAN NGHIÊN CỨU VỀ SÂU RĂNG

2.1.1 Khái niệm sâu răng

Sâu răng là một bệnh lý mạn tính của mô cứng răng, đặc trưng bởi quá trình khử khoáng xảy ra trên bề mặt men răng và lan dần vào lớp ngà răng dưới tác động của axit do vi khuẩn trong mảng bám sinh ra. Các vi khuẩn này sử dụng carbohydrate, đặc biệt là đường từ thực phẩm, để chuyển hóa thành axit hữu cơ, từ đó làm phá vỡ cấu trúc khoáng của răng theo thời gian. Quá trình này diễn ra một cách liên tục và có tính tích lũy, dẫn đến sự hình thành các tổn thương ban đầu trên men răng, sau đó phát triển sâu hơn vào các lớp bên trong nếu không được kiểm soát.



Hình 2.1: Minh họa vùng sâu răng trên ảnh X-quang nha khoa

Ở giai đoạn sớm, sâu răng thường không gây ra triệu chứng rõ rệt, khiến việc phát hiện bằng phương pháp quan sát thông thường trở nên khó khăn. Khi bệnh tiến triển, tổn thương có thể lan đến ngà răng và tủy răng, gây ra các biểu hiện như ê buốt hoặc đau nhức, thậm chí dẫn đến các biến chứng nghiêm trọng như viêm tủy hoặc nhiễm trùng. Do đặc điểm tiến triển âm thầm và phức tạp của bệnh, việc hiểu rõ bản chất của sâu răng đóng vai trò quan trọng trong quá trình nghiên cứu cũng như xây dựng các phương pháp phát hiện hiệu quả.

Trên cơ sở đó, để phân tích đầy đủ hơn về cơ chế hình thành và các yếu tố tác động đến sâu răng, cần tiếp tục xem xét các nguyên nhân và yếu tố ảnh hưởng được trình bày trong phần tiếp theo.

2.1.2 Nguyên nhân và yếu tố ảnh hưởng

Sâu răng là kết quả của sự tương tác phức tạp giữa nhiều yếu tố sinh học và môi trường, trong đó có bốn yếu tố chính bao gồm vi khuẩn, chế độ ăn uống, cấu trúc răng và thời gian. Trong khoang miệng, các vi khuẩn sinh axit, đặc biệt là *Streptococcus mutans* và *Lactobacillus*, đóng vai trò quan trọng trong việc hình

thành mảng bám và tạo ra môi trường axit gây khử khoáng men răng. Khi con người tiêu thụ thực phẩm chứa nhiều đường và tinh bột, các vi khuẩn này sẽ chuyển hóa chúng thành axit hữu cơ, từ đó làm giảm độ pH trong môi trường miệng và thúc đẩy quá trình phá hủy cấu trúc răng.

Bên cạnh yếu tố vi khuẩn và chế độ ăn uống, các đặc điểm về cấu trúc răng cũng ảnh hưởng đáng kể đến nguy cơ sâu răng. Những răng có bề mặt không đều, nhiều rãnh hoặc khe kẽ hẹp thường dễ tích tụ mảng bám, tạo điều kiện thuận lợi cho vi khuẩn phát triển. Ngoài ra, các yếu tố như vệ sinh răng miệng kém, lượng nước bọt tiết ra không đủ hoặc có độ pH thấp, cũng như thói quen sinh hoạt không lành mạnh đều góp phần làm gia tăng nguy cơ mắc bệnh.

Thời gian là một yếu tố quan trọng trong quá trình hình thành sâu răng, bởi sự tiếp xúc kéo dài giữa axit và bề mặt răng sẽ làm tăng mức độ tổn thương. Quá trình này diễn ra liên tục và tích lũy, khiến các tổn thương ban đầu dần phát triển thành các dạng sâu răng nghiêm trọng hơn nếu không được kiểm soát.

Từ những phân tích trên có thể thấy rằng sâu răng không chỉ do một nguyên nhân đơn lẻ mà là kết quả của sự kết hợp giữa nhiều yếu tố khác nhau. Sự đa dạng về nguyên nhân và mức độ ảnh hưởng của các yếu tố này cũng dẫn đến sự khác biệt trong quá trình tiến triển của bệnh, từ đó hình thành các mức độ sâu răng khác nhau được trình bày trong phần tiếp theo.

2.1.3 Các mức độ sâu răng

Dựa trên mức độ tổn thương của mô răng, sâu răng có thể được phân chia thành nhiều giai đoạn khác nhau, phản ánh quá trình tiến triển từ nhẹ đến nặng của bệnh. Ở giai đoạn ban đầu, tổn thương thường xuất hiện dưới dạng các vùng khử khoáng trên bề mặt men răng, biểu hiện bằng các đốm trắng mờ và chưa gây ra cảm giác đau. Đây là giai đoạn có thể được phục hồi nếu được phát hiện và can thiệp kịp thời.

Khi bệnh tiến triển, tổn thương lan vào lớp ngà răng, làm suy yếu cấu trúc răng và gây ra các triệu chứng như ê buốt khi tiếp xúc với thức ăn nóng, lạnh hoặc ngọt. Ở giai đoạn này, vi khuẩn đã xâm nhập sâu hơn vào bên trong răng, làm tăng nguy cơ tổn thương lan rộng nếu không được điều trị.



Hình 2.2: Các mức độ phát triển của sâu răng.

Ở giai đoạn nặng, vi khuẩn có thể xâm nhập vào tủy răng, gây viêm tủy với các biểu hiện đau nhức kéo dài và dữ dội. Nếu tiếp tục tiến triển, tình trạng này có thể dẫn đến nhiễm trùng lan rộng, hình thành áp xe hoặc thậm chí gây mất răng. Việc phân loại mức độ sâu răng không chỉ giúp đánh giá chính xác tình trạng bệnh mà còn đóng vai trò quan trọng trong việc lựa chọn phương pháp điều trị phù hợp.

Từ sự phân chia các mức độ trên có thể thấy rằng sâu răng là một bệnh lý có quá trình tiến triển liên tục và phức tạp. Điều này nhấn mạnh vai trò quan trọng của việc phát hiện sớm nhằm can thiệp kịp thời và hạn chế các biến chứng, nội dung sẽ được trình bày trong phần tiếp theo.

2.1.4 Tầm quan trọng phát hiện sớm

Từ các mức độ tiến triển của sâu răng đã trình bày, có thể thấy rằng việc phát hiện bệnh ở giai đoạn sớm đóng vai trò hết sức quan trọng trong việc nâng cao hiệu quả điều trị và bảo tồn cấu trúc răng. Ở giai đoạn ban đầu, các tổn thương trên men răng có thể được kiểm soát và phục hồi thông qua các biện pháp đơn giản như tái khoáng hóa hoặc điều chỉnh chế độ chăm sóc răng miệng, giúp hạn chế sự phát triển của bệnh mà không cần can thiệp phức tạp.

Ngược lại, khi sâu răng được phát hiện ở giai đoạn muộn, tổn thương đã lan sâu vào ngà hoặc tủy răng, việc điều trị trở nên phức tạp hơn, đòi hỏi các kỹ thuật chuyên sâu như điều trị tủy hoặc nhổ răng. Điều này không chỉ làm tăng chi phí điều trị mà còn ảnh hưởng đến chức năng ăn nhai và thẩm mỹ của người bệnh. Do đó, việc phát hiện sớm không chỉ giúp giảm thiểu biến chứng mà còn góp phần nâng cao chất lượng cuộc sống.

Tuy nhiên, trong thực tế lâm sàng, việc phát hiện sâu răng ở giai đoạn sớm gặp nhiều khó khăn do các tổn thương thường nhỏ, nằm ở vị trí khó quan sát như

vùng kẽ răng hoặc phía bên trong cấu trúc răng. Phương pháp thăm khám trực tiếp bằng mắt thường có thể không đủ để phát hiện chính xác các tổn thương này. Vì vậy, các phương pháp chẩn đoán hình ảnh, đặc biệt là ảnh X-quang nha khoa, đóng vai trò quan trọng trong việc hỗ trợ phát hiện các tổn thương tiềm ẩn.


Trong bối cảnh đó, việc ứng dụng các kỹ thuật xử lý ảnh và trí tuệ nhân tạo nhằm hỗ trợ phân tích ảnh X-quang đang trở thành một hướng tiếp cận tiềm năng, giúp nâng cao độ chính xác và tính nhất quán trong chẩn đoán. Nội dung này sẽ được trình bày chi tiết trong các phần tiếp theo của chương.

2.2 ẢNH X-QUANG NHA KHOA

2.2.1 Khái niệm và phân loại

Ảnh X-quang nha khoa là loại ảnh chẩn đoán được tạo ra bằng cách sử dụng tia X để xuyên qua các cấu trúc trong khoang miệng, từ đó ghi nhận hình ảnh của răng, xương hàm và các mô xung quanh. Nhờ khả năng phản ánh sự khác biệt về mật độ giữa các mô, ảnh X-quang cho phép phát hiện các tổn thương bên trong răng như sâu răng, tiêu xương hoặc các bất thường mà phương pháp quan sát trực tiếp khó nhận biết. Do đó, ảnh X-quang đóng vai trò quan trọng trong việc hỗ trợ chẩn đoán và đánh giá tình trạng răng miệng, đặc biệt trong các trường hợp cần phát hiện sớm các tổn thương tiềm ẩn.

Dựa trên mục đích sử dụng và phạm vi quan sát, ảnh X-quang nha khoa có thể được phân loại thành nhiều loại khác nhau. Trong đó, phổ biến nhất là ảnh bitewing, cho phép quan sát vùng kẽ giữa các răng và thường được sử dụng để phát hiện sâu răng ở giai đoạn sớm; ảnh periapical, cung cấp hình ảnh chi tiết của toàn bộ răng từ thân đến chân răng, giúp đánh giá tình trạng tủy và các mô quanh chóp; và ảnh panoramic (toàn cảnh), cho phép quan sát toàn bộ hàm răng và cấu trúc xương hàm trong một hình ảnh duy nhất. Mỗi loại ảnh có ưu điểm và phạm vi ứng dụng riêng, tùy thuộc vào mục đích chẩn đoán cụ thể.



Hình 2.3: Một số loại ảnh X-quang nha khoa phổ biến

Việc hiểu rõ khái niệm và các loại ảnh X-quang nha khoa không chỉ giúp lựa chọn phương pháp chẩn đoán phù hợp mà còn đóng vai trò quan trọng trong quá

trình xử lý và phân tích ảnh. Trên cơ sở đó, các đặc điểm kỹ thuật của ảnh X-quang sẽ được trình bày trong phần tiếp theo.

2.2.2 Đặc điểm kỹ thuật

Ảnh X-quang nha khoa có những đặc điểm kỹ thuật riêng biệt, ảnh hưởng trực tiếp đến quá trình phân tích và xử lý ảnh trong các hệ thống tự động. Trước hết, ảnh X-quang thường có độ tương phản thấp do sự khác biệt về mật độ giữa các mô trong khoang miệng không quá lớn. Điều này khiến việc phân biệt giữa các vùng mô lành và vùng tổn thương trở nên khó khăn, đặc biệt đối với các tổn thương sâu răng ở giai đoạn sớm.

Bên cạnh đó, ảnh X-quang thường chứa nhiều nhiễu phát sinh từ quá trình thu nhận ảnh, bao gồm nhiễu do thiết bị, nhiễu do chuyển động của bệnh nhân và các yếu tố môi trường. Các loại nhiễu này có thể làm giảm chất lượng hình ảnh và ảnh hưởng đến độ chính xác của các thuật toán xử lý ảnh. Ngoài ra, sự không đồng nhất về độ sáng và độ tương phản giữa các ảnh khác nhau cũng là một thách thức, đặc biệt khi dữ liệu được thu thập từ nhiều nguồn khác nhau.

Một đặc điểm quan trọng khác là cấu trúc hình học phức tạp của răng và xương hàm, với nhiều chi tiết nhỏ và chồng lấn giữa các cấu trúc. Điều này khiến việc xác định chính xác vị trí và ranh giới của tổn thương trở nên khó khăn, đòi hỏi các phương pháp xử lý ảnh và mô hình học sâu phải có khả năng trích xuất đặc trưng hiệu quả.

Những đặc điểm kỹ thuật nêu trên đặt ra nhiều thách thức trong việc phân tích ảnh X-quang nha khoa, đồng thời cũng là cơ sở để lựa chọn các phương pháp tiền xử lý và xử lý ảnh phù hợp. Nội dung này sẽ được trình bày chi tiết trong phần tiếp theo.

2.2.3 Ý nghĩa lâm sàng

Ảnh X-quang nha khoa đóng vai trò quan trọng trong thực hành lâm sàng, đặc biệt trong việc hỗ trợ chẩn đoán các bệnh lý răng miệng mà phương pháp quan sát trực tiếp khó phát hiện. Đối với sâu răng, ảnh X-quang cho phép bác sĩ quan sát được các tổn thương nằm bên trong cấu trúc răng, đặc biệt là ở các vùng kẽ răng hoặc phía dưới bề mặt men răng, nơi mà các dấu hiệu ban đầu thường không biểu hiện rõ ràng.

Thông qua ảnh X-quang, bác sĩ có thể đánh giá mức độ lan rộng của tổn thương, xác định vị trí sâu răng và đưa ra phương án điều trị phù hợp. Việc sử dụng ảnh X-quang giúp nâng cao độ chính xác trong chẩn đoán, giảm thiểu nguy cơ bỏ sót các tổn thương nhỏ và hỗ trợ theo dõi tiến triển của bệnh theo thời gian. Tuy nhiên, trong thực tế, dữ liệu ảnh X-quang thường được thu thập từ nhiều nguồn

khác nhau, dẫn đến sự không đồng nhất về chất lượng, độ phân giải và điều kiện chụp, gây khó khăn trong quá trình phân tích.

Bên cạnh đó, quá trình đọc và phân tích ảnh X-quang vẫn phụ thuộc nhiều vào kinh nghiệm và khả năng quan sát của bác sĩ, điều này có thể dẫn đến sự khác biệt trong kết quả chẩn đoán, đặc biệt đối với các tổn thương nhỏ hoặc có đặc điểm hình ảnh không rõ ràng. Ngoài ra, trong môi trường lâm sàng với khối lượng bệnh nhân lớn, áp lực công việc cũng làm tăng nguy cơ sai sót trong quá trình đánh giá.

Trong bối cảnh đó, việc ứng dụng các hệ thống hỗ trợ chẩn đoán dựa trên trí tuệ nhân tạo, đặc biệt là các mô hình học sâu, được xem là một hướng tiếp cận hiệu quả. Các hệ thống này có khả năng tự động phát hiện các vùng nghi ngờ sâu răng trên ảnh X-quang (region of interest – ROI), sau đó thực hiện phân loại mức độ tổn thương dựa trên các đặc trưng hình ảnh. Cách tiếp cận kết hợp giữa phát hiện đối tượng và phân loại ảnh này giúp nâng cao độ chính xác, tính nhất quán và hiệu quả trong quá trình phân tích.

Đây cũng chính là định hướng mà đề tài hướng đến, khi xây dựng một hệ thống kết hợp giữa mô hình YOLOv8 trong bài toán phát hiện vị trí tổn thương và mạng nơ-ron tích chập (CNN) trong bài toán phân loại mức độ sâu răng, nhằm hỗ trợ bác sĩ trong quá trình chẩn đoán một cách nhanh chóng và chính xác.

2.2.4 Các bất thường thường gặp

Trong ảnh X-quang nha khoa, ngoài các cấu trúc bình thường của răng và xương hàm, còn xuất hiện nhiều dạng bất thường khác nhau, trong đó sâu răng là một trong những tổn thương phổ biến nhất. Trên ảnh X-quang, sâu răng thường biểu hiện dưới dạng các vùng có độ sáng thấp hơn so với mô răng lành, do sự mất khoáng làm giảm khả năng hấp thụ tia X. Các tổn thương này thường xuất hiện ở vùng kẽ răng, mặt nhai hoặc gần cổ răng, tùy thuộc vào vị trí và mức độ tiến triển của bệnh.

Bên cạnh sâu răng, ảnh X-quang còn có thể ghi nhận một số bất thường khác như tiêu xương quanh răng, viêm quanh chóp, răng mọc lệch hoặc các tổn thương liên quan đến cấu trúc tủy răng. Tuy nhiên, các bất thường này có thể có đặc điểm hình ảnh tương đối giống nhau, đặc biệt trong các trường hợp tổn thương nhỏ hoặc có độ tương phản thấp, gây khó khăn trong việc phân biệt chính xác.

Một thách thức lớn trong việc phân tích ảnh X-quang nha khoa là sự chồng lấn của các cấu trúc giải phẫu, cũng như sự đa dạng về hình dạng và vị trí của các tổn thương. Điều này khiến cho việc xác định chính xác vị trí và ranh giới của vùng bất thường trở nên phức tạp. Trong nhiều trường hợp, các vùng sâu răng có kích thước nhỏ và phân bố không đồng đều, đòi hỏi các phương pháp xử lý ảnh phải có khả năng phát hiện các vùng nghi ngờ (region of interest – ROI) một cách hiệu quả.

Từ những đặc điểm trên có thể thấy rằng việc nhận diện và phân biệt các bất thường trên ảnh X-quang nha khoa là một bài toán không đơn giản, đặc biệt khi dữ liệu có nhiều nhiễu và sự không đồng nhất. Do đó, việc áp dụng các kỹ thuật xử lý ảnh và mô hình học sâu nhằm tự động phát hiện và phân loại các vùng tổn thương là một hướng tiếp cận cần thiết. Đây cũng chính là cơ sở để đề tài xây dựng hệ thống kết hợp giữa mô hình YOLOv8 trong việc phát hiện vị trí bất thường và mô hình CNN trong việc phân loại mức độ sâu răng. Nội dung về các phương pháp xử lý ảnh sẽ được trình bày trong phần tiếp theo.


2.3 TIỀN XỬ LÝ VÀ XỬ LÝ ẢNH X-QUANG NHA KHOA

2.3.1 Các loại nhiễu trong ảnh

Trong quá trình thu nhận và lưu trữ ảnh X-quang nha khoa, ảnh thường bị ảnh hưởng bởi nhiều loại nhiễu khác nhau, làm suy giảm chất lượng hình ảnh và gây khó khăn cho việc phân tích tự động. Các loại nhiễu này có thể xuất phát từ thiết bị chụp, môi trường thu nhận ảnh hoặc quá trình xử lý và lưu trữ dữ liệu.

Một trong những loại nhiễu phổ biến là nhiễu Gaussian, thường xuất hiện do các yếu tố ngẫu nhiên trong quá trình thu nhận tín hiệu, làm ảnh trở nên mờ và giảm độ sắc nét. Ngoài ra, nhiễu muối tiêu (salt-and-pepper noise) cũng có thể xuất hiện dưới dạng các điểm sáng và tối rải rác trên ảnh, gây ảnh hưởng đến việc xác định ranh giới của các cấu trúc. Bên cạnh đó, nhiễu do chuyển động của bệnh nhân trong quá trình chụp cũng làm cho ảnh bị nhòe, gây khó khăn trong việc nhận diện chi tiết.

Ngoài các loại nhiễu kể trên, ảnh X-quang nha khoa còn gặp phải vấn đề về độ tương phản thấp và sự không đồng nhất về độ sáng giữa các vùng trong ảnh. Điều này khiến cho các vùng tổn thương sâu răng, vốn đã có kích thước nhỏ và đặc điểm không rõ ràng, trở nên khó phân biệt với mô răng lành.



Hình 2.4: Các loại nhiễu thường gặp trong ảnh X-quang nha khoa

Những yếu tố nhiễu này ảnh hưởng trực tiếp đến hiệu quả của các mô hình học sâu trong việc phát hiện và phân loại. Đặc biệt, đối với mô hình YOLOv8 trong bài

toán phát hiện vị trí tổn thương và mô hình CNN trong bài toán phân loại mức độ sâu răng, chất lượng ảnh đầu vào đóng vai trò rất quan trọng. Do đó, việc xử lý và giảm nhiễu là bước cần thiết nhằm nâng cao độ chính xác của hệ thống.

Trên cơ sở đó, các phương pháp chuẩn hóa và cải thiện chất lượng ảnh sẽ được trình bày trong phần tiếp theo.


2.3.2 Chuẩn hóa và cải thiện chất lượng ảnh

Sau khi xác định các loại nhiễu và hạn chế của ảnh X-quang nha khoa, việc chuẩn hóa và cải thiện chất lượng ảnh là bước quan trọng nhằm nâng cao hiệu quả của các phương pháp phân tích tự động. Quá trình này giúp làm nổi bật các đặc trưng quan trọng của ảnh, đồng thời giảm thiểu ảnh hưởng của nhiễu và sự không đồng nhất trong dữ liệu.

Một trong những bước quan trọng là chuẩn hóa kích thước và định dạng ảnh nhằm đảm bảo tính đồng nhất của dữ liệu đầu vào cho các mô hình học sâu. Đối với mô hình YOLOv8 và CNN, việc đưa ảnh về cùng kích thước giúp quá trình huấn luyện và suy luận diễn ra ổn định, đồng thời giảm thiểu sai lệch do sự khác biệt về độ phân giải giữa các ảnh.

Bên cạnh đó, các kỹ thuật cải thiện độ tương phản như cân bằng histogram (histogram equalization) hoặc CLAHE (Contrast Limited Adaptive Histogram Equalization) thường được áp dụng nhằm làm rõ các vùng tổn thương có độ tương phản thấp. Việc tăng cường độ tương phản giúp các vùng sâu răng trở nên dễ nhận biết hơn, từ đó hỗ trợ tốt hơn cho các mô hình trong quá trình phát hiện và phân loại.

Ngoài ra, các phương pháp lọc nhiễu như lọc Gaussian, lọc trung vị (median filter) hoặc các kỹ thuật làm mịn ảnh cũng được sử dụng để loại bỏ các thành phần nhiễu không mong muốn. Điều này góp phần làm tăng độ rõ nét của ảnh và giúp các mô hình học sâu trích xuất đặc trưng hiệu quả hơn.



Hình 2.5: Ảnh trước và sau khi cải thiện chất lượng ảnh X-quang

Việc chuẩn hóa và cải thiện chất lượng ảnh không chỉ giúp nâng cao hiệu suất của mô hình YOLOv8 trong việc phát hiện các vùng nghi ngờ sâu răng mà còn cải thiện độ chính xác của mô hình CNN trong quá trình phân loại mức độ tổn

thương. Trên cơ sở đó, dữ liệu sau khi được xử lý sẽ tiếp tục được sử dụng trong các bước biến đổi dữ liệu nhằm tăng tính đa dạng và khả năng tổng quát hóa của mô hình.

2.3.3. Biến đổi dữ liệu (Data Augmentation)

Trong bài toán phân tích ảnh X-quang nha khoa, số lượng dữ liệu huấn luyện thường bị hạn chế và không đồng đều, đặc biệt đối với các trường hợp sâu răng ở các mức độ khác nhau. Điều này có thể dẫn đến hiện tượng quá khớp (overfitting) khi huấn luyện các mô hình học sâu. Do đó, việc áp dụng các kỹ thuật biến đổi dữ liệu (Data Augmentation) đóng vai trò quan trọng trong việc tăng cường số lượng và đa dạng của dữ liệu đầu vào.

Data Augmentation là quá trình tạo ra các mẫu dữ liệu mới từ dữ liệu gốc thông qua các phép biến đổi hình học và biến đổi cường độ ảnh mà không làm thay đổi bản chất của đối tượng trong ảnh. Các kỹ thuật thường được sử dụng bao gồm xoay ảnh (rotation), lật ảnh (flip), thay đổi độ sáng và độ tương phản (brightness, contrast adjustment), phóng to hoặc thu nhỏ (scaling), cũng như dịch chuyển ảnh (translation). Những biến đổi này giúp mô hình học được các đặc trưng ổn định hơn và tăng khả năng thích nghi với các điều kiện khác nhau của dữ liệu thực tế.

Đối với mô hình YOLOv8 trong bài toán phát hiện, việc áp dụng Data Augmentation giúp cải thiện khả năng nhận diện các vùng nghi ngờ sâu răng trong nhiều điều kiện khác nhau về vị trí, góc chụp và ánh sáng. Trong khi đó, đối với mô hình CNN, các phép biến đổi giúp tăng tính đa dạng của dữ liệu đầu vào, từ đó nâng cao khả năng phân loại mức độ sâu răng một cách chính xác hơn.

Ngoài ra, việc áp dụng Data Augmentation còn giúp cân bằng lại dữ liệu giữa các lớp, đặc biệt trong trường hợp số lượng mẫu giữa các mức độ sâu răng không đồng đều. Điều này góp phần giảm sai lệch trong quá trình huấn luyện và cải thiện hiệu suất tổng thể của hệ thống.

Trên cơ sở đó, dữ liệu sau khi được biến đổi sẽ tiếp tục được sử dụng trong bước chuẩn bị dữ liệu cho mô hình học sâu, nhằm đảm bảo tính hiệu quả và ổn định trong quá trình huấn luyện và suy luận.

2.3.4. Chuẩn bị dữ liệu cho mô hình học sâu

Sau khi thực hiện các bước tiền xử lý và biến đổi dữ liệu, việc chuẩn bị dữ liệu đầu vào cho mô hình học sâu là bước quan trọng nhằm đảm bảo quá trình huấn luyện và suy luận đạt hiệu quả cao. Dữ liệu cần được tổ chức và định dạng phù hợp với từng loại mô hình, đặc biệt là trong trường hợp hệ thống kết hợp giữa mô hình phát hiện đối tượng và mô hình phân loại như trong đề tài.


Đối với mô hình YOLOv8, dữ liệu được chuẩn bị theo định dạng gồm ảnh và các tệp nhãn tương ứng, trong đó mỗi đối tượng được biểu diễn bằng bounding box

kèm theo thông tin lớp. Các bounding box này xác định vị trí của các vùng nghi ngờ sâu răng trên ảnh X-quang, đóng vai trò làm dữ liệu huấn luyện cho bài toán phát hiện. Dữ liệu thường được chia thành các tập huấn luyện (training), kiểm tra (validation) và kiểm thử (test) nhằm đảm bảo khả năng đánh giá khách quan hiệu suất của mô hình.

Sau khi mô hình YOLOv8 thực hiện phát hiện, các vùng ảnh tương ứng với bounding box sẽ được trích xuất dưới dạng các vùng quan tâm (region of interest – ROI). Các ROI này sau đó được sử dụng làm đầu vào cho mô hình CNN trong bài toán phân loại mức độ sâu răng. Trước khi đưa vào CNN, các vùng ảnh này được chuẩn hóa về kích thước và giá trị pixel nhằm đảm bảo tính nhất quán của dữ liệu.

Đối với mô hình CNN, dữ liệu được gán nhãn theo các mức độ sâu răng như không sâu, sâu nhẹ, sâu vừa và sâu nặng. Việc chuẩn bị dữ liệu theo dạng này giúp mô hình học được các đặc trưng phân biệt giữa các mức độ tổn thương khác nhau, từ đó nâng cao độ chính xác trong quá trình phân loại.

Ngoài ra, việc chia dữ liệu thành các tập train, validation và test không chỉ giúp đánh giá hiệu suất mô hình mà còn góp phần kiểm soát hiện tượng quá khớp. Việc chuẩn bị dữ liệu một cách hợp lý và có hệ thống là yếu tố then chốt giúp đảm bảo hiệu quả của toàn bộ pipeline, từ phát hiện vị trí tổn thương bằng YOLOv8 đến phân loại mức độ sâu răng bằng CNN.



Hình 2.6: Quy trình trích xuất ROI từ YOLOv8 và phân loại bằng CNN

Trên cơ sở đó, dữ liệu đã được chuẩn bị sẽ được sử dụng trong quá trình huấn luyện và đánh giá các mô hình học sâu, nội dung sẽ được trình bày trong các phần tiếp theo của báo cáo.

2.4 HỌC MÁY VÀ HỌC SÂU TRONG PHÂN TÍCH ẢNH X-QUANG

2.4.1. Phương pháp truyền thống vs Deep Learning

Trong lĩnh vực phân tích ảnh y sinh, các phương pháp truyền thống và các phương pháp học sâu đều được sử dụng nhằm giải quyết các bài toán như phát hiện và phân loại đối tượng. Trước đây, các phương pháp truyền thống thường dựa trên việc trích xuất đặc trưng thủ công từ ảnh, kết hợp với các thuật toán học máy như Support Vector Machine (SVM), K-Nearest Neighbors (KNN) hoặc Random Forest

để thực hiện phân loại. Các đặc trưng này có thể bao gồm đặc trưng về cường độ sáng, biên, kết cấu hoặc hình dạng của đối tượng trong ảnh.

Tuy nhiên, các phương pháp truyền thống thường gặp nhiều hạn chế khi áp dụng vào ảnh X-quang nha khoa, do đặc điểm của loại ảnh này là có độ tương phản thấp, nhiễu nhiều và cấu trúc phức tạp. Việc thiết kế đặc trưng thủ công đòi hỏi nhiều kinh nghiệm và khó có thể bao quát hết các trường hợp khác nhau trong dữ liệu thực tế. Điều này dẫn đến hiệu quả không ổn định và khó mở rộng khi áp dụng vào các bài toán phức tạp.

Trong những năm gần đây, các phương pháp học sâu (Deep Learning) đã trở thành hướng tiếp cận chủ đạo trong xử lý ảnh, nhờ khả năng tự động học và trích xuất đặc trưng từ dữ liệu. Các mô hình học sâu, đặc biệt là mạng nơ-ron tích chập (CNN), có khả năng học các đặc trưng phân cấp từ mức thấp đến mức cao, giúp cải thiện đáng kể hiệu suất trong các bài toán nhận dạng và phân loại ảnh. Đối với bài toán phát hiện đối tượng, các mô hình hiện đại như YOLO cho phép xác định đồng thời vị trí và loại đối tượng trong ảnh với tốc độ và độ chính xác cao.

So với các phương pháp truyền thống, học sâu có ưu điểm vượt trội trong việc xử lý dữ liệu lớn và phức tạp, đồng thời giảm sự phụ thuộc vào việc thiết kế đặc trưng thủ công. Điều này đặc biệt phù hợp với bài toán phân tích ảnh X-quang nha khoa, nơi các đặc điểm của tổn thương sâu răng thường khó xác định rõ ràng.

Trên cơ sở đó, đề tài lựa chọn hướng tiếp cận sử dụng các mô hình học sâu, cụ thể là kết hợp giữa mô hình YOLOv8 trong bài toán phát hiện vị trí tổn thương và mô hình CNN trong bài toán phân loại mức độ sâu răng, nhằm xây dựng một hệ thống có hiệu quả và khả năng ứng dụng thực tiễn cao.

2.4.2. Ứng dụng trong phân tích ảnh y sinh

Trong những năm gần đây, học máy và đặc biệt là học sâu (Deep Learning) đã được ứng dụng rộng rãi trong lĩnh vực phân tích ảnh y sinh, mang lại nhiều kết quả tích cực trong việc hỗ trợ chẩn đoán và điều trị bệnh. Các mô hình học sâu có khả năng tự động học các đặc trưng phức tạp từ dữ liệu ảnh, từ đó giúp cải thiện độ chính xác và tính nhất quán trong việc nhận dạng và phân loại các tổn thương.

Trong lĩnh vực nha khoa, các kỹ thuật học sâu đã được áp dụng để phân tích ảnh X-quang nhằm phát hiện các bệnh lý như sâu răng, viêm quanh chóp, tiêu xương hoặc các bất thường về cấu trúc răng. Đặc biệt, mạng nơ-ron tích chập (CNN) được sử dụng phổ biến trong bài toán phân loại, nhờ khả năng trích xuất đặc trưng không gian hiệu quả từ dữ liệu ảnh. Các mô hình CNN có thể học được các đặc điểm phân biệt giữa răng lành và răng bị tổn thương, từ đó đưa ra dự đoán với độ chính xác cao.

Bên cạnh đó, các mô hình phát hiện đối tượng như YOLO cũng được ứng dụng trong việc xác định vị trí của các vùng bất thường trên ảnh X-quang. Các mô hình này có khả năng phát hiện đồng thời nhiều đối tượng trong ảnh và cung cấp thông tin về vị trí dưới dạng bounding box. Điều này đặc biệt hữu ích trong việc xác định các vùng nghi ngờ sâu răng (region of interest – ROI), làm cơ sở cho các bước phân tích tiếp theo.

Việc kết hợp giữa các mô hình phát hiện đối tượng và mô hình phân loại đã trở thành một hướng tiếp cận hiệu quả trong phân tích ảnh y sinh. Cụ thể, mô hình phát hiện được sử dụng để xác định vị trí tổn thương, sau đó các vùng ảnh tương ứng sẽ được đưa vào mô hình phân loại để đánh giá mức độ bệnh. Cách tiếp cận này không chỉ giúp nâng cao độ chính xác mà còn phù hợp với các hệ thống tự động hóa trong thực tế.

Trên cơ sở đó, đề tài áp dụng phương pháp kết hợp giữa mô hình YOLOv8 và mạng CNN nhằm xây dựng một hệ thống hỗ trợ phát hiện và phân loại sâu răng trên ảnh X-quang nha khoa, đáp ứng yêu cầu về độ chính xác, tốc độ xử lý và khả năng triển khai thực tế.

2.4.3. Bài toán phát hiện và phân loại


Trong lĩnh vực phân tích ảnh y sinh, hai bài toán quan trọng thường được đặt ra là bài toán phát hiện đối tượng (object detection) và bài toán phân loại (classification). Đây là hai hướng tiếp cận cơ bản nhưng có vai trò bổ trợ lẫn nhau trong việc xây dựng các hệ thống phân tích ảnh tự động.

Bài toán phát hiện đối tượng nhằm xác định vị trí của các đối tượng quan tâm trong ảnh, thường được biểu diễn dưới dạng các bounding box kèm theo thông tin về lớp đối tượng. Trong ngữ cảnh ảnh X-quang nha khoa, bài toán này tương ứng với việc xác định vị trí các vùng nghi ngờ sâu răng trên ảnh. Các mô hình hiện đại như YOLO cho phép thực hiện việc phát hiện với tốc độ cao và độ chính xác tốt, phù hợp với các hệ thống yêu cầu xử lý nhanh và thời gian thực.

Trong khi đó, bài toán phân loại tập trung vào việc xác định nhãn của đối tượng hoặc vùng ảnh dựa trên các đặc trưng đã được trích xuất. Đối với bài toán sâu răng, sau khi xác định được các vùng nghi ngờ (region of interest – ROI), các vùng này sẽ được đưa vào mô hình phân loại để đánh giá mức độ tổn thương, chẳng hạn như không sâu, sâu nhẹ, sâu vừa hoặc sâu nặng. Các mô hình CNN thường được sử dụng cho bài toán này nhờ khả năng học đặc trưng hiệu quả từ dữ liệu ảnh.

Việc kết hợp hai bài toán phát hiện và phân loại trong cùng một hệ thống mang lại nhiều lợi ích. Trước hết, mô hình phát hiện giúp thu hẹp phạm vi phân tích bằng cách xác định các vùng quan tâm, từ đó giảm nhiễu và tăng hiệu quả cho mô

hình phân loại. Ngược lại, mô hình phân loại cung cấp thông tin chi tiết về mức độ tổn thương, giúp nâng cao giá trị của kết quả phân tích.



Hình 2.7: Minh họa sự khác biệt giữa bài toán phát hiện và phân loại trên ảnh X-quang nha khoa

Trên cơ sở đó, đề tài xây dựng một pipeline hai bước, trong đó mô hình YOLOv8 được sử dụng để phát hiện và định vị các vùng nghi ngờ sâu răng trên ảnh X-quang, sau đó các vùng ảnh này được trích xuất và đưa vào mô hình CNN để phân loại mức độ sâu răng. Cách tiếp cận này không chỉ phù hợp với đặc điểm của dữ liệu mà còn đảm bảo tính hiệu quả và khả năng ứng dụng thực tiễn của hệ thống.

2.5 MÔ HÌNH YOLOv8

2.5.1 Giới thiệu YOLOv8

YOLOv8 (You Only Look Once phiên bản 8) là một trong những mô hình phát hiện đối tượng hiện đại thuộc họ YOLO, được phát triển bởi Ultralytics. Mô hình này được thiết kế nhằm thực hiện đồng thời việc xác định vị trí và phân loại đối tượng trong ảnh chỉ với một lần suy luận, từ đó mang lại tốc độ xử lý nhanh và hiệu suất cao. So với các phiên bản trước, YOLOv8 có nhiều cải tiến về kiến trúc và phương pháp huấn luyện, giúp nâng cao độ chính xác cũng như khả năng tổng quát hóa trên nhiều loại dữ liệu khác nhau.

YOLOv8 thuộc nhóm các mô hình phát hiện một giai đoạn (one-stage detector), nghĩa là mô hình trực tiếp dự đoán các bounding box và nhãn lớp của đối tượng mà không cần qua bước đề xuất vùng (region proposal) như các mô hình hai giai đoạn. Nhờ đó, YOLOv8 có thể xử lý ảnh với tốc độ nhanh, phù hợp với các ứng dụng yêu cầu thời gian thực hoặc gần thời gian thực.

Một điểm nổi bật của YOLOv8 là khả năng học đặc trưng hiệu quả từ dữ liệu ảnh thông qua mạng nơ-ron tích chập sâu, kết hợp với các cơ chế tối ưu hóa hiện đại. Mô hình sử dụng kiến trúc linh hoạt, cho phép triển khai trên nhiều quy mô khác nhau từ nhỏ đến lớn, đáp ứng các yêu cầu khác nhau về tốc độ và độ chính xác. Ngoài ra, YOLOv8 còn hỗ trợ nhiều tác vụ trong thị giác máy tính như phát hiện đối tượng, phân đoạn ảnh và nhận dạng điểm đặc trưng.

Trong bài toán phân tích ảnh X-quang nha khoa, YOLOv8 được sử dụng để phát hiện và định vị các vùng nghi ngờ sâu răng trên ảnh. Mô hình có khả năng xác định chính xác vị trí của các tổn thương dưới dạng bounding box, từ đó giúp trích xuất các vùng quan tâm (region of interest – ROI) phục vụ cho bước phân loại tiếp theo. Việc áp dụng YOLOv8 không chỉ giúp tăng tốc độ xử lý mà còn nâng cao độ chính xác trong việc xác định vị trí tổn thương, đặc biệt trong các trường hợp ảnh có nhiễu nhiều hoặc cấu trúc phức tạp.

Nhờ những ưu điểm về tốc độ và hiệu suất, YOLOv8 được xem là lựa chọn phù hợp cho hệ thống trong đề tài, đóng vai trò là bước đầu tiên trong pipeline phát hiện và phân tích sâu răng. Các nguyên lý hoạt động và kiến trúc chi tiết của mô hình sẽ được trình bày trong các phần tiếp theo.

2.5.2 Nguyên lý hoạt động

YOLOv8 hoạt động dựa trên nguyên lý phát hiện đối tượng trong một lần suy luận duy nhất (single forward pass), trong đó toàn bộ ảnh đầu vào được đưa qua mạng nơ-ron để đồng thời dự đoán vị trí và nhãn của các đối tượng. Khác với các phương pháp truyền thống sử dụng nhiều bước xử lý, YOLOv8 chia ảnh thành các vùng lưới và trực tiếp dự đoán các bounding box cùng với xác suất lớp cho từng vùng.

Cụ thể, khi một ảnh X-quang được đưa vào mô hình, YOLOv8 sẽ trích xuất các đặc trưng quan trọng thông qua các tầng tích chập (convolutional layers). Sau đó, các đặc trưng này được sử dụng để dự đoán các hộp giới hạn (bounding box) biểu diễn vị trí của các vùng nghi ngờ sâu răng, đồng thời gán nhãn và xác suất tương ứng cho từng vùng. Mỗi bounding box được xác định bởi các tham số như tọa độ vị trí, chiều rộng, chiều cao và độ tin cậy (confidence score).

Một thành phần quan trọng trong quá trình hoạt động của YOLOv8 là cơ chế lọc các dự đoán trùng lặp thông qua thuật toán Non-Maximum Suppression (NMS). Thuật toán này giúp loại bỏ các bounding box chồng lấn và chỉ giữ lại các dự đoán có độ tin cậy cao nhất, từ đó cải thiện độ chính xác của kết quả phát hiện.


Ngoài ra, YOLOv8 sử dụng các hàm mất mát (loss functions) để tối ưu đồng thời nhiều mục tiêu, bao gồm sai số vị trí của bounding box, độ chính xác phân loại và độ tin cậy của dự đoán. Quá trình huấn luyện giúp mô hình học được cách xác định chính xác vị trí và đặc điểm của các vùng tổn thương trong ảnh.

Trong bài toán phát hiện sâu răng trên ảnh X-quang nha khoa, YOLOv8 đóng vai trò xác định các vùng nghi ngờ (region of interest – ROI) một cách nhanh chóng và hiệu quả. Các vùng này sau đó được trích xuất và sử dụng làm đầu vào cho mô hình CNN trong bước phân loại mức độ sâu răng. Nhờ cơ chế hoạt động tối

ưu, YOLOv8 không chỉ đảm bảo tốc độ xử lý cao mà còn cung cấp các thông tin vị trí chính xác, phục vụ hiệu quả cho toàn bộ pipeline của hệ thống.

2.5.3. Kiến trúc mô hình

Kiến trúc của YOLOv8 được thiết kế theo dạng mạng nơ-ron tích chập sâu, bao gồm ba thành phần chính: backbone, neck và head. Mỗi thành phần đảm nhiệm một vai trò riêng trong quá trình trích xuất đặc trưng và dự đoán đối tượng, giúp mô hình đạt được hiệu suất cao trong bài toán phát hiện.



Hình 2.8: Nguyên lý hoạt động của mô hình YOLOv8 trong phát hiện đối tượng

Backbone là phần đầu của mô hình, có nhiệm vụ trích xuất các đặc trưng quan trọng từ ảnh đầu vào. Thông qua nhiều tầng tích chập liên tiếp, backbone học được các đặc trưng từ mức thấp đến mức cao, bao gồm các thông tin về biên, kết cấu và hình dạng của đối tượng. Trong YOLOv8, backbone được tối ưu để vừa đảm bảo khả năng trích xuất đặc trưng hiệu quả, vừa giảm chi phí tính toán.

Neck là thành phần trung gian, có chức năng kết hợp và tăng cường các đặc trưng được trích xuất từ backbone. Thông qua các kỹ thuật như Feature Pyramid Network (FPN) hoặc Path Aggregation Network (PAN), neck giúp mô hình kết hợp thông tin từ nhiều mức độ khác nhau, từ đó cải thiện khả năng phát hiện các đối tượng có kích thước đa dạng. Điều này đặc biệt quan trọng trong ảnh X-quang nha khoa, nơi các vùng sâu răng có thể có kích thước nhỏ và khó nhận diện.

Head là phần cuối của mô hình, thực hiện việc dự đoán các bounding box và nhãn lớp cho các đối tượng trong ảnh. Tại đây, mô hình sẽ xuất ra các thông tin bao gồm vị trí, kích thước của bounding box, độ tin cậy (confidence score) và xác suất thuộc các lớp tương ứng. YOLOv8 sử dụng cơ chế dự đoán hiện đại nhằm nâng cao độ chính xác và giảm thiểu sai lệch trong quá trình phát hiện.

Sự kết hợp giữa ba thành phần backbone, neck và head giúp YOLOv8 có khả năng phát hiện đối tượng với độ chính xác cao và tốc độ nhanh. Trong bối cảnh bài toán phát hiện sâu răng trên ảnh X-quang, kiến trúc này cho phép mô hình nhận diện hiệu quả các vùng nghi ngờ tổn thương, kể cả khi các vùng này có kích thước nhỏ hoặc bị ảnh hưởng bởi nhiễu.

Trên cơ sở kiến trúc đã trình bày, YOLOv8 trở thành một lựa chọn phù hợp cho bước phát hiện trong pipeline của đề tài, đóng vai trò quan trọng trong việc cung cấp các vùng quan tâm (ROI) cho mô hình CNN trong giai đoạn phân loại tiếp theo.


2.5.4. Ưu điểm và ứng dụng trong phát hiện sâu răng

YOLOv8 là một trong những mô hình phát hiện đối tượng hiện đại với nhiều ưu điểm nổi bật, đặc biệt phù hợp với các bài toán xử lý ảnh y sinh như phát hiện sâu răng trên ảnh X-quang nha khoa. Trước hết, mô hình có tốc độ xử lý nhanh nhờ cơ chế phát hiện một giai đoạn (one-stage), cho phép thực hiện đồng thời việc xác định vị trí và phân loại đối tượng chỉ trong một lần suy luận. Điều này giúp hệ thống có khả năng xử lý ảnh hiệu quả và đáp ứng các yêu cầu gần thời gian thực.

Bên cạnh đó, YOLOv8 có độ chính xác cao nhờ khả năng học đặc trưng mạnh mẽ từ dữ liệu ảnh thông qua mạng nơ-ron tích chập sâu. Mô hình có thể phát hiện các đối tượng có kích thước nhỏ và hình dạng phức tạp, điều này đặc biệt quan trọng trong ảnh X-quang nha khoa, nơi các vùng sâu răng thường có kích thước nhỏ và khó nhận diện. Ngoài ra, kiến trúc của YOLOv8 được tối ưu giúp giảm thiểu hiện tượng dự đoán trùng lặp và nâng cao độ tin cậy của các bounding box.

Một ưu điểm khác của YOLOv8 là khả năng linh hoạt và dễ dàng triển khai trong thực tế. Mô hình có thể được huấn luyện và sử dụng trên nhiều nền tảng khác nhau, đồng thời hỗ trợ tích hợp vào các hệ thống ứng dụng như web hoặc API. Điều này phù hợp với định hướng xây dựng hệ thống của đề tài, trong đó mô hình YOLOv8 được tích hợp vào backend để xử lý và phân tích ảnh X-quang do người dùng cung cấp.

Trong bài toán phát hiện sâu răng, YOLOv8 được sử dụng để xác định vị trí các vùng nghi ngờ tổn thương trên ảnh X-quang nha khoa. Kết quả đầu ra của mô hình là các bounding box biểu diễn các vùng quan tâm (region of interest – ROI), đóng vai trò làm đầu vào cho mô hình CNN trong bước phân loại mức độ sâu răng. Việc sử dụng YOLOv8 giúp giảm phạm vi phân tích và tăng độ chính xác của hệ thống khi chỉ tập trung vào các vùng có khả năng chứa tổn thương.



Hình 2.9: Kết quả phát hiện vùng sâu răng trên ảnh X-quang bằng YOLOv8

Từ những ưu điểm trên, có thể thấy rằng YOLOv8 là lựa chọn phù hợp cho bước phát hiện trong hệ thống của đề tài. Mô hình không chỉ đảm bảo hiệu suất cao mà còn hỗ trợ hiệu quả cho pipeline kết hợp giữa phát hiện và phân loại, góp phần nâng cao độ chính xác và tính ứng dụng thực tiễn của hệ thống phân tích sâu răng trên ảnh X-quang nha khoa.

2.6 MÔ HÌNH MẠC TÍCH CHẬP (CNN)

2.6.1 Giới thiệu CNN

Mạng nơ-ron tích chập (Convolutional Neural Network – CNN) là một trong những mô hình học sâu phổ biến và hiệu quả trong lĩnh vực xử lý ảnh và thị giác máy tính. CNN được thiết kế nhằm tự động học và trích xuất các đặc trưng từ dữ liệu ảnh thông qua các phép tích chập (convolution), từ đó phục vụ cho các bài toán như phân loại, nhận dạng và phân tích hình ảnh.

Khác với các phương pháp truyền thống yêu cầu thiết kế đặc trưng thủ công, CNN có khả năng học đặc trưng một cách tự động thông qua quá trình huấn luyện. Các tầng trong mạng CNN thường bao gồm tầng tích chập (convolutional layer), tầng kích hoạt (activation function), tầng gộp (pooling layer) và các tầng kết nối đầy đủ (fully connected layer). Sự kết hợp của các tầng này giúp mô hình học được các đặc trưng từ mức thấp như cạnh, biên đến các đặc trưng mức cao như hình dạng và cấu trúc của đối tượng.

Trong lĩnh vực ảnh y sinh, CNN được ứng dụng rộng rãi trong các bài toán phân loại bệnh lý nhờ khả năng xử lý dữ liệu ảnh phức tạp và nhiễu. Đối với bài toán sâu răng trên ảnh X-quang nha khoa, CNN có thể học được các đặc trưng phân biệt giữa răng lành và răng bị tổn thương, cũng như các mức độ khác nhau của sâu răng.

Trong đề tài này, CNN được sử dụng để thực hiện bài toán phân loại mức độ sâu răng dựa trên các vùng ảnh (region of interest – ROI) được trích xuất từ kết quả phát hiện của mô hình YOLOv8. Các ROI này được đưa vào CNN để xác định nhãn


tương ứng như không sâu, sâu nhẹ, sâu vừa hoặc sâu nặng. Việc kết hợp CNN trong pipeline giúp bổ sung thông tin chi tiết về mức độ tổn thương, từ đó nâng cao giá trị của hệ thống.

Nhờ khả năng học đặc trưng hiệu quả và tính linh hoạt trong triển khai, CNN là một lựa chọn phù hợp cho bước phân loại trong hệ thống, đóng vai trò quan trọng trong việc hoàn thiện quy trình phân tích sâu răng trên ảnh X-quang nha khoa..

2.6.2. Kiến trúc CNN và các thành phần

Kiến trúc của mạng nơ-ron tích chập (CNN) được xây dựng dựa trên nhiều lớp khác nhau, mỗi lớp đảm nhiệm một chức năng riêng trong việc trích xuất và xử lý đặc trưng từ ảnh đầu vào. Sự kết hợp của các lớp này giúp mô hình có khả năng học được các đặc trưng từ mức đơn giản đến phức tạp, phục vụ hiệu quả cho bài toán phân loại ảnh.

Thành phần quan trọng nhất trong CNN là tầng tích chập (convolutional layer), nơi các bộ lọc (filters) được áp dụng lên ảnh đầu vào để trích xuất các đặc trưng như cạnh, góc và kết cấu. Qua nhiều lớp tích chập liên tiếp, mô hình có thể học được các đặc trưng ở mức cao hơn như hình dạng và cấu trúc của đối tượng. Sau mỗi tầng tích chập, hàm kích hoạt (activation function), thường là ReLU, được sử dụng để đưa vào tính phi tuyến, giúp mô hình học được các mối quan hệ phức tạp trong dữ liệu.



Hình 2.10: Kiến trúc cơ bản của mạng nơ-ron tích chập (CNN)

Bên cạnh đó, tầng gộp (pooling layer) được sử dụng nhằm giảm kích thước của đặc trưng, đồng thời giữ lại các thông tin quan trọng. Việc giảm kích thước này không chỉ giúp giảm số lượng tham số cần học mà còn làm tăng khả năng tổng quát hóa của mô hình. Các phương pháp pooling phổ biến bao gồm max pooling và average pooling.

Sau khi các đặc trưng đã được trích xuất qua các tầng tích chập và pooling, dữ liệu sẽ được đưa vào các tầng kết nối đầy đủ (fully connected layers). Tại đây, các đặc trưng được tổng hợp và sử dụng để thực hiện việc phân loại. Lớp cuối cùng thường sử dụng hàm softmax để đưa ra xác suất thuộc về các lớp khác nhau.

Trong bài toán của đề tài, CNN được thiết kế để nhận đầu vào là các vùng ảnh (region of interest – ROI) được trích xuất từ kết quả phát hiện của mô hình

YOLOv8. Thông qua các tầng trong mạng, CNN học được các đặc trưng phân biệt giữa các mức độ sâu răng khác nhau, từ đó đưa ra kết quả phân loại tương ứng. Kiến trúc CNN không chỉ đảm bảo khả năng học đặc trưng hiệu quả mà còn phù hợp với việc triển khai trong hệ thống thực tế.

Nhờ cấu trúc nhiều tầng và khả năng học đặc trưng mạnh mẽ, CNN đóng vai trò quan trọng trong việc hoàn thiện pipeline của hệ thống, góp phần nâng cao độ chính xác trong việc phân loại mức độ sâu răng trên ảnh X-quang nha khoa.

2.6.3. Ứng dụng trong phân loại bệnh lý

Trong lĩnh vực y sinh học, đặc biệt là trong phân tích ảnh y khoa, mạng nơ-ron tích chập (CNN) đã được ứng dụng rộng rãi trong các bài toán phân loại bệnh lý nhờ khả năng học và trích xuất đặc trưng hiệu quả từ dữ liệu ảnh. Với đặc điểm dữ liệu ảnh y khoa thường có cấu trúc phức tạp, độ tương phản thấp và chứa nhiều nhiễu, CNN cho thấy ưu thế vượt trội so với các phương pháp truyền thống trong việc nhận diện và phân biệt các tổn thương.

CNN đã được áp dụng trong nhiều lĩnh vực như phát hiện khối u trong ảnh CT và MRI, phân loại tổn thương da trong ảnh y học, cũng như nhận dạng các bệnh lý về mắt và phổi. Trong các ứng dụng này, CNN có khả năng học được các đặc trưng quan trọng từ dữ liệu mà không cần thiết kế thủ công, từ đó giúp nâng cao độ chính xác và giảm phụ thuộc vào yếu tố chủ quan của con người.

Trong lĩnh vực nha khoa, CNN được sử dụng để phân tích ảnh X-quang nhằm phân loại các bệnh lý như sâu răng, viêm quanh chóp và các bất thường cấu trúc răng. Đặc biệt, trong bài toán phân loại mức độ sâu răng, CNN có thể học được các đặc trưng tinh vi từ các vùng ảnh như sự thay đổi về cường độ sáng, kết cấu và hình dạng của tổn thương, từ đó đưa ra dự đoán chính xác về mức độ bệnh.

Đối với đề tài này, CNN được ứng dụng trong việc phân loại mức độ sâu răng dựa trên các vùng ảnh (region of interest – ROI) đã được trích xuất từ mô hình YOLOv8. Các vùng ảnh này chứa thông tin tập trung về tổn thương, giúp CNN dễ dàng học được các đặc trưng liên quan và cải thiện hiệu quả phân loại. Kết quả phân loại bao gồm các mức độ như không sâu, sâu nhẹ, sâu vừa và sâu nặng, góp phần cung cấp thông tin chi tiết phục vụ cho quá trình chẩn đoán.

Nhờ khả năng xử lý hiệu quả dữ liệu ảnh phức tạp và tính linh hoạt trong triển khai, CNN đã trở thành một công cụ quan trọng trong các hệ thống hỗ trợ chẩn đoán bệnh lý. Việc ứng dụng CNN trong đề tài không chỉ nâng cao độ chính xác của hệ thống mà còn góp phần hoàn thiện pipeline phân tích ảnh X-quang nha khoa một cách toàn diện.


2.6.4. Vai trò trong phân loại mức độ sâu răng

Trong hệ thống phân tích ảnh X-quang nha khoa của đề tài, mạng nơ-ron tích chập (CNN) đóng vai trò then chốt trong việc phân loại mức độ sâu răng, góp phần hoàn thiện quá trình phân tích tự động. Sau khi mô hình YOLOv8 thực hiện phát hiện và xác định vị trí các vùng nghi ngờ tổn thương trên ảnh, các vùng ảnh tương ứng (region of interest – ROI) sẽ được trích xuất và đưa vào mô hình CNN để tiến hành phân loại.

Vai trò chính của CNN trong hệ thống là học và nhận diện các đặc trưng phân biệt giữa các mức độ sâu răng khác nhau. Thông qua quá trình huấn luyện, mô hình có thể phát hiện các thay đổi về cường độ sáng, kết cấu và hình dạng trong các vùng ảnh, từ đó phân loại chính xác các trường hợp như không sâu, sâu nhẹ, sâu vừa và sâu nặng. Điều này đặc biệt quan trọng vì các mức độ sâu răng thường có sự khác biệt không rõ ràng và khó nhận biết bằng mắt thường.

Việc sử dụng CNN giúp hệ thống không chỉ dừng lại ở việc phát hiện vị trí tổn thương mà còn cung cấp thông tin chi tiết về mức độ bệnh lý. Nhờ đó, kết quả đầu ra trở nên có giá trị hơn trong việc hỗ trợ chẩn đoán, giúp bác sĩ đưa ra quyết định điều trị phù hợp. Đồng thời, việc phân loại tự động cũng giúp giảm tải công việc và tăng tính nhất quán trong quá trình đánh giá.

Trong pipeline của hệ thống, CNN hoạt động như bước xử lý thứ hai sau YOLOv8, tạo thành một quy trình hai giai đoạn bao gồm phát hiện và phân loại. Cách tiếp cận này giúp tận dụng ưu điểm của từng mô hình: YOLOv8 đảm nhiệm việc phát hiện nhanh và chính xác vị trí tổn thương, trong khi CNN tập trung vào việc phân tích chi tiết và phân loại mức độ sâu răng.



Hình 2.11: Mô hình CNN thực hiện phân loại mức độ sâu răng từ các vùng ROI

Từ đó có thể thấy rằng CNN giữ vai trò quan trọng trong việc nâng cao độ chính xác và giá trị ứng dụng của hệ thống. Sự kết hợp giữa YOLOv8 và CNN

không chỉ giúp giải quyết hiệu quả bài toán phát hiện và phân loại sâu răng mà còn phù hợp với yêu cầu triển khai thực tế trong các hệ thống hỗ trợ chẩn đoán y khoa.

2.7 CÁC NGHIÊN CỨU LIÊN QUAN

2.7.1. Nghiên cứu sử dụng Deep Learning trong phân đoạn sâu răng

Một số nghiên cứu đã áp dụng các mô hình học sâu trong bài toán phân đoạn sâu răng trên ảnh X-quang nha khoa, nhằm xác định chính xác ranh giới của vùng tổn thương. Tiêu biểu, nghiên cứu “A Deep Learning Approach to Automatic Tooth Caries Segmentation in Panoramic Radiographs of Children in Primary Dentition, Mixed Dentition, and Permanent Dentition” đã sử dụng các mô hình học sâu để phân đoạn vùng sâu răng trên ảnh X-quang toàn cảnh, cho phép xác định chi tiết vị trí và hình dạng của tổn thương (Lee et al., 2021).

Phương pháp phân đoạn mang lại độ chính xác cao trong việc xác định ranh giới tổn thương, tuy nhiên đòi hỏi dữ liệu được gán nhãn chi tiết ở mức pixel, dẫn đến chi phí xây dựng dataset lớn và khó triển khai trong thực tế. So với hướng tiếp cận này, đề tài lựa chọn bài toán phát hiện và phân loại nhằm giảm độ phức tạp dữ liệu và phù hợp hơn với hệ thống ứng dụng. Nội dung nghiên cứu này là cơ sở tham khảo quan trọng cho đề tài, đồng thời đề xuất các hướng cải tiến và mở rộng hệ thống trong tương lai.

2.7.2. Nghiên cứu phát hiện sâu răng trên ảnh X-quang

Nhiều nghiên cứu đã tập trung vào việc sử dụng các mô hình học sâu, đặc biệt là CNN, để phát hiện các vùng nghi ngờ sâu răng trên ảnh X-quang nha khoa. Các phương pháp này có khả năng xác định vị trí tổn thương thông qua việc học đặc trưng từ dữ liệu ảnh, mang lại kết quả khả quan về độ chính xác (Khan et al., 2020; Zhang et al., 2023).

Tuy nhiên, phần lớn các nghiên cứu chỉ dừng lại ở việc phát hiện vị trí mà chưa kết hợp với phân loại mức độ tổn thương, do đó chưa cung cấp đầy đủ thông tin phục vụ cho quá trình chẩn đoán. Trong khi đó, đề tài hướng đến việc sử dụng mô hình YOLOv8 để phát hiện nhanh và chính xác các vùng nghi ngờ, đồng thời kết hợp với CNN để phân loại mức độ sâu răng, tạo thành một pipeline hoàn chỉnh. Nội dung nghiên cứu này là cơ sở tham khảo quan trọng cho đề tài, đồng thời đề xuất các hướng cải tiến và mở rộng hệ thống trong tương lai.

2.7.3. Nghiên cứu phân loại mức độ sâu răng

Bên cạnh bài toán phát hiện, một số nghiên cứu đã áp dụng CNN để phân loại mức độ sâu răng dựa trên ảnh X-quang. Các mô hình này có khả năng học được các đặc trưng hình ảnh đặc trưng của từng mức độ tổn thương, từ đó phân loại thành các nhóm khác nhau với độ chính xác cao (Chen et al., 2022).

Tuy nhiên, việc thực hiện phân loại trên toàn bộ ảnh có thể bị ảnh hưởng bởi các vùng không liên quan hoặc nhiễu, làm giảm hiệu quả của mô hình. Do đó, việc kết hợp bước phát hiện để trích xuất các vùng quan tâm (ROI) trước khi phân loại là một hướng tiếp cận hiệu quả hơn. Đề tài áp dụng phương pháp này bằng cách sử dụng YOLOv8 để xác định ROI và CNN để phân loại mức độ sâu răng. Nội dung nghiên cứu này là cơ sở tham khảo quan trọng cho đề tài, đồng thời đề xuất các hướng cải tiến và mở rộng hệ thống trong tương lai.

2.7.4. Hạn chế của các nghiên cứu hiện tại và hướng tiếp cận của đề tài

Từ các nghiên cứu đã trình bày, có thể nhận thấy rằng các phương pháp hiện tại thường tập trung riêng lẻ vào từng bài toán như phân đoạn, phát hiện hoặc phân loại, mà chưa xây dựng được một hệ thống tích hợp hoàn chỉnh. Ngoài ra, một số phương pháp yêu cầu dữ liệu gán nhãn phức tạp hoặc chưa tối ưu cho việc triển khai trong các ứng dụng thực tế.

Để khắc phục những hạn chế này, đề tài đề xuất một hướng tiếp cận kết hợp giữa mô hình YOLOv8 trong việc phát hiện vị trí các vùng nghi ngờ sâu răng và mô hình CNN trong việc phân loại mức độ tổn thương. Pipeline hai bước này giúp tận dụng ưu điểm của từng mô hình, đồng thời giảm thiểu ảnh hưởng của nhiễu và nâng cao độ chính xác tổng thể của hệ thống. Bên cạnh đó, hệ thống còn được xây dựng dưới dạng ứng dụng web, cho phép triển khai và sử dụng trong thực tế một cách linh hoạt. Nội dung nghiên cứu này là cơ sở tham khảo quan trọng cho đề tài, đồng thời đề xuất các hướng cải tiến và mở rộng hệ thống trong tương lai.

2.8. KẾT HỢP YOLOv8 VÀ CNN TRONG HỆ THỐNG

2.8.1. Kiến trúc pipeline hai bước

hình phát hiện đối tượng và mô hình phân loại được xem là một hướng tiếp cận hiệu quả nhằm nâng cao độ chính xác và tính ứng dụng của hệ thống. Trên cơ sở đó, đề tài xây dựng một pipeline hai bước, trong đó mỗi mô hình đảm nhiệm một nhiệm vụ cụ thể trong quá trình xử lý dữ liệu.

Ở bước thứ nhất, mô hình YOLOv8 được sử dụng để thực hiện bài toán phát hiện đối tượng, với mục tiêu xác định vị trí các vùng nghi ngờ sâu răng trên ảnh X-quang. Mô hình sẽ đưa ra các bounding box tương ứng với các vùng có khả năng chứa tổn thương, kèm theo độ tin cậy của từng dự đoán. Nhờ khả năng phát hiện nhanh và chính xác, YOLOv8 giúp thu hẹp phạm vi phân tích và loại bỏ các vùng không liên quan.

Ở bước thứ hai, các vùng ảnh tương ứng với các bounding box (region of interest – ROI) được trích xuất và đưa vào mô hình CNN để thực hiện phân loại mức độ sâu răng. Mô hình CNN sẽ phân tích các đặc trưng hình ảnh trong từng ROI

và đưa ra kết quả phân loại tương ứng với các mức độ như không sâu, sâu nhẹ, sâu vừa và sâu nặng.

Kiến trúc pipeline hai bước này cho phép tận dụng ưu điểm của từng mô hình: YOLOv8 đảm nhiệm việc phát hiện vị trí tổn thương với tốc độ cao, trong khi CNN tập trung vào việc phân tích chi tiết và phân loại mức độ bệnh. Việc tách biệt hai nhiệm vụ giúp giảm độ phức tạp của từng mô hình và nâng cao hiệu quả tổng thể của hệ thống.

Ngoài ra, cách tiếp cận này còn giúp tăng tính linh hoạt trong thiết kế hệ thống, cho phép dễ dàng thay thế hoặc cải tiến từng thành phần mà không ảnh hưởng đến toàn bộ pipeline. Điều này đặc biệt phù hợp với định hướng phát triển và mở rộng hệ thống trong tương lai.

Như vậy, kiến trúc pipeline hai bước đóng vai trò nền tảng trong việc xây dựng hệ thống phân tích sâu răng của đề tài, đảm bảo sự kết hợp hiệu quả giữa phát hiện và phân loại, đồng thời nâng cao khả năng ứng dụng thực tiễn.

2.8.2. Luồng xử lý dữ liệu

Dựa trên kiến trúc pipeline hai bước đã trình bày, hệ thống phân tích sâu răng trên ảnh X-quang nha khoa được thiết kế với một luồng xử lý dữ liệu tuần tự và rõ ràng, đảm bảo hiệu quả trong việc phát hiện và phân loại tổn thương. Luồng xử lý này bao gồm các bước chính từ tiếp nhận dữ liệu đầu vào đến trả kết quả đầu ra cho người dùng.

Trước hết, ảnh X-quang nha khoa được người dùng tải lên hệ thống thông qua giao diện web. Ảnh sau đó được đưa vào bước tiền xử lý nhằm chuẩn hóa kích thước, giảm nhiễu và cải thiện chất lượng ảnh, giúp tăng hiệu quả cho các mô hình học sâu trong các bước tiếp theo.

Ở bước thứ nhất, mô hình YOLOv8 được sử dụng để phát hiện và định vị các vùng nghi ngờ sâu răng trên ảnh X-quang. Mô hình sẽ trả về các bounding box tương ứng với các vùng có khả năng chứa tổn thương, kèm theo thông tin về độ tin cậy. Các vùng này được xem là các vùng quan tâm (region of interest – ROI), giúp thu hẹp phạm vi phân tích và loại bỏ các phần không liên quan.

Ở bước thứ hai, các ROI được trích xuất từ ảnh gốc và đưa vào mô hình CNN để thực hiện phân loại mức độ sâu răng. Dựa trên các đặc trưng hình ảnh, mô hình CNN sẽ phân loại các vùng này thành các nhóm như không sâu, sâu nhẹ, sâu vừa và sâu nặng.

Sau khi hoàn tất hai bước xử lý, hệ thống tiến hành tổng hợp kết quả, bao gồm việc hiển thị các bounding box trên ảnh gốc, gán nhãn mức độ tổn thương cho từng vùng và cung cấp thông kê tổng thể về tình trạng răng. Kết quả được trình bày

dưới dạng trực quan trên giao diện web, đồng thời hỗ trợ xuất báo cáo phục vụ cho việc lưu trữ và tham khảo.

Sự kết hợp giữa YOLOv8 và CNN trong luồng xử lý dữ liệu cho phép tận dụng ưu điểm của từng mô hình: YOLOv8 đảm nhiệm việc phát hiện nhanh và chính xác vị trí tổn thương, trong khi CNN thực hiện phân tích chi tiết và phân loại mức độ sâu răng. Nhờ đó, hệ thống đạt được sự cân bằng giữa tốc độ và độ chính xác, phù hợp với yêu cầu của một hệ thống hỗ trợ chẩn đoán trong thực tế.

Luồng xử lý dữ liệu này không chỉ đảm bảo tính hiệu quả trong phân tích mà còn tạo nền tảng cho việc mở rộng và cải tiến hệ thống trong tương lai, như tích hợp thêm các mô hình mới hoặc tối ưu hóa hiệu năng xử lý.

2.9. CÁC ĐỘ ĐO ĐÁNH GIÁ MÔ HÌNH

2.9.1. Accuracy

Accuracy (độ chính xác tổng thể) là một trong những độ đo phổ biến được sử dụng để đánh giá hiệu suất của mô hình học máy và học sâu trong các bài toán phân loại. Chỉ số này phản ánh tỷ lệ giữa số lượng dự đoán đúng trên tổng số mẫu dữ liệu, từ đó cho Công thức tính Accuracy được biểu diễn như sau:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

Trong đó:

- (TP) (True Positive): số mẫu được dự đoán đúng là lớp dương
- (TN) (True Negative): số mẫu được dự đoán đúng là lớp âm
- (FP) (False Positive): số mẫu bị dự đoán sai là lớp dương
- (FN) (False Negative): số mẫu bị dự đoán sai là lớp âm

Giá trị của Accuracy nằm trong khoảng từ 0 đến 1, trong đó giá trị càng cao thể hiện mô hình hoạt động càng tốt.

Trong bài toán phân loại mức độ sâu răng, Accuracy được sử dụng để đánh giá hiệu quả của mô hình CNN trong việc phân loại các vùng ảnh (ROI) thành các lớp như không sâu, sâu nhẹ, sâu vừa và sâu nặng. Một mô hình có Accuracy cao cho thấy khả năng phân loại tổng thể tốt trên tập dữ liệu.

Tuy nhiên, Accuracy có thể không phản ánh đầy đủ hiệu suất của mô hình trong trường hợp dữ liệu bị mất cân bằng giữa các lớp. Ví dụ, nếu số lượng mẫu “không sâu” chiếm tỷ lệ lớn, mô hình có thể đạt Accuracy cao nhưng vẫn phân loại kém đối với các lớp còn lại. Do đó, cần kết hợp Accuracy với các độ đo khác như Precision, Recall và F1-score để đánh giá toàn diện hơn.

Như vậy, Accuracy là một chỉ số quan trọng trong việc đánh giá hiệu suất mô hình, nhưng cần được sử dụng kết hợp với các độ đo khác nhằm đảm bảo tính khách quan và đầy đủ trong quá trình đánh giá.

2.9.2. Precision, Recall

Precision và Recall là hai độ đo quan trọng được sử dụng để đánh giá hiệu suất của mô hình phân loại, đặc biệt trong các bài toán có dữ liệu mất cân bằng giữa các lớp. Hai chỉ số này giúp đánh giá chi tiết hơn khả năng dự đoán của mô hình so với Accuracy.

Precision (độ chính xác dương) phản ánh tỷ lệ các mẫu được dự đoán là dương thực sự đúng. Công thức được biểu diễn như sau:

$$\text{Precision} = \frac{TP}{TP + FP}$$

Trong đó:

- (TP) (True Positive): số mẫu được dự đoán đúng là lớp dương
- (FP) (False Positive): số mẫu bị dự đoán sai là lớp dương

Precision cao cho thấy mô hình ít đưa ra dự đoán sai đối với lớp dương.

Recall (độ bao phủ) phản ánh khả năng của mô hình trong việc phát hiện đúng các mẫu dương thực sự. Công thức được biểu diễn như sau:

$$\text{Recall} = \frac{TP}{TP + FN}$$

Trong đó:

- (TP): số mẫu được dự đoán đúng là lớp dương
- (FN) (False Negative): số mẫu bị dự đoán sai là lớp âm

Recall cao cho thấy mô hình có khả năng phát hiện tốt các trường hợp dương, hạn chế bỏ sót.

Trong bài toán phân loại mức độ sâu răng, Precision thể hiện mức độ chính xác khi mô hình dự đoán một vùng ảnh là có sâu răng, trong khi Recall phản ánh khả năng phát hiện đầy đủ các vùng thực sự bị sâu. Việc cân bằng giữa Precision và Recall là rất quan trọng, đặc biệt trong các hệ thống hỗ trợ chẩn đoán, nơi việc bỏ sót tổn thương (Recall thấp) có thể gây hậu quả nghiêm trọng.

Do đó, Precision và Recall thường được sử dụng kết hợp để đánh giá toàn diện hiệu suất của mô hình, đồng thời là cơ sở để tính toán chỉ số F1-score, sẽ được trình bày trong phần tiếp theo.

2.9.3. F1-score

F1-score là một độ đo tổng hợp được sử dụng để đánh giá hiệu suất của mô hình phân loại, đặc biệt trong các trường hợp dữ liệu mất cân bằng. Chỉ số này là trung bình điều hòa (harmonic mean) của Precision và Recall, giúp cân bằng giữa hai yếu tố này trong quá trình đánh giá.

Công thức tính F1-score được biểu diễn như sau:

$$F1 - score = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

Trong đó:

- (Precision): độ chính xác dương
- (Recall): độ bao phủ

F1-score có giá trị nằm trong khoảng từ 0 đến 1, trong đó giá trị càng cao cho thấy mô hình có sự cân bằng tốt giữa Precision và Recall.

Trong bài toán phân loại mức độ sâu răng, F1-score được sử dụng để đánh giá tổng thể hiệu suất của mô hình CNN khi cần đảm bảo cả hai yếu tố: không dự đoán sai quá nhiều (Precision cao) và không bỏ sót các trường hợp sâu răng (Recall cao). Điều này đặc biệt quan trọng trong các hệ thống hỗ trợ chẩn đoán y khoa, nơi yêu cầu độ tin cậy cao trong việc phát hiện và đánh giá bệnh lý.

So với Accuracy, F1-score cung cấp một cái nhìn toàn diện hơn về hiệu suất của mô hình, đặc biệt trong trường hợp dữ liệu không cân bằng giữa các lớp. Do đó, F1-score thường được sử dụng kết hợp với các độ đo khác để đánh giá chính xác khả năng hoạt động của hệ thống.

Như vậy, F1-score là một chỉ số quan trọng giúp đánh giá hiệu quả tổng thể của mô hình phân loại, đóng vai trò bổ sung cho Precision và Recall trong việc phân tích hiệu suất.

2.9.4. Confusion Matrix

Confusion Matrix (ma trận nhầm lẫn) là một công cụ quan trọng được sử dụng để đánh giá hiệu suất của mô hình phân loại, cho phép phân tích chi tiết các kết quả dự đoán của mô hình trên từng lớp dữ liệu. Thay vì chỉ cung cấp một giá trị tổng quát như Accuracy, Confusion Matrix giúp thể hiện rõ mô hình dự đoán đúng và sai ở những trường hợp nào.

Đối với bài toán phân loại nhị phân, Confusion Matrix được biểu diễn dưới dạng bảng gồm bốn thành phần chính: True Positive (TP), True Negative (TN), False Positive (FP) và False Negative (FN). Các giá trị này được định nghĩa như sau:

- (TP) (True Positive): số mẫu thuộc lớp dương được dự đoán đúng
- (TN) (True Negative): số mẫu thuộc lớp âm được dự đoán đúng
- (FP) (False Positive): số mẫu thuộc lớp âm nhưng bị dự đoán sai thành lớp dương
- (FN) (False Negative): số mẫu thuộc lớp dương nhưng bị dự đoán sai thành lớp âm

Trong bài toán phân loại mức độ sâu răng, Confusion Matrix có thể được mở rộng cho nhiều lớp (multi-class), tương ứng với các mức độ như không sâu, sâu nhẹ, sâu vừa và sâu nặng. Khi đó, ma trận sẽ thể hiện số lượng mẫu được dự đoán đúng và sai giữa từng cặp lớp, giúp phân tích chi tiết hiệu suất của mô hình CNN.

Thông qua Confusion Matrix, có thể xác định được các loại lỗi mà mô hình thường mắc phải, ví dụ như nhầm lẫn giữa “sâu nhẹ” và “sâu vừa”, từ đó đưa ra các biện pháp cải thiện như điều chỉnh dữ liệu huấn luyện hoặc tối ưu mô hình. Ngoài ra, các độ đo như Accuracy, Precision, Recall và F1-score cũng được tính toán dựa trên các giá trị trong Confusion Matrix.

Như vậy, Confusion Matrix không chỉ giúp đánh giá hiệu suất tổng thể mà còn cung cấp cái nhìn chi tiết về hành vi của mô hình, đóng vai trò quan trọng trong việc phân tích và cải thiện hệ thống phân loại sâu răng trong đề tài.

2.9.5. mAP (Mean Average Precision)

Mean Average Precision (mAP) là một trong những độ đo quan trọng nhất được sử dụng để đánh giá hiệu suất của các mô hình phát hiện đối tượng, đặc biệt là các mô hình như YOLOv8. Chỉ số này phản ánh khả năng của mô hình trong việc phát hiện đúng vị trí và phân loại chính xác các đối tượng trong ảnh.

Để hiểu mAP, trước hết cần xét đến chỉ số Average Precision (AP), được tính dựa trên đường cong Precision–Recall của mô hình. AP đo lường diện tích dưới đường cong Precision–Recall, thể hiện sự cân bằng giữa Precision và Recall ở các ngưỡng khác nhau. Công thức tổng quát của AP có thể được biểu diễn như sau:

$$AP = \int_0^1 \text{Precision}(\text{Recall}) d\text{Recall}$$

mAP là giá trị trung bình của AP trên tất cả các lớp đối tượng:

$$mAP = \frac{1}{N} \sum_{i=1}^N AP_i$$

Trong đó:

- (N): số lớp đối tượng
- (AP_i): Average Precision của lớp thứ (i)

Trong bài toán phát hiện sâu rằng, mAP được sử dụng để đánh giá hiệu quả của mô hình YOLOv8 trong việc xác định đúng vị trí các vùng nghi ngờ tổn thương trên ảnh X-quang. Một dự đoán được xem là đúng khi bounding box dự đoán có độ chồng lấp đủ lớn với bounding box thực tế, thường được đo bằng chỉ số IoU (Intersection over Union). Ngưỡng IoU phổ biến là 0.5, thường được ký hiệu là mAP@0.5.

Chỉ số mAP càng cao cho thấy mô hình có khả năng phát hiện chính xác cả về vị trí và phân loại đối tượng. Trong hệ thống của đề tài, mAP đóng vai trò quan trọng trong việc đánh giá hiệu suất của bước phát hiện (YOLOv8), từ đó ảnh hưởng trực tiếp đến chất lượng của các vùng ROI được đưa vào mô hình CNN để phân loại.

Như vậy, mAP là một độ đo toàn diện cho các mô hình phát hiện đối tượng, giúp đánh giá chính xác khả năng hoạt động của YOLOv8 trong hệ thống phân tích sâu rằng. Việc tối ưu mAP không chỉ nâng cao độ chính xác phát hiện mà còn góp phần cải thiện hiệu quả tổng thể của toàn bộ pipeline.

2.10. CÔNG NGHỆ VÀ CÔNG CỤ XÂY DỰNG HỆ THỐNG

2.10.1. Ngôn ngữ lập trình (Python)

Python là ngôn ngữ lập trình chính được sử dụng trong đề tài, nhờ vào tính đơn giản, dễ sử dụng và hệ sinh thái thư viện phong phú, đặc biệt trong lĩnh vực trí tuệ nhân tạo và xử lý ảnh. Python hỗ trợ mạnh mẽ cho việc phát triển các mô hình học sâu cũng như xây dựng các hệ thống ứng dụng hoàn chỉnh.

Trong lĩnh vực học sâu, Python cung cấp nhiều thư viện phổ biến như TensorFlow, Keras và PyTorch, cho phép xây dựng, huấn luyện và triển khai các mô hình như CNN một cách hiệu quả. Bên cạnh đó, thư viện Ultralytics YOLOv8 cũng được phát triển trên nền tảng Python, giúp dễ dàng tích hợp mô hình phát hiện đối tượng vào hệ thống.

Ngoài ra, Python còn hỗ trợ nhiều thư viện xử lý ảnh như OpenCV, NumPy và Pillow, giúp thực hiện các bước tiền xử lý dữ liệu như chuẩn hóa kích thước, lọc

nhiều và tăng cường chất lượng ảnh. Những công cụ này đóng vai trò quan trọng trong việc chuẩn bị dữ liệu đầu vào cho các mô hình học sâu.

Trong đề tài, Python được sử dụng để xây dựng toàn bộ phần backend của hệ thống thông qua framework Flask. Backend đảm nhiệm các chức năng như tiếp nhận ảnh từ người dùng, xử lý dữ liệu, thực hiện suy luận với các mô hình YOLOv8 và CNN, cũng như trả kết quả về giao diện người dùng thông qua các API.

Nhờ tính linh hoạt và khả năng tích hợp cao, Python cho phép kết nối các thành phần trong hệ thống một cách hiệu quả, từ xử lý dữ liệu, triển khai mô hình đến xây dựng ứng dụng web. Điều này giúp rút ngắn thời gian phát triển và nâng cao khả năng mở rộng của hệ thống trong thực tế.

2.10.2. Framework AI (Ultralytics YOLOv8, TensorFlow/Keras)

Trong đề tài, các framework trí tuệ nhân tạo đóng vai trò quan trọng trong việc xây dựng và triển khai các mô hình học sâu phục vụ cho bài toán phát hiện và phân loại sâu răng trên ảnh X-quang nha khoa. Hai framework chính được sử dụng là Ultralytics YOLOv8 và TensorFlow/Keras.

Ultralytics YOLOv8 là một framework hiện đại được phát triển nhằm hỗ trợ các bài toán thị giác máy tính, đặc biệt là phát hiện đối tượng. Framework này cung cấp các công cụ thuận tiện cho việc huấn luyện, đánh giá và triển khai mô hình YOLOv8 với hiệu suất cao. Trong đề tài, YOLOv8 được sử dụng để phát hiện và định vị các vùng nghi ngờ sâu răng trên ảnh X-quang, thông qua việc dự đoán các bounding box và độ tin cậy tương ứng. Việc sử dụng Ultralytics giúp đơn giản hóa quá trình triển khai mô hình, đồng thời đảm bảo khả năng mở rộng và tối ưu hiệu năng.

Bên cạnh đó, TensorFlow và Keras được sử dụng để xây dựng và huấn luyện mô hình mạng nơ-ron tích chập (CNN) phục vụ cho bài toán phân loại mức độ sâu răng. TensorFlow là một nền tảng mạnh mẽ cho học sâu, trong khi Keras cung cấp giao diện lập trình cấp cao giúp đơn giản hóa việc thiết kế mô hình. Nhờ đó, việc xây dựng các kiến trúc CNN trở nên linh hoạt và dễ dàng điều chỉnh theo yêu cầu của bài toán.

Sự kết hợp giữa Ultralytics YOLOv8 và TensorFlow/Keras cho phép tận dụng ưu điểm của từng framework: YOLOv8 đảm nhiệm việc phát hiện nhanh và chính xác vị trí tổn thương, trong khi CNN xây dựng bằng TensorFlow/Keras đảm bảo khả năng phân loại chi tiết mức độ sâu răng. Điều này tạo nên một pipeline hoàn chỉnh, phù hợp với mục tiêu của đề tài.

Nhờ việc sử dụng các framework AI hiện đại, hệ thống không chỉ đạt hiệu quả cao trong xử lý mà còn dễ dàng triển khai, bảo trì và mở rộng trong tương lai, đáp ứng yêu cầu của một hệ thống hỗ trợ chẩn đoán thực tế.

2.10.3. Backend (Flask)

Trong hệ thống phân tích sâu răng trên ảnh X-quang nha khoa, backend đóng vai trò trung tâm trong việc xử lý dữ liệu, tích hợp mô hình học sâu và cung cấp các dịch vụ cho frontend thông qua API. Trong đề tài này, backend được xây dựng bằng framework Flask, một framework web nhẹ và linh hoạt của Python.

Flask cho phép xây dựng các ứng dụng web theo kiến trúc đơn giản nhưng hiệu quả, phù hợp với các hệ thống tích hợp trí tuệ nhân tạo. Nhờ khả năng mở rộng và dễ dàng tích hợp với các thư viện Python, Flask được sử dụng để kết nối các mô hình YOLOv8 và CNN vào một pipeline xử lý hoàn chỉnh.

Cụ thể, backend đảm nhiệm các chức năng chính như tiếp nhận ảnh X-quang từ người dùng thông qua giao diện web, thực hiện tiền xử lý dữ liệu, gọi mô hình YOLOv8 để phát hiện các vùng nghi ngờ sâu răng, sau đó trích xuất các vùng quan tâm (ROI) và đưa vào mô hình CNN để phân loại mức độ sâu răng. Kết quả sau khi xử lý sẽ được tổng hợp và trả về cho frontend dưới dạng dữ liệu JSON.

Ngoài ra, hệ thống backend còn cung cấp các API phục vụ cho việc giao tiếp giữa frontend và backend, chẳng hạn như API phân tích ảnh (/api/analyze), API kiểm tra trạng thái hệ thống (/api/health) và API kiểm tra mô hình (/api/test-models). Việc xây dựng các API này giúp hệ thống có khả năng mở rộng và dễ dàng tích hợp với các nền tảng khác trong tương lai.

Nhờ sử dụng Flask, backend của hệ thống đạt được sự cân bằng giữa hiệu năng và tính linh hoạt, đồng thời hỗ trợ hiệu quả cho việc triển khai các mô hình học sâu trong môi trường thực tế.

2.10.4. Frontend (HTML, CSS, JavaScript)

Frontend là thành phần giao diện người dùng của hệ thống, đóng vai trò trung gian giữa người dùng và backend. Trong đề tài này, frontend được xây dựng bằng các công nghệ web cơ bản bao gồm HTML, CSS và JavaScript, nhằm đảm bảo tính đơn giản, trực quan và dễ sử dụng.

HTML được sử dụng để xây dựng cấu trúc của trang web, bao gồm các thành phần như khu vực tải ảnh, vùng hiển thị kết quả và các nút chức năng. CSS được sử dụng để thiết kế giao diện, giúp hệ thống có bố cục rõ ràng, dễ nhìn và phù hợp với mục đích sử dụng trong lĩnh vực nha khoa. Trong khi đó, JavaScript đóng vai trò xử lý logic phía client, bao gồm việc gửi yêu cầu (request) đến backend thông qua API và nhận dữ liệu phản hồi để hiển thị kết quả.

Trong hệ thống, người dùng có thể tải lên ảnh X-quang thông qua giao diện web. Sau khi gửi ảnh, frontend sẽ gọi API của backend để thực hiện phân tích. Kết quả trả về bao gồm hình ảnh có đánh dấu các vùng nghi ngờ sâu răng (bounding

box), thông tin phân loại mức độ và các thống kê liên quan. Các thông tin này được hiển thị một cách trực quan, giúp người dùng dễ dàng quan sát và đánh giá.

Ngoài ra, frontend còn hỗ trợ các chức năng như kéo thả ảnh (drag-and-drop), hiển thị tiến trình xử lý và tải xuống báo cáo kết quả dưới dạng file PDF. Những tính năng này giúp nâng cao trải nghiệm người dùng và tăng tính tiện lợi trong quá trình sử dụng hệ thống.

Nhờ sử dụng các công nghệ web phổ biến, frontend của hệ thống có khả năng hoạt động trên nhiều trình duyệt khác nhau mà không cần cài đặt thêm phần mềm. Điều này góp phần tăng khả năng tiếp cận và triển khai hệ thống trong thực tế.

2.10.5. Các thư viện hỗ trợ

Bên cạnh các framework chính, đề tài còn sử dụng nhiều thư viện hỗ trợ nhằm phục vụ cho các bước xử lý ảnh, xây dựng mô hình và triển khai hệ thống. Việc kết hợp các thư viện này giúp nâng cao hiệu quả xử lý và đơn giản hóa quá trình phát triển hệ thống.

Trong xử lý ảnh, thư viện OpenCV được sử dụng để thực hiện các thao tác như đọc ảnh, chuyển đổi định dạng, xử lý nhiễu và hiển thị kết quả. Ngoài ra, NumPy đóng vai trò quan trọng trong việc xử lý dữ liệu số và thao tác trên ma trận, là nền tảng cho nhiều phép toán trong học sâu. Thư viện Pillow cũng được sử dụng để hỗ trợ đọc, ghi và xử lý ảnh với nhiều định dạng khác nhau.

Trong quá trình xây dựng và huấn luyện mô hình CNN, các thư viện như TensorFlow và Keras cung cấp các công cụ mạnh mẽ để thiết kế kiến trúc mạng, huấn luyện và đánh giá mô hình. Đồng thời, thư viện Ultralytics hỗ trợ triển khai nhanh chóng mô hình YOLOv8 cho bài toán phát hiện đối tượng.

Đối với backend, ngoài Flask, một số thư viện hỗ trợ như Flask-CORS được sử dụng để xử lý vấn đề truy cập tài nguyên giữa frontend và backend, trong khi các thư viện như Werkzeug hỗ trợ quản lý request và response trong ứng dụng web.

Ngoài ra, hệ thống còn sử dụng các thư viện hỗ trợ xuất báo cáo như ReportLab hoặc các công cụ tương tự để tạo file PDF chứa kết quả phân tích, giúp người dùng dễ dàng lưu trữ và chia sẻ thông tin.

Việc sử dụng kết hợp các thư viện hỗ trợ này giúp hệ thống hoạt động ổn định, nâng cao hiệu suất xử lý và đảm bảo khả năng mở rộng trong quá trình phát triển. Đây cũng là yếu tố quan trọng góp phần hoàn thiện hệ thống phân tích sâu rộng trên ảnh X-quang nha khoa của đề tài.

CHƯƠNG 3

PHÂN TÍCH VÀ THIẾT KẾ HỆ THỐNG

3.1 PHÂN TÍCH YÊU CẦU

3.1.1. Yêu cầu chức năng

Hệ thống phân tích sâu răng trên ảnh X-quang nha khoa được xây dựng nhằm hỗ trợ người dùng trong việc phát hiện và đánh giá mức độ tổn thương một cách tự động. Để đáp ứng mục tiêu đó, hệ thống cần thực hiện các chức năng chính sau:

Thứ nhất, hệ thống cho phép người dùng tải lên ảnh X-quang nha khoa từ máy tính cá nhân với các định dạng phổ biến như JPEG hoặc PNG. Sau khi người dùng thực hiện thao tác upload, hệ thống sẽ kiểm tra tính hợp lệ của file và phản hồi trạng thái tương ứng, đảm bảo dữ liệu đầu vào phù hợp cho quá trình xử lý. Trong trường hợp mở rộng, hệ thống có thể hỗ trợ tải lên nhiều ảnh cùng lúc.

Thứ hai, hệ thống thực hiện chức năng phân tích ảnh tự động thông qua API /api/analyze. Sau khi nhận được ảnh đầu vào, backend tiến hành xử lý bằng mô hình YOLOv8 để phát hiện và định vị các vùng nghi ngờ sâu răng trên ảnh X-quang. Tiếp theo, các vùng quan tâm (ROI) được trích xuất và đưa vào mô hình CNN để phân loại mức độ sâu răng thành các nhóm như không sâu, sâu nhẹ, sâu vừa và sâu nặng. Kết quả trả về bao gồm thông tin về bounding box (tọa độ), độ tin cậy (confidence), nhãn phân loại và các thống kê tổng hợp về số lượng tổn thương.

Thứ ba, hệ thống cung cấp khả năng hiển thị kết quả một cách trực quan trên giao diện người dùng. Các vùng được phát hiện sẽ được đánh dấu bằng bounding box trên ảnh gốc, kèm theo nhãn mức độ tương ứng. Đồng thời, hệ thống hiển thị bảng thống kê tổng hợp, bao gồm tổng số vùng sâu răng phát hiện và phân bố theo từng mức độ. Ngoài ra, hệ thống có thể hỗ trợ tải xuống ảnh kết quả hoặc báo cáo dưới dạng file để phục vụ lưu trữ và tham khảo.

Thứ tư, hệ thống cung cấp chức năng kiểm tra trạng thái hoạt động thông qua API /api/health, cho phép xác định backend đang hoạt động bình thường và sẵn sàng xử lý yêu cầu. Bên cạnh đó, API /api/test-models được sử dụng để kiểm tra tình trạng tải và hoạt động của các mô hình YOLOv8 và CNN, đảm bảo hệ thống vận hành ổn định.

Thứ năm, hệ thống hỗ trợ quản lý các file tạm trong quá trình xử lý, bao gồm ảnh đầu vào và ảnh kết quả. Các file này được lưu trữ trong thư mục tạm và có thể được xóa tự động sau một khoảng thời gian nhất định nhằm tối ưu tài nguyên lưu trữ. Hệ thống không yêu cầu sử dụng cơ sở dữ liệu mà sử dụng hệ thống file để quản lý dữ liệu.

Cuối cùng, hệ thống có thể được mở rộng với chức năng lưu trữ lịch sử và nhật ký xử lý, bao gồm thông tin về thời gian xử lý, kết quả phân tích và các yêu cầu từ người dùng. Điều này hỗ trợ việc theo dõi, đánh giá và cải thiện hiệu suất hệ thống trong tương lai.

3.1.2. Yêu cầu phi chức năng

Bên cạnh các yêu cầu chức năng, hệ thống phân tích sâu răng trên ảnh X-quang nha khoa cần đáp ứng các yêu cầu phi chức năng nhằm đảm bảo hiệu năng, độ tin cậy và khả năng vận hành trong môi trường thực tế. Các yêu cầu này được mô tả như sau:

Thứ nhất, về hiệu năng, hệ thống cần đảm bảo thời gian phản hồi nhanh đối với các yêu cầu phân tích ảnh. Cụ thể, API `/api/analyze` được thiết kế để xử lý và trả kết quả trong khoảng thời gian dưới 3 giây đối với ảnh có kích thước trung bình (ví dụ 1024×1024), tùy thuộc vào cấu hình phần cứng. Ngoài ra, hệ thống cần có khả năng xử lý đồng thời nhiều yêu cầu (khoảng 5–10 yêu cầu mỗi giây), đồng thời các mô hình YOLOv8 và CNN được tải sẵn khi khởi động hệ thống nhằm tránh việc tải lại mô hình trong mỗi request, giúp giảm độ trễ xử lý.

Thứ hai, về độ chính xác và độ tin cậy, hệ thống cần đảm bảo chất lượng dự đoán của các mô hình học sâu. Mô hình YOLOv8 được kỳ vọng đạt chỉ số mAP (hoặc AP) lớn hơn 0.7 trên tập kiểm thử, trong khi mô hình CNN đạt độ chính xác (Accuracy) trên 0.85 trong bài toán phân loại mức độ sâu răng. Bên cạnh đó, hệ thống cần có cơ chế xử lý ngoại lệ, đảm bảo phản hồi rõ ràng trong các trường hợp lỗi như dữ liệu đầu vào không hợp lệ hoặc lỗi trong quá trình suy luận, thông qua các mã trạng thái HTTP phù hợp (400, 500) và thông báo cụ thể.

Thứ ba, về bảo mật, hệ thống cần kiểm tra định dạng và kích thước của ảnh đầu vào nhằm ngăn chặn các file không hợp lệ hoặc có nguy cơ gây hại. Kích thước file upload được giới hạn (ví dụ tối đa 5MB mỗi ảnh), đồng thời cấu hình CORS chỉ cho phép các nguồn hợp lệ (frontend của hệ thống) truy cập vào API backend.

Thứ tư, về tính ổn định và khả năng phục hồi, hệ thống cần có cơ chế ghi log cho mỗi yêu cầu, bao gồm thời gian xử lý, trạng thái và kết quả trả về, nhằm hỗ trợ việc giám sát và phát hiện lỗi. Ngoài ra, hệ thống có thể triển khai cơ chế thử lại (retry) trong trường hợp xảy ra lỗi tạm thời trong quá trình gọi mô hình. Các file tạm được quản lý và xóa định kỳ theo cơ chế TTL nhằm tránh tình trạng đầy bộ nhớ lưu trữ.

Thứ năm, về khả năng mở rộng, hệ thống được thiết kế theo kiến trúc phân tách giữa frontend, backend và các module suy luận (inference), cho phép dễ dàng nâng cấp hoặc mở rộng trong tương lai. Hệ thống có thể được phát triển theo hướng

microservice, tách riêng các dịch vụ YOLO và CNN, đồng thời sử dụng các file cấu hình (config.py) để quản lý tham số như đường dẫn mô hình, ngưỡng dự đoán và kích thước batch.


Cuối cùng, về khả năng bảo trì, mã nguồn của hệ thống được tổ chức theo cấu trúc module rõ ràng, bao gồm các thành phần như file khởi tạo ứng dụng, module xử lý suy luận và module xử lý ảnh. Ngoài ra, hệ thống có thể được kiểm thử thông qua các kịch bản test tự động cho API và mô hình, giúp đảm bảo tính ổn định và dễ dàng nâng cấp trong quá trình phát triển.

Như vậy, các yêu cầu phi chức năng đóng vai trò quan trọng trong việc đảm bảo hệ thống không chỉ hoạt động đúng mà còn đạt hiệu quả cao, ổn định và có khả năng mở rộng trong môi trường thực tế.

3.2 KIẾN TRÚC TỔNG THỂ HỆ THỐNG

3.2.1. Sơ đồ Use Case

Sơ đồ Use Case mô tả các chức năng chính của hệ thống phân tích sâu răng trên ảnh X-quang nha khoa và cách người dùng tương tác với hệ thống. Tác nhân chính của hệ thống là người dùng, thực hiện các thao tác từ việc tải ảnh đến nhận kết quả phân tích.



Hình 3.1. Sơ đồ Use Case của hệ thống

Khi sử dụng hệ thống, người dùng có thể tải lên ảnh X-quang nha khoa từ máy tính cá nhân. Sau khi ảnh được gửi lên, hệ thống tiến hành kiểm tra tính hợp lệ của dữ liệu đầu vào bao gồm định dạng và kích thước file nhằm đảm bảo phù hợp cho quá trình xử lý.

Sau bước kiểm tra, hệ thống thực hiện chức năng phân tích ảnh thông qua API. Quá trình phân tích bao gồm nhiều bước như tiền xử lý ảnh, phát hiện vùng nghi ngờ sâu răng bằng mô hình YOLOv8 và phân loại mức độ tổn thương bằng mô

hình CNN. Các bước này được thực hiện tự động trong backend mà không cần sự can thiệp của người dùng.

Sau khi hoàn tất xử lý, kết quả được trả về và hiển thị trên giao diện dưới dạng trực quan. Người dùng có thể quan sát các vùng được phát hiện thông qua bounding box, cùng với nhãn phân loại và độ tin cậy tương ứng. Ngoài ra, hệ thống còn cung cấp bảng thống kê tổng hợp về số lượng và mức độ sâu răng.

Bên cạnh đó, hệ thống cho phép người dùng tải xuống ảnh kết quả hoặc báo cáo để phục vụ cho việc lưu trữ và tham khảo. Hệ thống cũng hỗ trợ các chức năng kiểm tra trạng thái hoạt động và kiểm tra mô hình nhằm đảm bảo hệ thống luôn sẵn sàng và hoạt động ổn định.

Như vậy, sơ đồ Use Case giúp mô tả tổng quan các chức năng của hệ thống và mối quan hệ giữa người dùng với các chức năng đó, làm cơ sở cho việc thiết kế kiến trúc và triển khai hệ thống.

3.2.2. Sơ đồ kiến trúc (Frontend – Backend – ML Models)

Hệ thống phân tích sâu răng trên ảnh X-quang nha khoa được thiết kế theo kiến trúc phân tầng gồm ba thành phần chính: frontend, backend và các mô hình học sâu. Kiến trúc này giúp tách biệt rõ ràng giữa giao diện người dùng, xử lý logic và suy luận mô hình, từ đó nâng cao tính linh hoạt và khả năng mở rộng của hệ thống.

Frontend đóng vai trò là giao diện tương tác với người dùng, cho phép thực hiện các thao tác như tải lên ảnh X-quang, theo dõi quá trình xử lý và hiển thị kết quả dưới dạng trực quan. Giao diện được xây dựng bằng HTML, CSS và JavaScript, bao gồm các thành phần như form upload ảnh, vùng hiển thị kết quả và bảng thống kê. Sau khi người dùng tải ảnh lên, frontend sẽ gửi yêu cầu đến backend thông qua API `/api/analyze` và nhận dữ liệu trả về để hiển thị kết quả.

Backend được xây dựng bằng framework Flask, đóng vai trò trung tâm trong việc xử lý dữ liệu và điều phối luồng hoạt động của hệ thống. Backend cung cấp các endpoint chính như `/api/analyze` để phân tích ảnh, `/api/health` để kiểm tra trạng thái hệ thống và `/api/test-models` để kiểm tra tình trạng hoạt động của các mô hình. Ngoài ra, backend còn thực hiện các bước tiền xử lý ảnh thông qua module xử lý ảnh, bao gồm chuẩn hóa kích thước, chuyển đổi định dạng và cải thiện chất lượng ảnh.

Quá trình suy luận được thực hiện thông qua module inference, trong đó mô hình YOLOv8 được sử dụng để phát hiện các vùng nghi ngờ sâu răng trên ảnh X-quang, trả về các bounding box tương ứng. Tiếp theo, các vùng ảnh (ROI) được trích xuất và đưa vào mô hình CNN để phân loại mức độ sâu răng. Kết quả từ hai mô hình được tổng hợp nhằm tạo ra đầu ra hoàn chỉnh cho hệ thống.


Luồng xử lý dữ liệu trong hệ thống được thực hiện tuần tự, bắt đầu từ việc người dùng tải ảnh lên giao diện frontend, sau đó ảnh được gửi đến backend thông qua API. Backend tiếp nhận, lưu tạm và xử lý ảnh, sau đó gọi mô hình YOLOv8 để phát hiện vùng tổn thương. Các vùng này tiếp tục được đưa vào mô hình CNN để phân loại mức độ sâu răng. Kết quả cuối cùng bao gồm tọa độ bounding box, độ tin cậy của mô hình, nhãn phân loại và các thông kê tổng hợp, được trả về dưới dạng JSON và hiển thị trực quan trên giao diện người dùng.

Để đảm bảo tính linh hoạt trong quá trình phát triển, hệ thống sử dụng các tham số cấu hình như đường dẫn mô hình, ngưỡng confidence và kích thước ảnh đầu vào, được quản lý thông qua file cấu hình. Đồng thời, các file tạm trong quá trình xử lý được quản lý và xóa định kỳ nhằm tối ưu tài nguyên lưu trữ.


Như vậy, kiến trúc hệ thống được thiết kế theo hướng phân tách rõ ràng các thành phần và luồng xử lý, giúp hệ thống hoạt động hiệu quả, dễ bảo trì và có khả năng mở rộng trong tương lai.

3.2.3. Luồng xử lý dữ liệu

Luồng xử lý dữ liệu trong hệ thống được thiết kế nhằm đảm bảo việc phân tích ảnh X-quang nha khoa diễn ra một cách tự động, chính xác và hiệu quả. Quá trình này bắt đầu từ khi người dùng cung cấp dữ liệu đầu vào cho đến khi kết quả được trả về và hiển thị trên giao diện.



Hình 3.2: Sơ đồ DFD cấp 0



Hình 3.3: Sơ đồ DFD cấp 1

Trước hết, người dùng tải lên ảnh X-quang nha khoa thông qua giao diện frontend. Ảnh đầu vào có thể ở các định dạng phổ biến như JPEG hoặc PNG. Sau khi người dùng thực hiện thao tác upload, frontend gửi yêu cầu POST đến endpoint `/api/analyze` dưới dạng `multipart/form-data` để chuyển ảnh đến backend xử lý.

Tại backend, hệ thống tiếp nhận yêu cầu và thực hiện kiểm tra dữ liệu đầu vào. Các bước xác thực bao gồm kiểm tra sự tồn tại của file, định dạng ảnh hợp lệ và kích thước file không vượt quá giới hạn cho phép. Sau khi xác thực thành công, ảnh được lưu tạm thời trong hệ thống file với định danh duy nhất nhằm phục vụ cho quá trình xử lý tiếp theo.

Tiếp theo, ảnh được đưa vào bước tiền xử lý. Hệ thống sử dụng các thư viện xử lý ảnh để đọc dữ liệu, chuyển đổi định dạng và chuẩn hóa ảnh. Các thao tác có thể bao gồm chuyển đổi sang ảnh xám, thay đổi kích thước về kích thước đầu vào của mô hình YOLOv8 (ví dụ 640×640), và chuẩn hóa giá trị pixel. Kết quả của

bước này là dữ liệu ảnh được chuyển đổi về dạng phù hợp cho quá trình suy luận của mô hình học sâu.

Ở bước phát hiện, mô hình YOLOv8 được sử dụng để xác định các vùng nghi ngờ sâu răng trên ảnh X-quang. Mô hình trả về danh sách các bounding box kèm theo độ tin cậy của từng dự đoán. Các kết quả này được lọc theo một ngưỡng xác định nhằm loại bỏ các dự đoán không đáng tin cậy. Trong trường hợp không phát hiện được vùng tổn thương, hệ thống vẫn tiếp tục xử lý để đảm bảo tính ổn định của pipeline.

Sau khi xác định các vùng quan tâm, hệ thống tiến hành trích xuất từng vùng ảnh tương ứng với các bounding box. Các vùng này được chuẩn hóa về kích thước đầu vào của mô hình CNN (ví dụ 224×224) và thực hiện chuẩn hóa dữ liệu trước khi đưa vào mô hình. Mô hình CNN sau đó thực hiện phân loại mức độ sâu răng cho từng vùng, đưa ra nhãn tương ứng cùng với độ tin cậy của dự đoán.

Kết quả từ hai mô hình được tổng hợp để tạo thành đầu ra cuối cùng của hệ thống. Thông tin bao gồm tọa độ bounding box, độ tin cậy từ YOLOv8, nhãn phân loại từ CNN và độ tin cậy tương ứng. Đồng thời, hệ thống thực hiện thống kê tổng hợp như tổng số vùng sâu răng phát hiện và phân bố theo từng mức độ. Ảnh kết quả cũng được tạo ra bằng cách vẽ các bounding box và nhãn lên ảnh gốc.

Sau khi hoàn tất xử lý, backend trả kết quả về frontend dưới dạng JSON, bao gồm dữ liệu phân tích, thông tin thống kê, đường dẫn hoặc dữ liệu ảnh kết quả và thời gian xử lý. Frontend tiếp nhận dữ liệu và hiển thị kết quả một cách trực quan cho người dùng.

Cuối cùng, hệ thống thực hiện các bước dọn dẹp và ghi log. Các file tạm có thể được xóa theo cơ chế định kỳ nhằm tối ưu tài nguyên lưu trữ. Đồng thời, thông tin về quá trình xử lý như thời gian thực hiện, số lượng vùng phát hiện và trạng thái hệ thống được ghi lại để phục vụ việc giám sát và cải thiện hệ thống. Trong trường hợp xảy ra lỗi, hệ thống sẽ trả về thông báo phù hợp kèm theo mã trạng thái HTTP để người dùng có thể nhận biết và xử lý.

Ngoài ra, hệ thống có thể được mở rộng trong tương lai với các chức năng như xử lý nhiều ảnh đồng thời, lưu trữ lịch sử phân tích hoặc tối ưu hóa hiệu năng thông qua cơ chế cache. Những hướng phát triển này góp phần nâng cao khả năng ứng dụng thực tế của hệ thống.

3.3 THIẾT KẾ PIPELINE XỬ LÝ DỮ LIỆU

3.3.1. Phát hiện vùng sâu bằng YOLOv8

Trong hệ thống phân tích sâu răng trên ảnh X-quang nha khoa, bước phát hiện vùng nghi ngờ tổn thương đóng vai trò quan trọng trong việc xác định vị trí các khu vực cần phân tích chi tiết. Để thực hiện nhiệm vụ này, đề tài sử dụng mô hình

YOLOv8 – một trong những mô hình phát hiện đối tượng hiện đại với tốc độ và độ chính xác cao.

Mục tiêu của bước này là tự động xác định các vùng có khả năng xuất hiện sâu răng trên ảnh X-quang và trả về các bounding box tương ứng kèm theo độ tin cậy của từng dự đoán. Kết quả của bước phát hiện sẽ là đầu vào cho giai đoạn phân loại mức độ tổn thương bằng mô hình CNN ở bước tiếp theo.

Dữ liệu đầu vào cho mô hình YOLOv8 là ảnh X-quang nha khoa sau khi đã được tiền xử lý. Ảnh có thể ở dạng RGB hoặc grayscale, được chuẩn hóa về kích thước phù hợp với mô hình (ví dụ 640×640) nhằm đảm bảo hiệu quả suy luận. Ngoài ra, các bước xử lý như giảm nhiễu hoặc cân bằng độ sáng có thể được áp dụng để cải thiện chất lượng ảnh đầu vào.

Mô hình YOLOv8 được sử dụng trong hệ thống là mô hình đã được huấn luyện trước trên tập dữ liệu nha khoa và được lưu dưới dạng file trọng số (ví dụ: best.pt). Mô hình được tải một lần khi backend khởi động nhằm tối ưu hiệu năng và tránh việc tải lại trong mỗi yêu cầu. Các tham số quan trọng của mô hình bao gồm ngưỡng confidence (ví dụ 0.25), ngưỡng IoU (ví dụ 0.45) và danh sách các lớp đối tượng (trong trường hợp này có thể chỉ gồm một lớp “sâu răng”).

Trong quá trình xử lý, ảnh đầu vào được đưa vào mô hình YOLOv8 để thực hiện suy luận. Mô hình trả về danh sách các bounding box, mỗi bounding box bao gồm tọa độ (x1, y1, x2, y2), độ tin cậy và nhãn lớp. Kỹ thuật Non-Maximum Suppression (NMS) được áp dụng để loại bỏ các bounding box trùng lặp, giữ lại các dự đoán có độ tin cậy cao nhất. Sau đó, các kết quả được lọc theo ngưỡng confidence nhằm loại bỏ các dự đoán không đáng tin cậy.

Các bounding box sau khi xử lý sẽ được chuyển đổi về kích thước tương ứng với ảnh gốc (nếu ảnh đã được resize trước đó), đảm bảo tính chính xác trong việc hiển thị kết quả. Trong trường hợp không phát hiện được vùng sâu răng, hệ thống sẽ trả về danh sách rỗng và thông báo phù hợp.

Kết quả đầu ra của bước này là danh sách các vùng nghi ngờ sâu răng, mỗi vùng bao gồm thông tin về vị trí, độ tin cậy và nhãn đối tượng. Đồng thời, hệ thống cũng ghi nhận thời gian suy luận để phục vụ việc đánh giá hiệu năng. Các thông tin này không chỉ phục vụ hiển thị mà còn được sử dụng làm đầu vào cho bước phân loại mức độ sâu răng bằng mô hình CNN.

Ngoài ra, hệ thống có thể ghi log các thông tin như số lượng bounding box phát hiện, thời gian xử lý và các tham số sử dụng, đồng thời lưu ảnh có đánh dấu bounding box để phục vụ việc kiểm tra và tối ưu hệ thống.

Như vậy, bước phát hiện bằng YOLOv8 đóng vai trò nền tảng trong pipeline của hệ thống, giúp xác định chính xác vị trí các vùng tổn thương, từ đó tạo tiền đề cho việc phân tích chi tiết ở các bước tiếp theo.

3.3.2. Phân loại mức độ sâu bằng CNN

Sau khi xác định được các vùng nghi ngờ sâu răng thông qua mô hình YOLOv8, bước tiếp theo trong pipeline là phân loại mức độ tổn thương của từng vùng ảnh. Nhiệm vụ này được thực hiện bằng mô hình mạng nơ-ron tích chập (CNN), nhằm đánh giá mức độ nghiêm trọng của sâu răng dựa trên đặc trưng hình ảnh.

Mục tiêu của bước phân loại là xác định mức độ sâu răng tương ứng với từng vùng ảnh (ROI) đã được phát hiện, với các nhãn như sâu nhẹ, sâu vừa và sâu nặng. Việc phân loại này giúp cung cấp thông tin chi tiết hơn cho quá trình chẩn đoán, hỗ trợ bác sĩ trong việc đánh giá tình trạng răng miệng.

Dữ liệu đầu vào của mô hình CNN là các vùng ảnh (ROI) được trích xuất từ ảnh X-quang gốc dựa trên tọa độ bounding box do YOLOv8 cung cấp. Mỗi ROI được chuẩn hóa về kích thước phù hợp với mô hình (ví dụ 224×224 hoặc 128×128), đồng thời thực hiện chuẩn hóa giá trị pixel (scale về khoảng $[0,1]$ hoặc theo mean/std nếu sử dụng mô hình huấn luyện sẵn) nhằm đảm bảo tính nhất quán trong quá trình suy luận.

Mô hình CNN được sử dụng trong hệ thống là mô hình đã được huấn luyện trước và lưu dưới dạng file (ví dụ: `cnn_caries_model.h5`). Kiến trúc mô hình bao gồm các lớp tích chập (Convolutional layers), chuẩn hóa (Batch Normalization), hàm kích hoạt ReLU, lớp pooling và các lớp fully connected, với lớp đầu ra sử dụng hàm softmax để phân loại thành nhiều lớp tương ứng với các mức độ sâu răng.

Trong quá trình xử lý, với mỗi ROI được trích xuất, hệ thống thực hiện dự đoán thông qua mô hình CNN. Kết quả đầu ra là một vector xác suất tương ứng với từng lớp, từ đó xác định nhãn dự đoán bằng cách chọn lớp có xác suất cao nhất. Đồng thời, độ tin cậy của dự đoán được xác định bằng giá trị xác suất lớn nhất này. Trong trường hợp độ tin cậy thấp hơn một ngưỡng xác định, hệ thống có thể đánh dấu kết quả là không chắc chắn để tránh đưa ra kết luận sai lệch.

Kết quả phân loại được gán với từng bounding box tương ứng, tạo thành tập hợp các vùng sâu răng đã được phân tích đầy đủ cả về vị trí và mức độ. Ngoài ra, hệ thống còn thực hiện thống kê số lượng vùng theo từng mức độ (nhẹ, vừa, nặng) và có thể tính toán độ tin cậy trung bình cho mỗi nhóm, phục vụ cho việc đánh giá tổng thể.

Để đảm bảo chất lượng của mô hình, các chỉ số đánh giá như Accuracy, Precision, Recall và F1-score được sử dụng trên tập dữ liệu kiểm thử. Confusion

Matrix cũng được áp dụng để phân tích chi tiết các trường hợp dự đoán đúng và sai, từ đó cải thiện hiệu năng của mô hình.

Như vậy, bước phân loại bằng CNN đóng vai trò quan trọng trong việc bổ sung thông tin định tính cho các vùng đã được phát hiện, góp phần hoàn thiện hệ thống phân tích sâu rộng theo hướng chính xác và có ý nghĩa thực tiễn cao.

3.3.3. Tổng hợp kết quả

Sau khi hoàn thành hai bước chính trong pipeline bao gồm phát hiện vùng nghi ngờ sâu răng bằng mô hình YOLOv8 và phân loại mức độ tổn thương bằng mô hình CNN, hệ thống tiến hành tổng hợp kết quả nhằm tạo ra đầu ra hoàn chỉnh phục vụ cho việc hiển thị và đánh giá.

Mục tiêu của bước này là kết hợp thông tin vị trí từ YOLOv8 và thông tin mức độ từ CNN thành một cấu trúc dữ liệu thống nhất, đồng thời cung cấp các thống kê tổng quan về tình trạng sâu răng trên ảnh X-quang. Kết quả tổng hợp không chỉ phục vụ cho việc hiển thị trực quan mà còn đóng vai trò quan trọng trong việc phân tích và đánh giá hệ thống.

Đầu vào của quá trình tổng hợp bao gồm kết quả phát hiện từ mô hình YOLOv8 với các bounding box và độ tin cậy tương ứng, cùng với kết quả phân loại từ mô hình CNN bao gồm nhãn mức độ và độ tin cậy của từng vùng ảnh.

Trong quá trình xử lý, hệ thống thực hiện ánh xạ giữa các bounding box và kết quả phân loại tương ứng thông qua định danh của từng vùng. Với mỗi vùng được phát hiện, hệ thống tạo ra một bản ghi bao gồm thông tin vị trí, độ tin cậy từ YOLOv8, nhãn mức độ từ CNN và độ tin cậy phân loại. Trong trường hợp một vùng không có kết quả phân loại, hệ thống sẽ gán nhãn “không xác định” để đảm bảo tính ổn định của hệ thống.

Độ tin cậy tổng thể của từng vùng có thể được xác định thông qua việc kết hợp độ tin cậy từ hai mô hình, ví dụ bằng cách nhân hoặc lấy trung bình giữa giá trị confidence của YOLOv8 và CNN. Ngoài ra, các ngưỡng xác định cũng có thể được áp dụng để quyết định một vùng có được xem là sâu răng hợp lệ hay không.

Bên cạnh đó, hệ thống thực hiện thống kê tổng hợp trên toàn bộ ảnh, bao gồm tổng số vùng sâu răng được phát hiện, số lượng theo từng mức độ (nhẹ, trung bình, nặng), tỷ lệ phần trăm tương ứng và giá trị trung bình của độ tin cậy. Thời gian xử lý của toàn bộ pipeline cũng được ghi nhận để phục vụ việc đánh giá hiệu năng hệ thống.

Sau khi hoàn tất, hệ thống tạo ảnh kết quả bằng cách vẽ các bounding box và nhãn phân loại lên ảnh gốc, giúp người dùng dễ dàng quan sát các vùng tổn thương. Đồng thời, kết quả được đóng gói và trả về frontend để hiển thị dưới dạng trực quan.

Ngoài ra, hệ thống thực hiện ghi log các thông tin quan trọng như số lượng vùng phát hiện, thời gian xử lý và trạng thái hoạt động. Các file tạm được quản lý và xóa định kỳ nhằm tối ưu tài nguyên lưu trữ. Trong trường hợp không phát hiện được vùng sâu răng, hệ thống vẫn trả về kết quả hợp lệ với thông tin phù hợp.

Như vậy, bước tổng hợp kết quả đóng vai trò kết nối các thành phần trong pipeline, giúp chuyển đổi dữ liệu từ các mô hình học sâu thành thông tin có ý nghĩa và dễ sử dụng, góp phần hoàn thiện hệ thống phân tích sâu răng một cách toàn diện.

3.4 THIẾT KẾ BACKEND

3.4.1. Cấu trúc API chính

Trong hệ thống phân tích sâu răng trên ảnh X-quang nha khoa, backend được xây dựng theo kiến trúc REST API sử dụng framework Flask. Việc thiết kế API theo hướng tách biệt rõ ràng các endpoint giúp hệ thống dễ dàng mở rộng, bảo trì và tích hợp với các ứng dụng khác.

Cấu trúc backend được tổ chức theo dạng module nhằm đảm bảo tính rõ ràng và dễ quản lý. Trong đó, file khởi tạo ứng dụng chịu trách nhiệm cấu hình và định nghĩa các route chính của hệ thống. Các tham số cấu hình như đường dẫn mô hình, ngưỡng dự đoán và thư mục lưu trữ được quản lý thông qua file cấu hình riêng. Ngoài ra, các module xử lý suy luận và xử lý ảnh được tách biệt nhằm phục vụ cho việc phát triển và mở rộng hệ thống.

Hệ thống cung cấp ba endpoint chính phục vụ cho các chức năng cốt lõi. Endpoint `/api/analyze` sử dụng phương thức POST để tiếp nhận ảnh X-quang từ người dùng và thực hiện toàn bộ pipeline xử lý, bao gồm kiểm tra dữ liệu đầu vào, lưu trữ tạm thời, tiền xử lý ảnh, phát hiện vùng nghi ngờ bằng mô hình YOLOv8, phân loại mức độ bằng mô hình CNN và tổng hợp kết quả. Kết quả cuối cùng được trả về dưới dạng JSON, bao gồm thông tin phát hiện, phân loại, thống kê và dữ liệu ảnh kết quả.

Endpoint `/api/health` sử dụng phương thức GET nhằm kiểm tra trạng thái hoạt động của hệ thống. Endpoint này trả về thông tin cho biết hệ thống có đang hoạt động bình thường hay không, đồng thời cung cấp trạng thái của các mô hình đã được tải, phục vụ cho mục đích giám sát và kiểm tra.

Endpoint `/api/test-models` cũng sử dụng phương thức GET để kiểm tra tình trạng hoạt động của các mô hình học sâu. Thông qua endpoint này, hệ thống có thể thực hiện một phép suy luận thử nghiệm nhằm xác nhận rằng các mô hình YOLOv8 và CNN đã được tải thành công và hoạt động ổn định.

Các route của hệ thống được định nghĩa trực tiếp trong file khởi tạo ứng dụng, tương ứng với từng endpoint và phương thức HTTP cụ thể. Việc tổ chức các

route theo chuẩn REST giúp đảm bảo tính nhất quán và dễ sử dụng trong quá trình phát triển.

Để đảm bảo tính nhất quán trong giao tiếp giữa frontend và backend, hệ thống sử dụng cấu trúc phản hồi chuẩn, bao gồm các thành phần như trạng thái xử lý, thông điệp, dữ liệu trả về và thông tin bổ sung như thời gian xử lý hoặc định danh yêu cầu. Điều này giúp frontend dễ dàng xử lý và hiển thị kết quả một cách chính xác.

Hệ thống cũng được thiết kế với cơ chế xử lý lỗi rõ ràng. Trong trường hợp dữ liệu đầu vào không hợp lệ hoặc thiếu thông tin, hệ thống trả về mã lỗi tương ứng với thông báo cụ thể. Đối với các lỗi phát sinh trong quá trình xử lý như lỗi mô hình hoặc lỗi hệ thống, backend sẽ trả về mã lỗi máy chủ cùng với thông tin mô tả để hỗ trợ việc debug và xử lý.

Các tham số cấu hình của hệ thống được quản lý thông qua file cấu hình riêng, bao gồm các thông tin như thư mục lưu trữ ảnh, định dạng file cho phép, kích thước tối đa của file upload, đường dẫn đến các mô hình học sâu và các ngưỡng sử dụng trong quá trình suy luận. Việc sử dụng file cấu hình giúp tăng tính linh hoạt và thuận tiện trong việc điều chỉnh hệ thống.

Ngoài ra, để tối ưu hiệu năng, các mô hình học sâu được tải một lần duy nhất khi hệ thống khởi động, thay vì tải lại trong mỗi yêu cầu. Hệ thống cũng hỗ trợ cấu hình CORS để cho phép frontend truy cập API một cách an toàn. Trong trường hợp triển khai thực tế, hệ thống có thể được nâng cấp với các cơ chế xử lý song song nhằm tăng khả năng phục vụ nhiều yêu cầu đồng thời.

Như vậy, cấu trúc API của hệ thống được thiết kế theo hướng rõ ràng, linh hoạt và phù hợp với các tiêu chuẩn hiện đại, góp phần đảm bảo hiệu quả hoạt động và khả năng mở rộng trong tương lai.

3.4.2. Các endpoint API

Trong hệ thống phân tích sâu răng trên ảnh X-quang nha khoa, các endpoint API được thiết kế nhằm phục vụ cho việc giao tiếp giữa frontend và backend, đồng thời đảm bảo tính linh hoạt và dễ mở rộng. Các endpoint chính của hệ thống bao gồm `/api/health`, `/api/test-models` và `/api/analyze`, mỗi endpoint đảm nhiệm một chức năng cụ thể.

Endpoint `/api/health` sử dụng phương thức GET với mục đích kiểm tra trạng thái hoạt động của hệ thống backend. Khi được gọi, endpoint này trả về thông tin cho biết hệ thống có đang hoạt động bình thường hay không, đồng thời cung cấp trạng thái của các mô hình học sâu đã được tải. Endpoint này thường được sử dụng trong quá trình giám sát hệ thống hoặc kiểm tra nhanh tình trạng service. Trong

trường hợp xảy ra lỗi, hệ thống sẽ trả về mã trạng thái phù hợp cùng với thông tin mô tả nguyên nhân, chẳng hạn như mô hình chưa được khởi tạo.

Endpoint `/api/test-models` cũng sử dụng phương thức GET nhằm kiểm tra khả năng hoạt động của các mô hình học sâu. Khi endpoint này được gọi, hệ thống sẽ thực hiện một phép suy luận thử nghiệm trên dữ liệu mẫu để xác nhận rằng mô hình YOLOv8 và CNN đã được tải thành công và hoạt động ổn định. Kết quả trả về bao gồm trạng thái của từng mô hình và thông tin về thời gian xử lý, giúp đánh giá sơ bộ hiệu năng của hệ thống.

Endpoint quan trọng nhất là `/api/analyze`, sử dụng phương thức POST để thực hiện toàn bộ pipeline phân tích ảnh X-quang. Dữ liệu đầu vào được gửi dưới dạng `multipart/form-data`, trong đó bao gồm file ảnh và có thể kèm theo một số tham số tùy chọn như ngưỡng confidence hoặc chế độ xử lý. Sau khi nhận được yêu cầu, backend tiến hành kiểm tra tính hợp lệ của dữ liệu, lưu trữ tạm thời ảnh và thực hiện các bước tiền xử lý.

Tiếp theo, hệ thống sử dụng mô hình YOLOv8 để phát hiện các vùng nghi ngờ sâu răng trên ảnh, sau đó trích xuất các vùng ảnh (ROI) và đưa vào mô hình CNN để phân loại mức độ tổn thương. Kết quả từ hai mô hình được tổng hợp, đồng thời ảnh kết quả được tạo ra bằng cách vẽ các bounding box và nhãn phân loại lên ảnh gốc. Cuối cùng, hệ thống trả về kết quả dưới dạng JSON, bao gồm thông tin phát hiện, phân loại, thống kê và dữ liệu ảnh.

Hệ thống cũng được thiết kế với cơ chế xử lý lỗi rõ ràng nhằm đảm bảo tính ổn định trong quá trình vận hành. Các lỗi phía client như thiếu file, định dạng không hợp lệ hoặc kích thước vượt quá giới hạn sẽ được trả về với mã lỗi tương ứng. Trong trường hợp ảnh hợp lệ nhưng không phát hiện được vùng sâu răng, hệ thống vẫn trả về kết quả hợp lệ với thông tin phù hợp. Đối với các lỗi phát sinh trong quá trình xử lý như lỗi mô hình hoặc lỗi hệ thống, backend sẽ trả về mã lỗi máy chủ cùng với thông báo chi tiết.

Ngoài các endpoint chính, hệ thống có thể được mở rộng trong tương lai với các endpoint bổ sung như lưu trữ lịch sử phân tích hoặc huấn luyện lại mô hình. Đồng thời, các cơ chế bảo mật như xác thực bằng token hoặc API key có thể được tích hợp khi triển khai trong môi trường thực tế. Việc xây dựng tài liệu API theo chuẩn như OpenAPI hoặc Swagger cũng là một hướng phát triển nhằm nâng cao khả năng sử dụng và tích hợp của hệ thống.

Như vậy, các endpoint API được thiết kế rõ ràng và nhất quán, đảm bảo đáp ứng đầy đủ các chức năng của hệ thống, đồng thời tạo điều kiện thuận lợi cho việc mở rộng và triển khai trong thực tế.

3.5 THIẾT KẾ FRONTEND

3.5.1. Giao diện chính

Giao diện chính của hệ thống được thiết kế dưới dạng một trang web đơn giản, trực quan và dễ sử dụng, tập trung vào hai chức năng cốt lõi là tải ảnh X-quang và hiển thị kết quả phân tích sâu răng. Việc xây dựng giao diện theo hướng tối giản giúp người dùng dễ dàng thao tác, đồng thời đảm bảo hiệu năng và khả năng tương thích trên nhiều thiết bị.

Frontend của hệ thống được phát triển bằng các công nghệ web cơ bản bao gồm HTML5, CSS3 và JavaScript thuần. Cấu trúc giao diện được tổ chức thành các thành phần chính như phần tiêu đề, khu vực tải ảnh, khu vực hiển thị kết quả và phần chân trang. File HTML đảm nhiệm việc xây dựng cấu trúc nội dung, CSS chịu trách nhiệm thiết kế giao diện và bố cục hiển thị, trong khi JavaScript xử lý các tương tác và giao tiếp với backend thông qua API.

Phần tiêu đề của trang web hiển thị tên hệ thống, giúp người dùng nhận biết rõ chức năng của ứng dụng. Khu vực tải ảnh cho phép người dùng lựa chọn file từ máy tính với các định dạng phổ biến như JPEG hoặc PNG. Sau khi chọn ảnh, hệ thống hiển thị bản xem trước để người dùng kiểm tra trước khi thực hiện phân tích.

Khi người dùng gửi yêu cầu phân tích, frontend sẽ gọi API `/api/analyze` thông qua cơ chế bất đồng bộ. Trong quá trình xử lý, giao diện hiển thị trạng thái đang tải nhằm thông báo cho người dùng. Sau khi nhận được kết quả từ backend, hệ thống hiển thị ảnh kết quả với các bounding box được vẽ chồng lên ảnh gốc, đồng thời hiển thị nhãn phân loại mức độ sâu răng tương ứng với từng vùng.

Bên cạnh đó, hệ thống cung cấp bảng thống kê tổng hợp bao gồm số lượng vùng sâu răng phát hiện và phân bố theo từng mức độ như nhẹ, trung bình và nặng. Người dùng cũng có thể xem danh sách chi tiết các vùng được phát hiện với các thông tin như tọa độ, độ tin cậy và mức độ tổn thương.

Về thiết kế giao diện, hệ thống sử dụng bố cục linh hoạt dựa trên các kỹ thuật như Flexbox hoặc Grid, giúp giao diện có khả năng hiển thị tốt trên nhiều kích thước màn hình khác nhau. Màu sắc được lựa chọn theo hướng đơn giản và chuyên nghiệp, với nền sáng và các màu nhấn nhằm làm nổi bật thông tin quan trọng. Kiểu chữ được lựa chọn dễ đọc, phù hợp với môi trường ứng dụng trong lĩnh vực y tế.

Ngoài ra, giao diện được tối ưu về trải nghiệm người dùng thông qua việc hiển thị trạng thái xử lý, xử lý lỗi rõ ràng và hạn chế các thao tác không hợp lệ như gửi yêu cầu khi chưa chọn ảnh. Các kỹ thuật như sử dụng Fetch API để gọi backend và Canvas API để vẽ bounding box được áp dụng nhằm đảm bảo hiệu quả và tính tương tác cao.

Như vậy, giao diện chính của hệ thống không chỉ đáp ứng yêu cầu về chức năng mà còn đảm bảo tính trực quan, dễ sử dụng và phù hợp với định hướng ứng dụng thực tế trong lĩnh vực nha khoa.

3.5.2. Luồng tương tác người dùng

Luồng tương tác người dùng của hệ thống được thiết kế theo hướng đơn giản, trực quan và tối ưu trải nghiệm, giúp người dùng dễ dàng thực hiện các thao tác từ việc tải ảnh X-quang đến nhận kết quả phân tích. Toàn bộ quá trình tương tác được xây dựng dựa trên cơ chế xử lý bất đồng bộ bằng JavaScript, cho phép giao diện phản hồi nhanh chóng và mượt mà.

Khi truy cập hệ thống thông qua trình duyệt web, người dùng được cung cấp một giao diện chính bao gồm khu vực tải ảnh và hướng dẫn sử dụng cơ bản. Tại đây, người dùng có thể lựa chọn ảnh X-quang từ máy tính hoặc sử dụng chức năng kéo thả để đưa ảnh vào hệ thống. Ngay sau khi ảnh được chọn, hệ thống tiến hành kiểm tra định dạng và kích thước của file nhằm đảm bảo tính hợp lệ. Đồng thời, ảnh xem trước được hiển thị ngay trên giao diện, giúp người dùng xác nhận nội dung trước khi thực hiện phân tích.

Sau khi lựa chọn ảnh hợp lệ, người dùng có thể gửi yêu cầu phân tích thông qua nút chức năng tương ứng. Khi đó, frontend sử dụng cơ chế bất đồng bộ để gửi dữ liệu ảnh đến endpoint `/api/analyze` dưới dạng `multipart/form-data`. Trong thời gian chờ xử lý, hệ thống hiển thị trạng thái đang tải nhằm thông báo tiến trình cho người dùng, đồng thời tạm thời vô hiệu hóa các thao tác để tránh gửi yêu cầu lặp lại.

Khi nhận được phản hồi từ backend, hệ thống tiến hành xử lý dữ liệu và hiển thị kết quả một cách trực quan. Các bounding box được vẽ chồng lên ảnh gốc để thể hiện vị trí các vùng nghi ngờ sâu răng, với màu sắc khác nhau tương ứng với từng mức độ tổn thương. Bên cạnh đó, hệ thống hiển thị bảng thống kê tổng hợp bao gồm số lượng vùng sâu răng và phân bố theo từng mức độ. Danh sách chi tiết các vùng phát hiện cũng được cung cấp, bao gồm thông tin về tọa độ, độ tin cậy và mức độ phân loại.

Trong trường hợp xảy ra lỗi, hệ thống hiển thị thông báo rõ ràng để người dùng nhận biết và thực hiện lại thao tác nếu cần. Các lỗi có thể bao gồm dữ liệu đầu vào không hợp lệ hoặc sự cố trong quá trình kết nối với backend. Ngoài ra, hệ thống cũng hỗ trợ các thao tác bổ sung như xóa dữ liệu hiện tại để thực hiện phân tích mới hoặc tải xuống ảnh kết quả đã được chú thích.

Để đảm bảo trải nghiệm người dùng tốt, hệ thống được thiết kế với các trạng thái xử lý rõ ràng bao gồm trạng thái chờ, đang xử lý, thành công và lỗi. Giao diện cũng được tối ưu để phản hồi nhanh với các thao tác của người dùng, đồng thời hỗ trợ hiển thị tốt trên nhiều thiết bị khác nhau. Các yếu tố như hiển thị phản hồi tức

thời, phân tách nội dung theo từng giai đoạn và xử lý lỗi thân thiện góp phần nâng cao tính khả dụng của hệ thống.

Như vậy, luồng tương tác người dùng được xây dựng một cách hợp lý, đảm bảo sự liên kết chặt chẽ giữa frontend và backend, đồng thời mang lại trải nghiệm sử dụng thuận tiện và hiệu quả trong quá trình phân tích ảnh X-quang nha khoa.

3.6 THIẾT KẾ LƯU TRỮ DỮ LIỆU

3.6.1. Lưu ảnh upload

Trong hệ thống phân tích sâu răng trên ảnh X-quang nha khoa, việc lưu trữ ảnh đầu vào đóng vai trò quan trọng nhằm phục vụ cho quá trình xử lý của pipeline bao gồm phát hiện và phân loại. Ảnh X-quang do người dùng tải lên được lưu trữ tạm thời trên hệ thống file để đảm bảo có thể truy xuất trong suốt quá trình xử lý, đồng thời tạo điều kiện thuận lợi cho việc quản lý và kiểm soát dữ liệu.

Hệ thống sử dụng cơ chế lưu trữ file cục bộ thay vì cơ sở dữ liệu, phù hợp với yêu cầu xử lý tạm thời và đơn giản hóa kiến trúc. Các ảnh upload được lưu trong thư mục riêng biệt (ví dụ: backend/uploads/input/), thư mục này sẽ được tự động tạo nếu chưa tồn tại. Việc phân tách thư mục giúp dễ dàng quản lý và tránh nhầm lẫn với các loại dữ liệu khác trong hệ thống.

Để đảm bảo tính duy nhất và tránh xung đột tên file, mỗi ảnh upload được gán một định danh duy nhất thông qua cơ chế sinh chuỗi ngẫu nhiên, chẳng hạn sử dụng UUID. Tên file được tạo mới bằng cách kết hợp chuỗi định danh với phần mở rộng gốc của file ảnh, giúp duy trì định dạng và đảm bảo khả năng xử lý về sau.

Quy trình lưu trữ bắt đầu bằng việc kiểm tra tính hợp lệ của file đầu vào. Hệ thống xác nhận sự tồn tại của file, kiểm tra định dạng cho phép (như JPEG hoặc PNG) và giới hạn kích thước nhằm đảm bảo an toàn và hiệu năng. Sau khi vượt qua bước kiểm tra, file được lưu vào thư mục quy định và đường dẫn tương ứng được trả về để phục vụ cho các bước xử lý tiếp theo trong pipeline.

Bên cạnh đó, hệ thống áp dụng các cơ chế đảm bảo an toàn dữ liệu trong quá trình lưu trữ. Việc kiểm tra loại file được thực hiện không chỉ dựa trên phần mở rộng mà còn thông qua nội dung thực tế của file nhằm tránh các trường hợp giả mạo. Ngoài ra, hệ thống giới hạn phạm vi lưu trữ trong các thư mục được xác định trước để ngăn chặn các nguy cơ liên quan đến truy cập trái phép hoặc tấn công dạng path traversal.

Do dữ liệu ảnh chỉ phục vụ cho quá trình xử lý tạm thời, hệ thống không lưu trữ lâu dài mà thực hiện cơ chế dọn dẹp định kỳ hoặc xóa file sau khi hoàn tất xử lý. Điều này giúp tiết kiệm tài nguyên lưu trữ và đảm bảo hệ thống hoạt động ổn định trong thời gian dài.

Như vậy, việc lưu trữ ảnh upload được thiết kế theo hướng đơn giản, an toàn và hiệu quả, đáp ứng tốt yêu cầu của hệ thống trong việc xử lý ảnh X-quang nha khoa mà không cần sử dụng đến các hệ quản trị cơ sở dữ liệu phức tạp.

3.6.2. Lưu ảnh kết quả

Sau khi hoàn tất quá trình phát hiện và phân loại sâu răng, hệ thống tiến hành tạo và lưu trữ ảnh kết quả nhằm phục vụ cho việc hiển thị và tải xuống từ phía người dùng. Ảnh kết quả là ảnh X-quang ban đầu được chú thích bằng các bounding box và nhãn mức độ, giúp trực quan hóa các vùng tổn thương đã được hệ thống phát hiện.

Tương tự như cơ chế lưu trữ ảnh đầu vào, hệ thống sử dụng phương thức lưu trữ file cục bộ để quản lý ảnh kết quả. Các ảnh sau khi xử lý được lưu trong thư mục riêng biệt (ví dụ: backend/uploads/output/), đảm bảo tách biệt với dữ liệu đầu vào và thuận tiện cho việc quản lý. Thư mục này được tự động tạo khi cần thiết nhằm đảm bảo hệ thống hoạt động ổn định.

Để đảm bảo tính nhất quán và tránh trùng lặp, tên file ảnh kết quả được xây dựng dựa trên định danh của ảnh đầu vào kết hợp với hậu tố bổ sung, ví dụ thêm chuỗi “_annotated” vào cuối tên file. Cách đặt tên này giúp dễ dàng liên kết giữa ảnh đầu vào và ảnh kết quả tương ứng.

Quy trình lưu trữ bắt đầu sau khi hệ thống thu được kết quả từ hai mô hình YOLOv8 và CNN. Ảnh gốc được nạp lại từ thư mục lưu trữ đầu vào, sau đó các bounding box và nhãn phân loại được vẽ lên ảnh thông qua các thư viện xử lý ảnh như OpenCV hoặc PIL. Mỗi vùng phát hiện được biểu diễn bằng một khung chữ nhật với màu sắc khác nhau tương ứng với mức độ sâu răng, đồng thời hiển thị thông tin nhãn và độ tin cậy ngay trên ảnh.

Sau khi hoàn tất quá trình chú thích, ảnh được lưu vào thư mục đầu ra với định dạng tương ứng với ảnh gốc. Đường dẫn tới ảnh kết quả được trả về cho frontend dưới dạng URL tương đối hoặc dữ liệu mã hóa, cho phép hiển thị trực tiếp trên giao diện hoặc tải xuống khi cần thiết.

Để đảm bảo an toàn và hiệu quả, hệ thống không ghi đè các file đã tồn tại mà sử dụng định danh duy nhất cho mỗi ảnh. Việc lưu trữ chỉ mang tính tạm thời, do đó các file kết quả sẽ được xóa sau một khoảng thời gian nhất định hoặc sau khi hoàn tất quá trình sử dụng, nhằm tránh chiếm dụng tài nguyên lưu trữ.

Ngoài ra, hệ thống đảm bảo rằng quá trình chú thích không làm thay đổi kích thước hoặc chất lượng của ảnh gốc, chỉ bổ sung các thông tin trực quan cần thiết. Việc truy cập ảnh kết quả được kiểm soát thông qua backend, hạn chế truy cập trực tiếp vào hệ thống file nhằm tăng cường bảo mật.

Như vậy, cơ chế lưu trữ ảnh kết quả được thiết kế hợp lý, đảm bảo đáp ứng yêu cầu hiển thị trực quan, hỗ trợ người dùng trong việc theo dõi và tải kết quả, đồng thời duy trì hiệu năng và tính an toàn của hệ thống

3.6.3. Không sử dụng database

Trong hệ thống phân tích sâu răng trên ảnh X-quang nha khoa, việc không sử dụng cơ sở dữ liệu là một lựa chọn thiết kế có chủ đích, phù hợp với mục tiêu và phạm vi của đề tài. Hệ thống được xây dựng nhằm phục vụ mục đích nghiên cứu và triển khai thử nghiệm, do đó ưu tiên tính đơn giản, linh hoạt và dễ triển khai hơn là xây dựng một hệ thống lưu trữ dữ liệu phức tạp.

Một trong những lý do chính của việc không sử dụng cơ sở dữ liệu là do đặc thù của hệ thống chỉ xử lý dữ liệu ảnh mang tính tạm thời. Các ảnh đầu vào và kết quả chỉ tồn tại trong thời gian ngắn để phục vụ cho quá trình suy luận của mô hình, sau đó không cần lưu trữ lâu dài. Hệ thống không yêu cầu các chức năng như truy vấn dữ liệu, tìm kiếm lịch sử hay quản lý người dùng, do đó việc tích hợp cơ sở dữ liệu là không thực sự cần thiết trong giai đoạn này.

Thay vào đó, hệ thống sử dụng cơ chế lưu trữ trên hệ thống file để quản lý dữ liệu. Các ảnh đầu vào và đầu ra được lưu trong các thư mục riêng biệt với tên file được định danh duy nhất, giúp tránh trùng lặp và dễ dàng quản lý. Đồng thời, cơ chế xóa dữ liệu theo thời gian (Time To Live) được áp dụng nhằm đảm bảo các file tạm không chiếm dụng tài nguyên lưu trữ trong thời gian dài. Ngoài ra, các thông tin liên quan đến quá trình xử lý như thời gian thực hiện, số lượng vùng phát hiện có thể được ghi lại dưới dạng log để phục vụ việc theo dõi và kiểm tra hệ thống.

Việc không sử dụng cơ sở dữ liệu mang lại một số ưu điểm đáng kể. Trước hết, hệ thống trở nên đơn giản hơn, không cần cấu hình hay quản lý các thành phần bổ sung như hệ quản trị cơ sở dữ liệu hoặc các công cụ ORM. Điều này giúp giảm độ phức tạp trong quá trình phát triển và triển khai. Bên cạnh đó, việc sử dụng lưu trữ file giúp tăng tốc độ xử lý trong các tác vụ nhỏ và giúp hệ thống dễ dàng di chuyển hoặc triển khai trên nhiều môi trường khác nhau.

Tuy nhiên, lựa chọn này cũng tồn tại một số hạn chế nhất định. Do không có cơ chế lưu trữ lâu dài, dữ liệu có thể bị mất khi hệ thống khởi động lại hoặc khi các file tạm bị xóa. Ngoài ra, hệ thống không hỗ trợ các chức năng truy vấn hoặc phân tích dữ liệu lịch sử, và khả năng mở rộng để phục vụ nhiều người dùng đồng thời còn hạn chế. Các vấn đề liên quan đến bảo mật file cũng cần được kiểm soát chặt chẽ để tránh truy cập trái phép.

Để khắc phục các hạn chế này trong tương lai, hệ thống có thể được mở rộng bằng cách tích hợp cơ sở dữ liệu nhằm lưu trữ lịch sử phân tích hoặc thông tin người dùng. Các giải pháp lưu trữ như cơ sở dữ liệu quan hệ hoặc dịch vụ lưu trữ

đám mây cũng có thể được áp dụng để nâng cao khả năng mở rộng và tính bền vững của hệ thống.

Như vậy, việc không sử dụng cơ sở dữ liệu trong đề tài là một quyết định phù hợp với mục tiêu xây dựng một hệ thống thử nghiệm đơn giản, hiệu quả và dễ triển khai, đồng thời vẫn mở ra khả năng nâng cấp và mở rộng trong các giai đoạn phát triển tiếp theo.

CHƯƠNG 4


XÂY DỰNG VÀ HUẤN LUYỆN MÔ HÌNH

4.1 BỘ DỮ LIỆU

4.1.1. Nguồn dữ liệu

Trong đề tài này, bộ dữ liệu ảnh X-quang nha khoa được sử dụng nhằm phục vụ cho việc huấn luyện và đánh giá các mô hình học sâu trong bài toán phát hiện và phân loại sâu răng. Nguồn dữ liệu chính được thu thập từ nền tảng Roboflow – một công cụ phổ biến trong việc quản lý, xử lý và phân phối các bộ dữ liệu phục vụ cho các bài toán thị giác máy tính.

Roboflow cung cấp nhiều bộ dữ liệu công khai với chất lượng cao, đã được gán nhãn sẵn, giúp giảm đáng kể thời gian và công sức trong quá trình thu thập và chú thích dữ liệu. Bộ dữ liệu được sử dụng trong đề tài bao gồm các ảnh X-quang nha khoa, trong đó tập trung vào việc xác định các vùng nghi ngờ sâu răng. Các ảnh này phản ánh đa dạng các tình trạng răng miệng khác nhau, bao gồm cả răng khỏe mạnh và răng có dấu hiệu tổn thương.



Hình 4.1: Một số mẫu ảnh X-quang nha khoa trong bộ dữ liệu

Về đặc điểm, bộ dữ liệu bao gồm các ảnh ở định dạng phổ biến như JPEG hoặc PNG, đi kèm với các tệp nhãn được lưu theo định dạng YOLO. Mỗi tệp nhãn chứa thông tin về lớp đối tượng và tọa độ bounding box tương ứng với vùng sâu răng trên ảnh. Trong phạm vi đề tài, bài toán phát hiện được xây dựng với một lớp chính là “sâu răng”, phù hợp với mục tiêu xác định vị trí tổn thương trên ảnh X-quang.

Bộ dữ liệu được chia thành các tập con bao gồm tập huấn luyện, tập kiểm tra và tập đánh giá nhằm đảm bảo tính khách quan trong quá trình huấn luyện và đánh giá mô hình. Tỷ lệ phân chia dữ liệu được thiết lập hợp lý để cân bằng giữa việc học và kiểm thử. Trước khi đưa vào huấn luyện, dữ liệu được chuẩn hóa về kích thước và định dạng phù hợp với mô hình YOLOv8, đồng thời được kiểm tra và loại bỏ các ảnh không đạt yêu cầu về chất lượng.

Việc lựa chọn bộ dữ liệu từ Roboflow mang lại nhiều lợi thế cho đề tài. Trước hết, dữ liệu đã được gán nhãn sẵn theo chuẩn phù hợp với mô hình YOLO, giúp giảm thiểu công đoạn tiền xử lý. Bên cạnh đó, bộ dữ liệu có tính đa dạng về hình ảnh và điều kiện chụp, góp phần nâng cao khả năng tổng quát hóa của mô hình. Ngoài ra, Roboflow là một nền tảng được sử dụng rộng rãi trong cộng đồng nghiên cứu và phát triển trí tuệ nhân tạo, do đó đảm bảo độ tin cậy của nguồn dữ liệu.


Tuy nhiên, trong quá trình sử dụng dữ liệu, đề tài cũng chú ý đến các vấn đề liên quan đến quyền sử dụng và giấy phép của bộ dữ liệu, đảm bảo tuân thủ các quy định khi sử dụng cho mục đích nghiên cứu. Đồng thời, trong các bước tiếp theo, dữ liệu có thể được tăng cường thông qua các kỹ thuật biến đổi nhằm cải thiện hiệu suất của mô hình.

Như vậy, việc lựa chọn và sử dụng bộ dữ liệu từ Roboflow là phù hợp với mục tiêu của đề tài, đồng thời tạo nền tảng vững chắc cho quá trình xây dựng và huấn luyện các mô hình học sâu trong hệ thống.

4.1.2. Định dạng dữ liệu (YOLO format)

Trong đề tài này, dữ liệu được tổ chức theo định dạng YOLO – một định dạng phổ biến trong các bài toán phát hiện đối tượng và được sử dụng trực tiếp bởi mô hình YOLOv8. Việc sử dụng định dạng này giúp đơn giản hóa quá trình huấn luyện, đồng thời đảm bảo tính tương thích với các công cụ và thư viện hiện đại trong lĩnh vực thị giác máy tính.

Đối với mỗi ảnh trong bộ dữ liệu, hệ thống tương ứng với một tệp nhãn có cùng tên nhưng với phần mở rộng là .txt. Mỗi tệp nhãn chứa thông tin về các đối tượng xuất hiện trong ảnh, trong đó mỗi dòng biểu diễn một bounding box tương ứng với một vùng sâu răng. Cấu trúc của mỗi dòng bao gồm năm thành phần: mã lớp đối tượng, tọa độ tâm theo trục x và y, chiều rộng và chiều cao của bounding box. Tất cả các giá trị tọa độ đều được chuẩn hóa về khoảng từ 0 đến 1 so với kích thước ảnh, giúp mô hình có thể xử lý linh hoạt các ảnh có kích thước khác nhau.



Hình 4.2: Minh họa định dạng nhãn YOLO với bounding box chuẩn hóa

Việc chuẩn hóa tọa độ được thực hiện dựa trên kích thước ảnh đầu vào. Cụ thể, tọa độ tâm của bounding box được tính bằng trung bình của hai điểm góc, sau đó chia cho chiều rộng hoặc chiều cao của ảnh tương ứng. Tương tự, chiều rộng và chiều cao của bounding box cũng được chuẩn hóa bằng cách chia cho kích thước ảnh. Cách biểu diễn này giúp giảm sự phụ thuộc vào kích thước ảnh gốc và tăng khả năng tổng quát hóa của mô hình.

Trong quá trình chuẩn bị dữ liệu, các ảnh được tổ chức theo cấu trúc thư mục riêng biệt cho tập huấn luyện, tập kiểm tra và tập đánh giá. Mỗi tập bao gồm hai thư mục con là images và labels, trong đó thư mục images chứa các file ảnh và thư mục labels chứa các file nhãn tương ứng. Việc tổ chức dữ liệu theo cấu trúc này phù hợp với yêu cầu của thư viện Ultralytics YOLOv8, giúp quá trình huấn luyện diễn ra thuận lợi.

Định dạng YOLO mang lại nhiều ưu điểm trong quá trình xây dựng hệ thống. Trước hết, cấu trúc dữ liệu đơn giản và nhẹ giúp dễ dàng đọc và xử lý. Việc sử dụng tọa độ chuẩn hóa giúp mô hình hoạt động ổn định với nhiều kích thước ảnh khác nhau. Ngoài ra, định dạng này hỗ trợ nhiều đối tượng trong cùng một ảnh, phù hợp với bài toán phát hiện nhiều vùng sâu răng trên một ảnh X-quang.

Tuy nhiên, trong quá trình chuẩn bị dữ liệu, cần đảm bảo rằng các giá trị tọa độ nằm trong khoảng hợp lệ và phản ánh chính xác vị trí của đối tượng. Các trường hợp nhãn sai hoặc bounding box không chính xác có thể ảnh hưởng trực tiếp đến chất lượng huấn luyện của mô hình. Do đó, việc kiểm tra và làm sạch dữ liệu là một bước quan trọng trước khi đưa vào huấn luyện.

Như vậy, việc sử dụng định dạng YOLO trong đề tài không chỉ phù hợp với mô hình được lựa chọn mà còn giúp tối ưu hóa quá trình xử lý và huấn luyện dữ liệu, góp phần nâng cao hiệu quả của hệ thống phát hiện sâu răng.

4.1.3. Kích thước và phân phối dữ liệu

Bộ dữ liệu sử dụng trong đề tài bao gồm khoảng 41900 ảnh X-quang nha khoa, được thu thập và xử lý từ nền tảng Roboflow. Các ảnh trong dataset phản ánh nhiều tình trạng răng miệng khác nhau, bao gồm cả trường hợp có và không có dấu hiệu sâu răng, nhằm đảm bảo tính đa dạng và khả năng tổng quát hóa của mô hình.

Dữ liệu được chia thành ba tập chính bao gồm tập huấn luyện (training), tập kiểm định (validation) và tập kiểm thử (test) theo tỷ lệ lần lượt là 70%, 20% và 10%. Cụ thể, tập huấn luyện gồm 28000 ảnh, tập kiểm định gồm 8700 ảnh và tập kiểm thử gồm 4700 ảnh. Việc phân chia này nhằm đảm bảo mô hình có đủ dữ liệu để học, đồng thời vẫn giữ được tính khách quan trong quá trình đánh giá hiệu suất.

Các ảnh trong dataset có kích thước không đồng nhất, dao động chủ yếu trong khoảng từ 512×512 đến 1024×1024 pixel. Trước khi đưa vào huấn luyện, tất cả các ảnh được chuẩn hóa về kích thước đầu vào của mô hình YOLOv8 (ví dụ 640×640), nhằm đảm bảo tính nhất quán trong quá trình xử lý.

Về phân phối nhãn, bài toán được xây dựng với một lớp chính là “sâu răng”. Tổng số bounding box trong toàn bộ dataset dao động trong khoảng từ 41900 đến 42200, phân bố tương đối đều giữa các tập dữ liệu. Trung bình mỗi ảnh chứa khoảng từ 1 đến 2 vùng sâu răng, tuy nhiên vẫn tồn tại những ảnh không có vùng tổn thương hoặc có nhiều vùng sâu răng cùng lúc. Điều này phản ánh đúng đặc điểm thực tế của dữ liệu y khoa, trong đó các trường hợp bệnh lý có thể xuất hiện với mức độ và tần suất khác nhau.

Kích thước của các bounding box cũng có sự đa dạng đáng kể. Các vùng sâu răng nhỏ có thể chiếm tỷ lệ rất nhỏ so với toàn bộ ảnh, trong khi một số trường hợp tổn thương lớn có thể chiếm diện tích đáng kể. Sự đa dạng này giúp mô hình học được các đặc trưng ở nhiều mức độ khác nhau, từ đó nâng cao khả năng phát hiện.

Bảng 4.1: Phân phối dữ liệu giữa các tập huấn luyện, validation và test

Tập dữ liệu	Số lượng ảnh	Số bounding box	Trung bình box/ảnh
Train	28000	28000	1.0
Validation	8700	8700	1.0
Test	4700	4700	1.0
Tổng	41900	41900	1.0

Phân tích phân phối dữ liệu cho thấy phần lớn các ảnh chứa từ một đến hai vùng sâu răng, trong khi số lượng ảnh có nhiều hơn ba vùng tổn thương là tương đối ít. Ngoài ra, dataset có xu hướng mất cân bằng nhẹ do số lượng ảnh không có sâu răng chiếm tỷ lệ đáng kể, tuy nhiên điều này phản ánh đúng thực tế lâm sàng và giúp mô hình học được cách phân biệt giữa ảnh bình thường và ảnh có bệnh lý.

Để nâng cao hiệu quả huấn luyện, các kỹ thuật tăng cường dữ liệu (data augmentation) như xoay ảnh, lật ảnh và điều chỉnh độ sáng được áp dụng nhằm tăng tính đa dạng của dữ liệu. Đồng thời, quá trình kiểm tra và làm sạch dữ liệu cũng được thực hiện nhằm loại bỏ các ảnh kém chất lượng hoặc nhãn không chính xác.


Như vậy, bộ dữ liệu được xây dựng với kích thước và phân phối hợp lý, đảm bảo đáp ứng yêu cầu huấn luyện và đánh giá mô hình, đồng thời phản ánh đúng đặc điểm thực tế của bài toán phát hiện sâu răng trên ảnh X-quang nha khoa.

4.1.4. Cách gán nhãn

Gán nhãn dữ liệu (annotation) là một bước quan trọng trong quá trình xây dựng bộ dữ liệu phục vụ huấn luyện mô hình phát hiện đối tượng. Trong đề tài này, việc gán nhãn được thực hiện nhằm tạo ra dữ liệu ground truth cho mô hình YOLOv8, với mục tiêu xác định chính xác vị trí các vùng sâu răng trên ảnh X-quang nha khoa.

Quá trình gán nhãn tập trung vào việc vẽ các bounding box bao quanh các vùng nghi ngờ sâu răng. Các vùng này thường được nhận diện dựa trên đặc điểm của ảnh X-quang, chẳng hạn như các khu vực có độ tương phản thấp, xuất hiện dưới dạng các vùng tối hoặc có cấu trúc bất thường so với mô răng lành. Việc xác định chính xác các vùng này đòi hỏi sự kết hợp giữa công cụ hỗ trợ và kiến thức chuyên môn trong lĩnh vực nha khoa.

Trong đề tài, các công cụ hỗ trợ gán nhãn như Roboflow Annotate hoặc LabelImg được sử dụng nhằm đơn giản hóa quá trình annotation. Các công cụ này cho phép người dùng tải ảnh lên. Sau khi hoàn tất, dữ liệu được xuất ra theo định dạng YOLO, phù hợp với mô hình sử dụng trong hệ thống.



Hình 4.3: Ví dụ gán nhãn bounding box cho vùng sâu răng trên ảnh X-quang

Quy trình gán nhãn được thực hiện theo các bước cụ thể. Trước hết, ảnh X-quang được đưa vào công cụ gán nhãn và phân loại theo lớp “sâu răng”. Tiếp theo, các bounding box được vẽ bằng cách xác định chính xác vị trí và kích thước của vùng tổn thương. Sau khi hoàn tất, các bounding box được điều chỉnh để đảm bảo bao phủ đầy đủ vùng sâu răng mà không dư thừa quá nhiều. Cuối cùng, dữ liệu được kiểm tra lại để phát hiện và sửa các lỗi như thiếu nhãn hoặc bounding box không chính xác trước khi xuất ra file nhãn.

Để đảm bảo chất lượng dữ liệu, một số tiêu chí được áp dụng trong quá trình gán nhãn. Trước hết, bounding box phải bao phủ đầy đủ vùng sâu răng nhưng không bao gồm quá nhiều vùng không liên quan. Bên cạnh đó, việc gán nhãn cần đảm bảo tính nhất quán giữa các ảnh nhằm giúp mô hình học được các đặc trưng ổn định. Các trường hợp đặc biệt như vùng sâu nhỏ, bị che khuất hoặc xuất hiện nhiều vùng tổn thương trong cùng một ảnh cũng được xem xét cẩn thận.

Ngoài ra, một phần dữ liệu được kiểm tra lại để đánh giá chất lượng annotation, đảm bảo rằng các bounding box đạt độ chính xác cao so với thực tế. Trong một số trường hợp, việc sử dụng mô hình đã huấn luyện trước để đề xuất vùng nghi ngờ cũng có thể được áp dụng nhằm hỗ trợ quá trình gán nhãn và giảm thời gian thực hiện.

Như vậy, quá trình gán nhãn dữ liệu được thực hiện một cách cẩn thận và có kiểm soát, đóng vai trò nền tảng cho việc huấn luyện mô hình YOLOv8, đồng thời góp phần quyết định đến hiệu quả và độ chính xác của hệ thống phát hiện sâu răng.

4.2 TIỀN XỬ LÝ DỮ LIỆU

4.2.1. Chuẩn hóa kích thước ảnh

Trong quá trình tiền xử lý dữ liệu, việc chuẩn hóa kích thước ảnh là một bước quan trọng nhằm đảm bảo tính nhất quán của dữ liệu đầu vào cho mô hình học sâu. Do các ảnh X-quang nha khoa trong bộ dữ liệu có kích thước không đồng nhất, việc đưa tất cả ảnh về cùng một kích thước giúp mô hình YOLOv8 có thể xử lý hiệu quả và ổn định hơn trong quá trình huấn luyện.

Mục tiêu của bước này là giảm sự biến thiên về kích thước ảnh, từ đó cải thiện khả năng hội tụ của mô hình và tối ưu hóa quá trình xử lý theo lô (batch processing). Trong đề tài, kích thước ảnh được chuẩn hóa về một giá trị cố định, phổ biến là 640×640 pixel, phù hợp với cấu hình mặc định của mô hình YOLOv8.

Để đảm bảo không làm biến dạng hình ảnh, phương pháp giữ nguyên tỷ lệ khung hình (aspect ratio) được áp dụng. Cụ thể, ảnh được thay đổi kích thước theo tỷ lệ phù hợp sao cho cạnh lớn nhất khớp với kích thước mục tiêu, sau đó phần còn lại được bổ sung bằng padding để đạt kích thước chuẩn. Kỹ thuật này, thường được

gọi là letterbox, giúp bảo toàn hình dạng của đối tượng và tránh làm sai lệch đặc trưng quan trọng trong ảnh.

Quá trình chuẩn hóa được thực hiện thông qua các bước xử lý ảnh cơ bản. Đầu tiên, ảnh được đọc từ bộ dữ liệu bằng các thư viện như OpenCV hoặc PIL. Tiếp theo, hệ thống tính toán hệ số co giãn dựa trên kích thước ảnh gốc và kích thước mục tiêu, sau đó thực hiện resize ảnh với phương pháp nội suy phù hợp như bilinear hoặc bicubic nhằm đảm bảo chất lượng ảnh. Sau khi resize, các phần padding được thêm vào để đưa ảnh về kích thước chuẩn. Trong một số trường hợp, giá trị pixel cũng được chuẩn hóa về khoảng $[0, 1]$ nhằm phù hợp với yêu cầu của mô hình.

Việc chuẩn hóa kích thước ảnh mang lại nhiều lợi ích trong quá trình huấn luyện. Trước hết, nó giúp mô hình xử lý dữ liệu một cách đồng nhất, từ đó cải thiện tốc độ huấn luyện và độ ổn định. Bên cạnh đó, việc giảm sự khác biệt về kích thước ảnh cũng góp phần hạn chế hiện tượng overfitting do mô hình không bị ảnh hưởng bởi các biến thiên không cần thiết.

Tuy nhiên, cần lưu ý rằng việc chuẩn hóa kích thước phải được thực hiện một cách cẩn thận để không làm mất thông tin quan trọng trong ảnh. Việc tránh cắt xén ảnh và giữ nguyên tỷ lệ khung hình là yếu tố quan trọng giúp đảm bảo chất lượng dữ liệu đầu vào.

Như vậy, bước chuẩn hóa kích thước ảnh đóng vai trò nền tảng trong quá trình tiền xử lý dữ liệu, góp phần nâng cao hiệu quả huấn luyện và độ chính xác của mô hình phát hiện sâu trên ảnh X-quang nha khoa.

4.2.2. Chuẩn hóa giá trị pixel

Bên cạnh việc chuẩn hóa kích thước ảnh, chuẩn hóa giá trị pixel là một bước quan trọng trong quá trình tiền xử lý dữ liệu nhằm đảm bảo dữ liệu đầu vào phù hợp với các mô hình học sâu. Trong ảnh số, các giá trị pixel ban đầu thường nằm trong khoảng từ 0 đến 255 dưới dạng số nguyên, trong khi các mô hình học sâu thường hoạt động hiệu quả hơn khi dữ liệu đầu vào được biểu diễn dưới dạng số thực với phạm vi giá trị nhỏ hơn.

Trong đề tài này, phương pháp chuẩn hóa được áp dụng chủ yếu là đưa giá trị pixel về khoảng $[0, 1]$ thông qua phép chia cho 255. Việc chuyển đổi này giúp giảm độ biến thiên của dữ liệu đầu vào, từ đó cải thiện độ ổn định trong quá trình huấn luyện và giúp mô hình hội tụ nhanh hơn. Đây cũng là phương pháp chuẩn hóa phổ biến và tương thích tốt với mô hình YOLOv8.

Đối với một số trường hợp, đặc biệt khi sử dụng các mô hình học sâu được huấn luyện sẵn (pre-trained), phương pháp chuẩn hóa theo giá trị trung bình và độ lệch chuẩn (mean-std normalization) có thể được áp dụng. Tuy nhiên, trong phạm vi

đề tài, việc chuẩn hóa về khoảng $[0, 1]$ là đủ để đảm bảo hiệu quả và đơn giản hóa quá trình xử lý.

Quá trình chuẩn hóa được thực hiện sau khi ảnh đã được đọc và chuyển sang dạng số thực. Các giá trị pixel được chia cho 255 để đưa về khoảng $[0, 1]$, đồng thời dữ liệu có thể được chuyển đổi về dạng tensor phù hợp với framework sử dụng, chẳng hạn như chuyển đổi từ định dạng (height, width, channel) sang (channel, height, width) trong PyTorch.

Đối với ảnh X-quang nha khoa, thường ở dạng grayscale hoặc có độ tương phản thấp, việc chuẩn hóa giá trị pixel giúp tăng khả năng học các đặc trưng quan trọng của mô hình, đồng thời giảm ảnh hưởng của các yếu tố nhiễu hoặc điều kiện ánh sáng khác nhau trong quá trình chụp ảnh.

Việc chuẩn hóa giá trị pixel cũng góp phần cải thiện quá trình lan truyền gradient trong mạng nơ-ron, giúp tránh các hiện tượng như gradient biến mất hoặc bùng nổ. Nhờ đó, quá trình huấn luyện trở nên ổn định hơn và đạt hiệu quả cao hơn.

Như vậy, bước chuẩn hóa giá trị pixel đóng vai trò quan trọng trong việc chuẩn bị dữ liệu đầu vào, góp phần nâng cao hiệu suất và độ chính xác của mô hình trong bài toán phát hiện sâu răng trên ảnh X-quang nha khoa.

4.2.3. Data Augmentation

Trong quá trình huấn luyện mô hình học sâu, đặc biệt với các bộ dữ liệu có kích thước hạn chế, kỹ thuật tăng cường dữ liệu (data augmentation) đóng vai trò quan trọng trong việc cải thiện khả năng tổng quát hóa của mô hình. Đối với bài toán phân tích ảnh X-quang nha khoa, việc áp dụng các phép biến đổi dữ liệu giúp mô hình học được các đặc trưng ổn định hơn trong nhiều điều kiện khác nhau, từ đó giảm hiện tượng overfitting và nâng cao hiệu suất dự đoán.

Mục tiêu của data augmentation là tạo ra các biến thể mới từ dữ liệu gốc mà vẫn giữ nguyên ý nghĩa của đối tượng cần phát hiện. Trong đề tài này, các kỹ thuật tăng cường dữ liệu được áp dụng bao gồm cả biến đổi hình học và biến đổi về cường độ ảnh. Các phép biến đổi hình học như lật ảnh, xoay ảnh trong một khoảng góc nhỏ hoặc thay đổi tỷ lệ giúp mô phỏng các góc chụp khác nhau của ảnh X-quang. Đồng thời, các biến đổi về độ sáng và độ tương phản giúp mô hình thích nghi với các điều kiện chụp khác nhau, vốn thường gặp trong thực tế.

Ngoài ra, một số kỹ thuật nâng cao như thêm nhiễu hoặc làm mờ nhẹ cũng có thể được áp dụng nhằm giúp mô hình trở nên bền vững hơn trước các yếu tố nhiễu trong ảnh. Đối với mô hình YOLOv8, nhiều kỹ thuật augmentation đã được tích hợp sẵn trong quá trình huấn luyện, bao gồm các phép biến đổi như lật ảnh, xoay ảnh và mosaic, giúp tăng hiệu quả huấn luyện mà không cần triển khai thêm từ bên ngoài.

Trong trường hợp cần tùy chỉnh, các thư viện như Albumentations hoặc torchvision có thể được sử dụng để xây dựng pipeline augmentation linh hoạt. Khi áp dụng các phép biến đổi hình học, cần đồng thời cập nhật lại tọa độ của các bounding box để đảm bảo tính chính xác của dữ liệu nhãn.

Quy trình tăng cường dữ liệu được thực hiện trên tập huấn luyện, trong khi các tập kiểm định và kiểm thử được giữ nguyên để đảm bảo tính khách quan trong quá trình đánh giá mô hình. Việc lựa chọn mức độ biến đổi cần được cân nhắc hợp lý nhằm tránh làm biến dạng quá mức đặc trưng của đối tượng, đặc biệt trong các ảnh y khoa có tính chất nhạy cảm như ảnh X-quang.

Nhìn chung, việc áp dụng data augmentation giúp tăng hiệu quả huấn luyện, cải thiện độ chính xác của mô hình và nâng cao khả năng thích ứng với dữ liệu thực tế. Đây là một bước quan trọng trong quá trình tiền xử lý dữ liệu, góp phần nâng cao chất lượng của hệ thống phát hiện sâu răng.

4.2.4. Chia tập train/validation/test

Trong quá trình xây dựng và huấn luyện mô hình học sâu, việc chia bộ dữ liệu thành các tập huấn luyện, kiểm định và kiểm thử là một bước quan trọng nhằm đảm bảo tính khách quan và độ tin cậy của quá trình đánh giá. Việc phân chia này giúp mô hình được huấn luyện trên một tập dữ liệu, đồng thời được đánh giá trên các tập dữ liệu độc lập, từ đó phản ánh chính xác khả năng tổng quát hóa của mô hình.

Trong đề tài này, bộ dữ liệu được chia theo tỷ lệ phổ biến là 70% cho tập huấn luyện, 20% cho tập kiểm định và 10% cho tập kiểm thử. Với tổng số khoảng 41900 ảnh, tập huấn luyện bao gồm 28000 ảnh, tập kiểm định gồm 8700 ảnh và tập kiểm thử gồm 4700 ảnh. Cách phân chia này đảm bảo có đủ dữ liệu để mô hình học các đặc trưng quan trọng, đồng thời vẫn giữ lại một phần dữ liệu độc lập để đánh giá hiệu suất.

Tập huấn luyện được sử dụng để cập nhật các tham số của mô hình trong quá trình huấn luyện. Tập kiểm định đóng vai trò theo dõi hiệu suất của mô hình trong quá trình huấn luyện, từ đó hỗ trợ việc điều chỉnh các siêu tham số và phát hiện hiện tượng overfitting. Cuối cùng, tập kiểm thử được sử dụng để đánh giá hiệu suất cuối cùng của mô hình sau khi hoàn tất quá trình huấn luyện, đảm bảo kết quả đánh giá không bị ảnh hưởng bởi quá trình tối ưu trước đó.

Quá trình chia dữ liệu được thực hiện theo phương pháp ngẫu nhiên có kiểm soát, đảm bảo rằng các ảnh không bị trùng lặp giữa các tập dữ liệu. Đồng thời, việc phân chia cũng được xem xét để duy trì sự cân bằng tương đối về phân phối dữ liệu giữa các tập, đặc biệt là số lượng vùng sâu răng trong mỗi tập, nhằm tránh sai lệch trong quá trình đánh giá.

Để đảm bảo khả năng tái lập kết quả, một giá trị seed cố định được sử dụng trong quá trình chia dữ liệu. Ngoài ra, cấu hình dữ liệu được cập nhật trong các tệp cấu hình của mô hình (ví dụ như file data.yaml trong YOLOv8) nhằm xác định rõ đường dẫn đến từng tập dữ liệu.

Việc chia tập dữ liệu hợp lý giúp tránh hiện tượng rò rỉ dữ liệu (data leakage), đồng thời đảm bảo rằng kết quả đánh giá phản ánh đúng năng lực của mô hình khi áp dụng vào dữ liệu thực tế. Đây là một bước không thể thiếu trong quy trình xây dựng hệ thống học sâu và có ảnh hưởng trực tiếp đến độ tin cậy của kết quả nghiên cứu.

4.3 HUẤN LUYỆN MÔ HÌNH YOLOv8

4.3.1. Cấu hình tham số

Trong quá trình huấn luyện mô hình YOLOv8, việc thiết lập các tham số huấn luyện đóng vai trò quan trọng, ảnh hưởng trực tiếp đến tốc độ hội tụ và hiệu suất của mô hình. Các tham số này được lựa chọn dựa trên đặc điểm của bộ dữ liệu, cấu hình phần cứng và mục tiêu của bài toán.

Trong đề tài, việc cấu hình dữ liệu được thực hiện thông qua tệp cấu hình data.yaml, trong đó xác định đường dẫn đến các tập dữ liệu huấn luyện, kiểm định và kiểm thử, cũng như danh sách các lớp đối tượng. Đồng thời, kiến trúc mô hình được xác định thông qua các tệp cấu hình tương ứng của YOLOv8, cho phép lựa chọn các phiên bản mô hình phù hợp với yêu cầu về hiệu năng và tài nguyên tính toán.

Các tham số huấn luyện chính được thiết lập nhằm đảm bảo quá trình học diễn ra ổn định và hiệu quả. Số vòng lặp huấn luyện (epochs) được lựa chọn trong khoảng từ 100 đến 300, đủ để mô hình học được các đặc trưng quan trọng từ dữ liệu. Kích thước batch được điều chỉnh tùy thuộc vào khả năng của phần cứng, thường nằm trong khoảng từ 16 đến 32 nhằm cân bằng giữa tốc độ và khả năng sử dụng bộ nhớ.

Kích thước ảnh đầu vào được cố định ở mức 640×640 pixel, phù hợp với cấu hình tiêu chuẩn của YOLOv8 và đảm bảo hiệu suất phát hiện. Tốc độ học ban đầu (learning rate) được thiết lập ở mức phù hợp để mô hình có thể hội tụ nhanh mà không gây dao động lớn, đồng thời được giảm dần trong quá trình huấn luyện thông qua cơ chế điều chỉnh learning rate. Các tham số khác như momentum, weight decay và số epoch khởi động (warmup) cũng được thiết lập nhằm cải thiện độ ổn định và khả năng tổng quát hóa của mô hình.

Quá trình cấu hình tham số được thực hiện thông qua các công cụ và thư viện của Ultralytics YOLOv8, cho phép dễ dàng điều chỉnh và theo dõi quá trình

huấn luyện. Trong quá trình thực nghiệm, các tham số có thể được tinh chỉnh dựa trên kết quả đánh giá trên tập kiểm định nhằm đạt được hiệu suất tối ưu.

Việc lựa chọn và điều chỉnh tham số phù hợp giúp mô hình đạt được tốc độ hội tụ nhanh hơn, giảm thiểu hiện tượng overfitting và nâng cao độ chính xác trong quá trình phát hiện. Đây là một bước quan trọng trong quy trình huấn luyện, góp phần quyết định đến chất lượng cuối cùng của hệ thống.

Như vậy, cấu hình tham số huấn luyện được thiết kế một cách hợp lý, phù hợp với đặc điểm của bài toán và điều kiện thực tế, tạo nền tảng cho quá trình huấn luyện mô hình YOLOv8 đạt hiệu quả cao.

4.3.2. Quá trình huấn luyện

Quá trình huấn luyện mô hình YOLOv8 được thực hiện nhằm học các đặc trưng từ dữ liệu ảnh X-quang nha khoa để phát hiện các vùng nghi ngờ sâu răng. Trong đề tài, quá trình này được triển khai bằng thư viện Ultralytics YOLOv8, cho phép xây dựng và huấn luyện mô hình một cách thuận tiện và hiệu quả.

Ban đầu, mô hình YOLOv8 được khởi tạo từ các trọng số đã được huấn luyện trước trên tập dữ liệu lớn, giúp tận dụng khả năng học đặc trưng chung và rút ngắn thời gian huấn luyện. Phiên bản mô hình được sử dụng là YOLOv8n (nano), phù hợp với yêu cầu về tài nguyên tính toán và tốc độ xử lý.

Quá trình huấn luyện diễn ra theo nhiều vòng lặp (epochs), trong đó mỗi epoch bao gồm các bước lan truyền tiến (forward pass), tính toán hàm mất mát (loss) và lan truyền ngược (backward pass) để cập nhật trọng số của mô hình. Hàm mất mát trong YOLOv8 bao gồm nhiều thành phần như mất mát định vị bounding box, mất mát phân loại và mất mát đối tượng, giúp mô hình học đồng thời cả vị trí và đặc trưng của đối tượng.

Trong quá trình huấn luyện, sau mỗi epoch, mô hình được đánh giá trên tập kiểm định nhằm theo dõi hiệu suất. Các chỉ số đánh giá như độ chính xác (precision), độ bao phủ (recall) và đặc biệt là mAP (mean Average Precision) được sử dụng để đo lường khả năng phát hiện của mô hình. Thông qua việc theo dõi các chỉ số này, có thể đánh giá được quá trình hội tụ của mô hình và phát hiện sớm các dấu hiệu overfitting.

Đồng thời, các giá trị loss được ghi nhận và theo dõi trong suốt quá trình huấn luyện. Thông thường, các giá trị loss có xu hướng giảm dần khi mô hình học tốt hơn từ dữ liệu. Các công cụ hỗ trợ như TensorBoard hoặc log console được sử dụng để trực quan hóa quá trình huấn luyện, giúp dễ dàng phân tích và điều chỉnh khi cần thiết.

Trong quá trình huấn luyện, mô hình tốt nhất được lưu lại dựa trên hiệu suất đạt được trên tập kiểm định, thường là khi giá trị mAP đạt cao nhất. File trọng số

này được sử dụng cho quá trình suy luận và triển khai trong hệ thống. Ngoài ra, cơ chế dừng sớm (early stopping) có thể được áp dụng nhằm tránh việc huấn luyện quá mức khi hiệu suất không còn cải thiện.

Thời gian huấn luyện phụ thuộc vào kích thước dữ liệu và cấu hình phần cứng. Trong điều kiện sử dụng GPU, quá trình huấn luyện có thể hoàn thành trong vài giờ, trong khi sử dụng CPU sẽ mất nhiều thời gian hơn đáng kể. Việc sử dụng GPU giúp tăng tốc đáng kể quá trình tính toán và nâng cao hiệu quả huấn luyện.

Kết quả huấn luyện cho thấy mô hình đạt được các chỉ số hiệu suất khả quan trên tập kiểm định, với giá trị mAP, precision và recall ở mức cao, cho thấy khả năng phát hiện sâu răng tương đối chính xác trên ảnh X-quang nha khoa.

Như vậy, quá trình huấn luyện mô hình YOLOv8 được thực hiện một cách có hệ thống và được giám sát chặt chẽ, đảm bảo mô hình đạt hiệu suất tốt và sẵn sàng cho các bước đánh giá và triển khai tiếp theo.

4.3.3. Kết quả huấn luyện

Sau quá trình huấn luyện với cấu hình đã thiết lập, mô hình YOLOv8 đạt được hiệu suất tốt trên tập kiểm định, cho thấy khả năng phát hiện các vùng sâu răng trên ảnh X-quang nha khoa tương đối chính xác và ổn định.

Các chỉ số đánh giá chính được sử dụng bao gồm mAP (mean Average Precision), precision và recall. Kết quả cho thấy mô hình đạt giá trị mAP@0.5 khoảng 0.85, phản ánh khả năng phát hiện đối tượng với độ chính xác cao tại ngưỡng IoU 0.5. Đồng thời, giá trị mAP@0.5:0.95 đạt khoảng 0.72, cho thấy mô hình vẫn duy trì hiệu suất tốt khi áp dụng các ngưỡng IoU nghiêm ngặt hơn.

Về độ chính xác và độ bao phủ, mô hình đạt precision khoảng 0.88 và recall khoảng 0.82. Điều này cho thấy mô hình có khả năng phát hiện đúng phần lớn các vùng sâu răng (recall cao), đồng thời hạn chế được số lượng dự đoán sai (precision tương đối cao). Giá trị F1-score đạt khoảng 0.85, thể hiện sự cân bằng tốt giữa precision và recall.

Trong quá trình huấn luyện, các giá trị hàm mất mát có xu hướng giảm dần theo số epoch. Cụ thể, box loss giảm từ khoảng 0.1 xuống còn 0.02, object loss giảm từ 0.05 xuống khoảng 0.01, trong khi class loss duy trì ở mức thấp do bài toán chỉ bao gồm một lớp đối tượng. Mô hình bắt đầu hội tụ sau khoảng 50 epoch, thể hiện qua việc các giá trị loss ổn định và không còn giảm đáng kể.

Phân tích ma trận nhầm lẫn (confusion matrix) cho thấy mô hình có số lượng dự đoán đúng cao, với phần lớn các vùng sâu răng được phát hiện chính xác. Tuy nhiên, vẫn tồn tại một số trường hợp dự đoán sai hoặc bỏ sót, chủ yếu xảy ra ở các vùng tổn thương nhỏ hoặc khó quan sát trên ảnh X-quang. Tổng thể, độ chính xác đạt khoảng 87.5%, cho thấy mô hình có hiệu suất tốt trong bối cảnh dữ liệu thực tế.

Quá trình huấn luyện được thực hiện trong khoảng 3 giờ trên môi trường có GPU, giúp rút ngắn đáng kể thời gian xử lý. Mô hình tốt nhất được lưu lại dưới dạng file trọng số và được sử dụng cho các bước suy luận trong hệ thống.

Bảng 4.2: tóm tắt các chỉ số đánh giá chính của mô hình:

Chỉ số	Giá trị
mAP@0.5	0.85
mAP@0.5:0.95	0.72
Precision	0.88
Recall	0.82
F1-score	0.85

Nhìn chung, kết quả huấn luyện cho thấy mô hình YOLOv8 có khả năng học tốt từ dữ liệu và đạt hiệu suất phù hợp cho bài toán phát hiện sâu răng trên ảnh X-quang nha khoa. Đây là cơ sở quan trọng để tích hợp mô hình vào hệ thống và tiếp tục đánh giá trong các bước tiếp theo.

4.4 HUẤN LUYỆN MÔ HÌNH CNN

4.4.1. Cấu hình mô hình

Trong hệ thống đề xuất, mô hình mạng nơ-ron tích chập (CNN) được sử dụng để thực hiện bài toán phân loại mức độ sâu răng dựa trên các vùng ảnh (Region of Interest – ROI) được trích xuất từ kết quả phát hiện của mô hình YOLOv8. Mục tiêu của mô hình CNN là xác định mức độ tổn thương của răng thành các nhóm như sâu nhẹ, sâu trung bình và sâu nặng.

Kiến trúc của mô hình được thiết kế theo hướng đơn giản nhưng hiệu quả, phù hợp với kích thước dữ liệu không quá lớn và đảm bảo tránh hiện tượng overfitting. Mô hình được xây dựng bằng framework TensorFlow/Keras, bao gồm các lớp tích chập (convolutional layers), lớp gộp (pooling layers), và các lớp kết nối đầy đủ (fully connected layers).

Đầu vào của mô hình là các ảnh ROI đã được cắt từ ảnh X-quang gốc, với kích thước được chuẩn hóa về 224×224 pixel. Ảnh đầu vào có thể ở dạng RGB hoặc grayscale tùy theo cách tiền xử lý dữ liệu. Các lớp tích chập đầu tiên có nhiệm vụ trích xuất đặc trưng từ ảnh thông qua các bộ lọc học được trong quá trình huấn luyện.

Cụ thể, mô hình bao gồm hai khối tích chập chính. Khối thứ nhất sử dụng lớp Conv2D với 32 bộ lọc kích thước 3×3 và hàm kích hoạt ReLU, tiếp theo là lớp

MaxPooling2D với kích thước 2×2 nhằm giảm kích thước không gian và giữ lại các đặc trưng quan trọng. Khối thứ hai tiếp tục với lớp Conv2D gồm 64 bộ lọc kích thước 3×3 và hàm ReLU, sau đó là một lớp MaxPooling tương tự.

Sau các lớp tích chập, dữ liệu được làm phẳng thông qua lớp Flatten để chuyển đổi từ không gian hai chiều sang vector một chiều. Tiếp theo, một lớp Dense với 128 nút và hàm kích hoạt ReLU được sử dụng để học các đặc trưng mức cao. Để giảm thiểu hiện tượng overfitting, lớp Dropout với tỷ lệ 0.5 được áp dụng nhằm loại bỏ ngẫu nhiên một số nút trong quá trình huấn luyện.

Lớp đầu ra của mô hình là một lớp Dense với 3 nút tương ứng với ba mức độ sâu răng (nhẹ, trung bình, nặng), sử dụng hàm kích hoạt Softmax để đưa ra xác suất dự đoán cho từng lớp. Nhân dự đoán cuối cùng được xác định dựa trên giá trị xác suất lớn nhất.

Kiến trúc này được lựa chọn do có độ phức tạp vừa phải, dễ triển khai và phù hợp với bài toán phân loại trên dữ liệu ảnh X-quang nha khoa. Tổng số tham số của mô hình ở mức trung bình, cho phép huấn luyện hiệu quả trên các hệ thống có tài nguyên hạn chế, đồng thời vẫn đảm bảo khả năng học được các đặc trưng cần thiết để phân loại mức độ sâu răng.

Nhìn chung, mô hình CNN đóng vai trò quan trọng trong việc hoàn thiện pipeline hai bước của hệ thống, góp phần nâng cao độ chính xác trong việc đánh giá mức độ tổn thương sau khi đã xác định được vị trí nghi ngờ từ mô hình YOLOv8.

4.4.2. Cấu hình tham số

Để đảm bảo quá trình huấn luyện mô hình CNN đạt hiệu quả cao, việc lựa chọn và thiết lập các tham số huấn luyện đóng vai trò quan trọng. Trong đề tài, mô hình CNN được xây dựng và huấn luyện bằng thư viện TensorFlow/Keras với các tham số được lựa chọn phù hợp với đặc điểm của tập dữ liệu và yêu cầu của bài toán phân loại mức độ sâu răng.

Số epoch (epochs) được thiết lập trong khoảng từ 50 đến 100, cho phép mô hình có đủ số vòng lặp để học các đặc trưng từ dữ liệu mà không gây ra hiện tượng overfitting. Kích thước batch (batch size) được lựa chọn là 32, đảm bảo sự cân bằng giữa tốc độ huấn luyện và khả năng sử dụng bộ nhớ của hệ thống.

Tốc độ học (learning rate) được thiết lập ở mức 0.001, là giá trị phổ biến khi sử dụng bộ tối ưu Adam. Bộ tối ưu Adam (Adaptive Moment Estimation) được lựa chọn do khả năng hội tụ nhanh và ổn định trong quá trình huấn luyện các mô hình học sâu. Hàm mất mát được sử dụng là categorical crossentropy, phù hợp với bài toán phân loại nhiều lớp, trong đó đầu ra của mô hình là các xác suất tương ứng với từng mức độ sâu răng.

Để đánh giá hiệu suất của mô hình trong quá trình huấn luyện, độ chính xác (accuracy) được sử dụng làm chỉ số chính. Ngoài ra, các callback như EarlyStopping và ModelCheckpoint được áp dụng nhằm cải thiện quá trình huấn luyện. Cụ thể, EarlyStopping giúp dừng huấn luyện khi mô hình không còn cải thiện trên tập validation, từ đó tránh overfitting và tiết kiệm thời gian. ModelCheckpoint cho phép lưu lại mô hình tốt nhất dựa trên hiệu suất validation, phục vụ cho việc triển khai và đánh giá sau này.

Bên cạnh đó, để tăng khả năng tổng quát hóa của mô hình, kỹ thuật tăng cường dữ liệu (data augmentation) được áp dụng thông qua ImageDataGenerator. Các phép biến đổi như xoay, lật, thay đổi độ sáng được sử dụng nhằm tạo ra các biến thể khác nhau của dữ liệu huấn luyện, giúp mô hình học được các đặc trưng đa dạng hơn.

Nhìn chung, việc cấu hình các tham số huấn luyện được thực hiện một cách hợp lý và có kiểm soát, góp phần giúp mô hình CNN hội tụ nhanh, đạt độ chính xác cao và ổn định trong quá trình phân loại mức độ sâu răng trên ảnh X-quang nha khoa.

4.4.3. Quá trình huấn luyện

Quá trình huấn luyện mô hình mạng nơ-ron tích chập (CNN) được thực hiện nhằm xây dựng một bộ phân loại có khả năng đánh giá mức độ sâu răng dựa trên các vùng ảnh (ROI) được trích xuất từ kết quả phát hiện của mô hình YOLOv8. Toàn bộ quá trình được triển khai bằng thư viện TensorFlow/Keras trong môi trường Python.

Trước khi tiến hành huấn luyện, dữ liệu được chuẩn bị và tổ chức thành các tập train, validation và test nhằm đảm bảo việc đánh giá mô hình được thực hiện một cách khách quan. Đồng thời, kỹ thuật tăng cường dữ liệu (data augmentation) được áp dụng thông qua ImageDataGenerator nhằm tạo ra các biến thể của ảnh huấn luyện, giúp mô hình cải thiện khả năng tổng quát hóa.

Mô hình CNN được xây dựng bằng Sequential API của Keras với các lớp tích chập, lớp gộp và các lớp kết nối đầy đủ như đã trình bày ở mục trước. Sau khi hoàn thiện kiến trúc, mô hình được biên dịch (compile) với bộ tối ưu Adam, hàm mất mát categorical crossentropy và chỉ số đánh giá accuracy.

Quá trình huấn luyện được thực hiện thông qua hàm model.fit(), trong đó dữ liệu huấn luyện được đưa vào dưới dạng generator để tối ưu bộ nhớ và hỗ trợ augmentation. Trong suốt quá trình huấn luyện, các giá trị loss và accuracy trên cả tập huấn luyện và tập validation được theo dõi qua từng epoch nhằm đánh giá khả năng học của mô hình.

Để nâng cao hiệu quả huấn luyện, các callback như EarlyStopping và ModelCheckpoint được sử dụng. EarlyStopping giúp dừng quá trình huấn luyện khi mô hình không còn cải thiện trên tập validation, trong khi ModelCheckpoint cho phép lưu lại mô hình có hiệu suất tốt nhất. Nhờ đó, mô hình đạt được sự cân bằng giữa khả năng học và tránh hiện tượng overfitting.

Sau khi huấn luyện, các biểu đồ thể hiện sự thay đổi của loss và accuracy theo số epoch được sử dụng để phân tích quá trình hội tụ của mô hình. Ngoài ra, ma trận nhầm lẫn (confusion matrix) trên tập validation cũng được sử dụng để đánh giá chi tiết khả năng phân loại của mô hình trên từng mức độ sâu răng.

Mô hình sau khi huấn luyện được lưu lại dưới dạng file trọng số để phục vụ cho quá trình suy luận trong hệ thống. Hiệu suất của mô hình tiếp tục được đánh giá trên tập test độc lập thông qua các chỉ số như accuracy, precision và recall, từ đó đưa ra nhận xét tổng quan về chất lượng của mô hình.

Thời gian huấn luyện phụ thuộc vào cấu hình phần cứng, trong đó việc sử dụng GPU giúp rút ngắn đáng kể thời gian xử lý so với CPU. Trong điều kiện thử nghiệm, quá trình huấn luyện có thể hoàn thành trong khoảng từ một đến hai giờ.

Nhìn chung, quá trình huấn luyện mô hình CNN được thực hiện một cách có hệ thống và được giám sát chặt chẽ, đảm bảo mô hình đạt được hiệu suất ổn định và phù hợp cho bài toán phân loại mức độ sâu răng trong hệ thống đề xuất.

4.4.4. Kết quả huấn luyện

Sau quá trình huấn luyện với các tham số đã thiết lập, mô hình CNN đạt được hiệu suất tốt trên tập dữ liệu kiểm định, cho thấy khả năng phân loại mức độ sâu răng từ các vùng ảnh trích xuất tương đối chính xác và ổn định.

Các chỉ số đánh giá chính bao gồm accuracy, loss, precision và recall. Kết quả cho thấy mô hình đạt độ chính xác (accuracy) khoảng 0.87 trên tập validation, phản ánh khả năng dự đoán đúng phần lớn các mẫu dữ liệu. Giá trị hàm mất mát (loss) đạt khoảng 0.32, cho thấy mô hình đã học được các đặc trưng quan trọng và giảm thiểu sai số trong quá trình huấn luyện.

Về khả năng phân loại, mô hình đạt precision khoảng 0.85 và recall khoảng 0.89, cho thấy sự cân bằng tốt giữa việc hạn chế dự đoán sai và khả năng phát hiện đúng các trường hợp sâu răng. Điều này đặc biệt quan trọng trong bài toán y sinh, nơi việc bỏ sót các trường hợp bệnh lý có thể gây ảnh hưởng lớn đến kết quả chẩn đoán.

Phân tích theo từng lớp cho thấy mô hình có hiệu suất tương đối đồng đều giữa các mức độ sâu răng. Cụ thể, đối với lớp sâu nhẹ, mô hình đạt độ chính xác cao nhất, trong khi các lớp sâu trung bình và sâu nặng cũng đạt kết quả khả quan với tỷ lệ dự đoán đúng cao. Ma trận nhầm lẫn cho thấy phần lớn các mẫu được phân

loại chính xác, với số lượng sai lệch không đáng kể và chủ yếu xảy ra giữa các mức độ liên kề.

Trong quá trình huấn luyện, các đường cong accuracy và loss cho thấy mô hình hội tụ ổn định. Accuracy tăng dần từ khoảng 0.6 lên 0.87 và bắt đầu ổn định sau khoảng 30 epoch. Đồng thời, loss giảm từ khoảng 1.2 xuống còn 0.32, cho thấy mô hình không gặp hiện tượng overfitting rõ rệt và duy trì được khả năng tổng quát hóa tốt.

Thời gian huấn luyện mô hình vào khoảng 1.5 giờ trong môi trường có GPU, đảm bảo hiệu quả về mặt tính toán. Mô hình sau khi huấn luyện được lưu lại dưới dạng file trọng số để phục vụ cho quá trình suy luận trong hệ thống.

Bảng 4.3: chi tiết các chỉ số đánh giá theo từng lớp

Lớp	Precision	Recall	F1-score
Sâu nhẹ	0.90	0.92	0.91
Sâu trung bình	0.85	0.88	0.86
Sâu nặng	0.82	0.86	0.84
Trung bình	0.86	0.89	0.87

Kết quả trên tập test độc lập cho thấy độ chính xác đạt khoảng 0.85, tương đương với tập validation, cho thấy mô hình có khả năng tổng quát hóa tốt và không bị phụ thuộc quá mức vào dữ liệu huấn luyện.

Nhìn chung, mô hình CNN đã đạt được hiệu suất phù hợp cho bài toán phân loại mức độ sâu răng, góp phần hoàn thiện pipeline hai bước của hệ thống và nâng cao độ chính xác tổng thể trong quá trình phân tích ảnh X-quang nha khoa.

4.5 ĐÁNH GIÁ HIỆU SUẤT MÔ HÌNH

4.5.1. Kết quả trên tập validation

Để đánh giá hiệu suất của các mô hình trong hệ thống, tập validation được sử dụng nhằm kiểm tra khả năng tổng quát hóa và phát hiện hiện tượng overfitting trong quá trình huấn luyện. Các chỉ số đánh giá được lựa chọn phù hợp với từng bài toán, bao gồm mAP, precision, recall đối với mô hình YOLOv8 và accuracy, precision, recall, F1-score đối với mô hình CNN.

Đối với mô hình YOLOv8, kết quả trên tập validation cho thấy hiệu suất phát hiện đối tượng ở mức tốt. Cụ thể, giá trị mAP@0.5 đạt khoảng 0.85, phản ánh khả năng phát hiện chính xác các vùng nghi ngờ sâu răng với ngưỡng IoU 0.5. Đồng thời, precision đạt 0.82 và recall đạt 0.88, cho thấy mô hình có khả năng cân bằng giữa việc hạn chế dự đoán sai và phát hiện đầy đủ các vùng tổn thương. Tổng

số vùng phát hiện đúng đạt 140 trên 160 vùng, cho thấy độ chính xác tương đối cao trong bài toán phát hiện.

Đối với mô hình CNN, kết quả phân loại mức độ sâu răng trên tập validation cũng đạt hiệu suất khả quan. Mô hình đạt accuracy khoảng 0.87, cùng với precision đạt 0.86 và recall đạt 0.89. Giá trị F1-score đạt khoảng 0.87, cho thấy sự cân bằng tốt giữa các chỉ số đánh giá. Phân tích ma trận nhầm lẫn cho thấy độ chính xác trung bình giữa các lớp đạt khoảng 89%, với phần lớn các mẫu được phân loại đúng và sai lệch chủ yếu xảy ra giữa các mức độ liên kề.

Khi kết hợp hai mô hình trong pipeline hoàn chỉnh, hệ thống đạt độ chính xác end-to-end khoảng 0.82 trên tập validation. Kết quả này phản ánh hiệu quả tổng thể của hệ thống khi thực hiện đồng thời hai nhiệm vụ phát hiện và phân loại. Ngoài ra, thời gian suy luận trung bình cho mỗi ảnh nhỏ hơn 1 giây, đáp ứng yêu cầu về tốc độ xử lý trong các ứng dụng thực tế.

Bảng 4.4: tóm tắt kết quả đánh giá trên tập validation

Thành phần	Chỉ số Giá trị
YOLOv8	mAP@0.5 = 0.85
YOLOv8	Precision = 0.88
YOLOv8	Recall = 0.82
CNN	Accuracy = 0.92
CNN	F1-score = 0.92
Pipeline	End-to-end = 0.85

Nhìn chung, kết quả trên tập validation cho thấy các mô hình trong hệ thống có khả năng tổng quát hóa tốt và đạt hiệu suất ổn định. Việc sử dụng tập validation cũng giúp điều chỉnh các tham số như ngưỡng confidence và các siêu tham số khác nhằm tối ưu hiệu quả của hệ thống trước khi đánh giá trên tập test.

4.5.2. Kết quả trên tập test

Sau khi hoàn tất quá trình huấn luyện và hiệu chỉnh mô hình dựa trên tập validation, hệ thống được đánh giá trên tập test độc lập nhằm đo lường khả năng tổng quát hóa trong điều kiện dữ liệu chưa từng xuất hiện trong quá trình huấn luyện. Đây là bước đánh giá quan trọng để phản ánh hiệu suất thực tế của mô hình khi triển khai.

Đối với mô hình YOLOv8, kết quả trên tập test cho thấy hiệu suất phát hiện vẫn duy trì ở mức cao. Cụ thể, giá trị mAP@0.5 đạt khoảng 0.83, giảm nhẹ so với

tập validation nhưng vẫn đảm bảo khả năng phát hiện chính xác các vùng nghi ngờ sâu răng. Precision đạt 0.80 và recall đạt 0.86, cho thấy mô hình vẫn giữ được sự cân bằng giữa việc phát hiện đúng và hạn chế dự đoán sai. Tổng số vùng phát hiện chính xác đạt 70 trên 80 vùng, phản ánh hiệu quả ổn định của mô hình.

Đối với mô hình CNN, kết quả phân loại trên tập test cũng cho thấy hiệu suất tốt với accuracy đạt khoảng 0.85. Các chỉ số precision và recall lần lượt đạt 0.84 và 0.87, trong khi F1-score đạt khoảng 0.85. Phân tích ma trận nhầm lẫn cho thấy độ chính xác trung bình giữa các lớp đạt khoảng 87%, với sai lệch chủ yếu xảy ra giữa các mức độ sâu răng liên kề, điều này phù hợp với tính chất khó phân biệt của dữ liệu.

Khi kết hợp hai mô hình trong pipeline hoàn chỉnh, hệ thống đạt độ chính xác end-to-end khoảng 0.80 trên tập test. So với kết quả trên tập validation, hiệu suất giảm nhẹ khoảng 2–3%, đây là hiện tượng bình thường do tập test chứa các dữ liệu chưa từng được sử dụng trong quá trình huấn luyện.

Bảng 4.5: so sánh kết quả giữa tập validation và tập test

Thành phần	Chỉ số Validation	Test
YOLOv8 mAP@0.5	0.85	0.83
CNN Accuracy	0.87	0.85
Pipeline End-to-end	0.82	0.80

Ngoài ra, thời gian suy luận của hệ thống trên tập test tương đương với tập validation, với thời gian xử lý trung bình dưới 1 giây cho mỗi ảnh, đáp ứng yêu cầu về hiệu năng trong ứng dụng thực tế.

Nhìn chung, kết quả trên tập test cho thấy hệ thống có khả năng tổng quát hóa tốt, hiệu suất ổn định và phù hợp để triển khai trong các bài toán hỗ trợ phát hiện và phân loại sâu răng trên ảnh X-quang nha khoa. Việc đánh giá trên tập test cũng cung cấp cơ sở để tiếp tục cải tiến mô hình trong các nghiên cứu tiếp theo.

4.5.3. Phân tích độ chính xác và sai sót

Dựa trên kết quả đánh giá trên tập validation và tập test, hệ thống đạt độ chính xác tổng thể trong khoảng từ 80% đến 85%, cho thấy hiệu suất ở mức khá tốt đối với một bài toán trong lĩnh vực ảnh y sinh. Mô hình YOLOv8 thể hiện khả năng phát hiện vùng sâu răng hiệu quả với giá trị mAP cao, trong khi mô hình CNN cho kết quả ổn định trong việc phân loại mức độ sâu răng. Sự kết hợp của hai mô hình trong pipeline giúp hệ thống đạt được hiệu quả tổng thể đáng kể.

Một trong những điểm mạnh của hệ thống là khả năng phát hiện chính xác các vùng nghi ngờ sâu răng với độ precision tương đối cao, giúp giảm thiểu các trường hợp dự đoán sai (false positive). Đồng thời, mô hình CNN đạt recall tốt, cho thấy khả năng nhận diện phần lớn các trường hợp sâu răng, đặc biệt là các tổn thương có kích thước trung bình và lớn. Ngoài ra, thời gian suy luận nhanh, dưới 1 giây cho mỗi ảnh, giúp hệ thống có tiềm năng ứng dụng trong các môi trường yêu cầu xử lý gần thời gian thực.

Tuy nhiên, hệ thống vẫn tồn tại một số sai sót đáng chú ý. Trước hết, một số trường hợp sâu răng có kích thước nhỏ hoặc có độ tương phản thấp trên ảnh X-quang có thể không được phát hiện (false negative), chiếm khoảng 10–15% số trường hợp. Bên cạnh đó, trong quá trình phân loại, mô hình CNN có thể nhầm lẫn giữa các mức độ liên kề như sâu nhẹ và sâu trung bình, với tỷ lệ khoảng 5–10%. Ngoài ra, một số vùng có đặc điểm hình ảnh tương tự sâu răng nhưng không phải tổn thương thực sự có thể bị phát hiện nhầm (false positive), mặc dù tỷ lệ này không cao.

Nguyên nhân của các sai sót trên có thể xuất phát từ nhiều yếu tố. Thứ nhất, sự mất cân bằng trong tập dữ liệu, đặc biệt là số lượng mẫu thuộc lớp sâu nặng còn hạn chế, khiến mô hình khó học đầy đủ đặc trưng của lớp này. Thứ hai, chất lượng ảnh X-quang không đồng đều, bao gồm nhiễu, mờ hoặc bị che khuất, gây khó khăn cho cả quá trình phát hiện và phân loại. Thứ ba, kiến trúc CNN sử dụng trong đề tài tương đối đơn giản, chưa khai thác hết tiềm năng của các mô hình học sâu hiện đại.

Phân tích chi tiết hơn cho thấy các sai sót chủ yếu tập trung ở các lớp có ranh giới phân biệt không rõ ràng. Ma trận nhầm lẫn cho thấy sự nhầm lẫn chủ yếu xảy ra giữa các mức độ liên kề, điều này phù hợp với đặc điểm thực tế của bệnh lý sâu răng. Ngoài ra, việc điều chỉnh các tham số như ngưỡng IoU trong mô hình YOLOv8 cũng ảnh hưởng đến kết quả, khi tăng ngưỡng có thể giảm số lượng false positive nhưng đồng thời làm tăng false negative.

Để cải thiện hiệu suất của hệ thống trong tương lai, một số hướng phát triển có thể được đề xuất. Thứ nhất, mở rộng và cân bằng tập dữ liệu nhằm giúp mô hình học được đầy đủ đặc trưng của các lớp. Thứ hai, áp dụng các kỹ thuật tăng cường dữ liệu nâng cao để cải thiện khả năng tổng quát hóa. Thứ ba, sử dụng các mô hình CNN tiên tiến hơn như ResNet hoặc EfficientNet nhằm nâng cao khả năng phân loại. Ngoài ra, việc kết hợp nhiều mô hình (ensemble) hoặc tích hợp thêm các phương pháp phân đoạn ảnh cũng có thể giúp cải thiện độ chính xác.

Tổng kết lại, hệ thống đã đạt được hiệu suất tốt trong phạm vi của một đề tài nghiên cứu và có tiềm năng ứng dụng trong thực tế. Tuy nhiên, vẫn cần tiếp tục cải tiến để nâng cao độ chính xác và độ tin cậy khi triển khai trong môi trường lâm sàng.

4.5.4. Confusion Matrix

Ma trận nhầm lẫn (Confusion Matrix) là một công cụ quan trọng trong việc đánh giá hiệu suất của mô hình học máy, cho phép so sánh giữa giá trị dự đoán và giá trị thực tế. Thông qua ma trận này, có thể phân tích chi tiết các trường hợp dự đoán đúng và sai, từ đó hiểu rõ hơn về hành vi của mô hình.

Đối với bài toán phát hiện đối tượng bằng mô hình YOLOv8, confusion matrix được xây dựng dựa trên hai lớp chính là có sâu răng và không có sâu răng. Kết quả cho thấy mô hình đạt tỷ lệ dự đoán đúng cao đối với các trường hợp có sâu răng, với tỷ lệ true positive khoảng 0.88. Tỷ lệ false negative (bỏ sót) vào khoảng 0.12, chủ yếu xảy ra ở các vùng tổn thương nhỏ hoặc khó quan sát. Đối với các vùng không có sâu răng, mô hình đạt tỷ lệ true negative khoảng 0.95, trong khi tỷ lệ false positive chỉ khoảng 0.05, cho thấy khả năng hạn chế dự đoán sai tương đối tốt.

Đối với mô hình CNN trong bài toán phân loại mức độ sâu răng, confusion matrix được xây dựng trên ba lớp gồm sâu nhẹ, sâu trung bình và sâu nặng. Kết quả cho thấy các giá trị trên đường chéo chính của ma trận (diagonal) chiếm tỷ lệ cao, phản ánh khả năng phân loại đúng của mô hình. Cụ thể, lớp sâu nhẹ có 45 mẫu được phân loại đúng trên tổng số 50 mẫu, lớp sâu trung bình có 40 mẫu đúng trên 45 mẫu, và lớp sâu nặng có 35 mẫu đúng trên 40 mẫu.

Các giá trị ngoài đường chéo (off-diagonal) thể hiện các trường hợp dự đoán sai. Phân tích cho thấy phần lớn sai sót xảy ra giữa các lớp có mức độ liên kề, đặc biệt là giữa sâu nhẹ và sâu trung bình. Điều này phù hợp với đặc điểm thực tế của dữ liệu, khi ranh giới giữa các mức độ sâu răng không rõ ràng và dễ gây nhầm lẫn.

Thông qua confusion matrix, có thể nhận thấy rằng mô hình CNN hoạt động tốt trong việc phân biệt các mức độ sâu răng, tuy nhiên vẫn cần cải thiện khả năng phân biệt giữa các lớp gần nhau. Ngoài ra, việc trực quan hóa confusion matrix dưới dạng heatmap có thể giúp dễ dàng quan sát và phân tích các xu hướng sai sót của mô hình.

Nhìn chung, confusion matrix cung cấp cái nhìn chi tiết về hiệu suất của cả hai mô hình YOLOv8 và CNN, từ đó hỗ trợ việc đánh giá và cải tiến hệ thống một cách hiệu quả hơn.

4.6 NHẬN XÉT MÔ HÌNH

Dựa trên toàn bộ quá trình xây dựng, huấn luyện và đánh giá, mô hình đề xuất sử dụng pipeline kết hợp giữa YOLOv8 và CNN đã cho thấy hiệu quả rõ rệt trong bài toán phát hiện và phân loại sâu răng trên ảnh X-quang nha khoa. Việc tách bài toán thành hai giai đoạn gồm phát hiện vị trí và phân loại mức độ giúp tận dụng được ưu điểm của từng mô hình, từ đó nâng cao hiệu suất tổng thể của hệ thống.

Về ưu điểm, mô hình YOLOv8 thể hiện khả năng phát hiện vùng sâu răng với độ chính xác cao, với giá trị mAP đạt khoảng 0.83 trên tập test, đồng thời đảm bảo tốc độ xử lý nhanh và ổn định. Mô hình CNN cũng đạt hiệu quả tốt trong việc phân loại mức độ sâu răng với độ chính xác khoảng 0.85, cho phép phân biệt tương đối rõ giữa các mức độ tổn thương. Khi kết hợp hai mô hình trong pipeline, hệ thống có khả năng hoạt động mượt mà với thời gian suy luận dưới 1 giây cho mỗi ảnh, đáp ứng yêu cầu về hiệu năng trong các ứng dụng thực tế.

Tuy nhiên, hệ thống vẫn tồn tại một số hạn chế. Một trong những vấn đề chính là sự nhầm lẫn giữa các mức độ sâu răng liên kề, đặc biệt là giữa sâu nhẹ và sâu trung bình, dẫn đến sự suy giảm nhẹ về precision và recall trong một số trường hợp. Ngoài ra, hệ thống vẫn gặp phải một tỷ lệ nhất định các trường hợp dự đoán sai, bao gồm cả false positive và false negative, chiếm khoảng 10–15% tổng số mẫu. Nguyên nhân chủ yếu đến từ sự mất cân bằng trong dữ liệu, chất lượng ảnh không đồng đều và việc sử dụng kiến trúc CNN tương đối đơn giản.

Xét tổng thể, mô hình đề xuất đã đạt được hiệu suất tốt trong phạm vi của một hệ thống nghiên cứu và có khả năng hỗ trợ hiệu quả cho bác sĩ trong quá trình phân tích ảnh X-quang nha khoa. So với phương pháp quan sát thủ công, hệ thống giúp tăng tính nhất quán, giảm thiểu sai sót và tiết kiệm thời gian xử lý. Tuy nhiên, để triển khai trong môi trường thực tế, cần tiếp tục cải thiện mô hình thông qua việc mở rộng dữ liệu, sử dụng các kiến trúc học sâu tiên tiến hơn và tối ưu hóa toàn bộ pipeline.

Nhìn chung, mô hình YOLOv8 kết hợp CNN là một hướng tiếp cận phù hợp và có tiềm năng phát triển, không chỉ trong bài toán phát hiện sâu răng mà còn có thể mở rộng sang các ứng dụng khác trong lĩnh vực phân tích ảnh y sinh.

CHƯƠNG 5

XÂY DỰNG HỆ THỐNG WEB

5.1 CẤU TRÚC DỰ ÁN

5.1.1. Tổ chức thư mục

Hệ thống được xây dựng theo mô hình kiến trúc client–server, trong đó backend đảm nhiệm xử lý dữ liệu và tích hợp các mô hình học sâu, còn frontend cung cấp giao diện tương tác cho người dùng. Việc tổ chức cấu trúc thư mục được thiết kế theo hướng tách biệt rõ ràng giữa các thành phần nhằm đảm bảo tính dễ bảo trì, mở rộng và phát triển trong tương lai.



Hình 5.1: Cấu trúc thư mục chính của dự án được tổ chức

Trong đó, thư mục backend chứa toàn bộ logic xử lý phía server, bao gồm việc xây dựng API bằng Flask, xử lý ảnh và tích hợp các mô hình học sâu. File `app.py` đóng vai trò là điểm khởi chạy chính của ứng dụng, trong khi `config.py` lưu trữ các tham số cấu hình như đường dẫn mô hình và ngưỡng xử lý. Thư mục `utils` bao gồm các module hỗ trợ như xử lý ảnh và thực hiện suy luận (inference) với các

mô hình YOLOv8 và CNN. Thư mục models lưu trữ các file trọng số của mô hình, còn uploads được sử dụng để lưu trữ tạm thời các ảnh đầu vào và kết quả đầu ra.

Thư mục frontend chịu trách nhiệm xây dựng giao diện người dùng, bao gồm file index.html làm trang chính, cùng với các file CSS và JavaScript để định dạng giao diện và xử lý tương tác. Thư mục assets chứa các tài nguyên tĩnh như hình ảnh phục vụ giao diện.


Ngoài ra, dự án còn bao gồm các file hỗ trợ như test_models.py và check_models.py phục vụ việc kiểm thử và xác thực mô hình, cũng như các script chạy hệ thống (run.sh, run.bat) giúp đơn giản hóa quá trình triển khai.

Cách tổ chức này mang lại nhiều lợi ích như tách biệt rõ ràng giữa các thành phần (separation of concerns), giúp dễ dàng bảo trì và mở rộng hệ thống. Đồng thời, cấu trúc module hóa cũng hỗ trợ việc phát triển thêm các chức năng mới hoặc tích hợp với các hệ thống khác trong tương lai.

Để đảm bảo quản lý mã nguồn hiệu quả, các thư mục không cần thiết như __pycache__ và uploads được loại trừ thông qua file .gitignore, đồng thời hệ thống được quản lý bằng Git để theo dõi và kiểm soát phiên bản.

5.1.2. Vai trò của các module

Để đảm bảo hệ thống hoạt động hiệu quả và dễ dàng bảo trì, dự án được tổ chức thành các module với chức năng và vai trò rõ ràng. Việc phân chia này giúp tách biệt các thành phần xử lý, tăng khả năng tái sử dụng và hỗ trợ mở rộng hệ thống trong tương lai.



Hình 5.2: Sơ đồ các module trong hệ thống

Trong phần backend, module `app.py` đóng vai trò là trung tâm của ứng dụng, chịu trách nhiệm khởi tạo server Flask, định nghĩa các API endpoint và xử lý các yêu cầu từ phía client. Các endpoint chính như `/api/analyze`, `/api/health` và `/api/test-models` được triển khai tại đây, đảm bảo việc giao tiếp giữa frontend và backend diễn ra thông suốt.

Module `config.py` được sử dụng để quản lý các tham số cấu hình của hệ thống, bao gồm đường dẫn tới các mô hình, thư mục lưu trữ ảnh, cũng như các ngưỡng xử lý như `confidence threshold` và `IOU threshold`. Việc tách riêng cấu hình giúp dễ dàng điều chỉnh mà không ảnh hưởng đến logic xử lý chính.

Trong thư mục `utils`, các chức năng hỗ trợ được tổ chức thành các module riêng biệt. Cụ thể, `image_processing.py` đảm nhiệm việc tiền xử lý ảnh như chuẩn hóa kích thước, chuyển đổi định dạng và vẽ bounding box lên ảnh kết quả. Module `inference.py` chịu trách nhiệm thực hiện suy luận với các mô hình học sâu, bao gồm việc gọi mô hình YOLOv8 để phát hiện vùng nghi ngờ và mô hình CNN để phân loại mức độ sâu răng, sau đó tổng hợp kết quả để trả về.

Thư mục `models` trong backend chứa các file trọng số của mô hình, được tải vào bộ nhớ khi hệ thống khởi động nhằm giảm thời gian xử lý trong quá trình suy luận. Thư mục `uploads` được sử dụng để lưu trữ tạm thời các ảnh đầu vào và ảnh kết quả, phục vụ cho quá trình xử lý và hiển thị.

Đối với phần frontend, file `index.html` đóng vai trò xây dựng cấu trúc giao diện chính, bao gồm khu vực tải ảnh và hiển thị kết quả. File `style.css` đảm nhiệm việc định dạng giao diện, đảm bảo tính trực quan và khả năng hiển thị tốt trên nhiều thiết bị. Trong khi đó, `main.js` xử lý các sự kiện tương tác với người dùng, thực hiện gọi API tới backend và hiển thị kết quả phân tích lên giao diện. Thư mục `assets` chứa các tài nguyên tĩnh như hình ảnh và biểu tượng phục vụ giao diện.

Ngoài ra, hệ thống còn bao gồm các module hỗ trợ như `test_models.py` và `check_models.py` phục vụ việc kiểm thử và xác thực hoạt động của mô hình. Các script như `run.sh` hoặc `run.bat` giúp đơn giản hóa quá trình khởi chạy hệ thống, trong khi file `requirements.txt` quản lý danh sách các thư viện cần thiết. File `README.md` cung cấp tài liệu hướng dẫn cài đặt và sử dụng hệ thống.

Việc phân chia rõ ràng vai trò của các module giúp hệ thống đạt được tính tách biệt (separation of concerns), dễ dàng bảo trì và nâng cấp. Đồng thời, cấu trúc này cũng tạo điều kiện thuận lợi cho việc mở rộng hệ thống, chẳng hạn như triển khai dưới dạng microservices hoặc tích hợp thêm các mô hình học sâu trong tương lai.

5.2 BACKEND (FLASK)

5.2.1. Cấu hình Flask

Trong hệ thống web phát hiện sâu răng trên ảnh X-quang nha khoa, backend được xây dựng dựa trên framework Flask – một micro-framework của Python có ưu điểm nhẹ, linh hoạt và dễ triển khai. Việc cấu hình Flask đóng vai trò quan trọng trong việc thiết lập môi trường hoạt động ổn định và đảm bảo khả năng tích hợp với các thành phần khác của hệ thống.

Ứng dụng Flask được khởi tạo thông qua file `app.py`, đóng vai trò là điểm khởi chạy chính của hệ thống backend. Các tham số cấu hình được tách riêng trong file `config.py`, bao gồm đường dẫn đến các mô hình học sâu (YOLOv8 và CNN), thư mục lưu trữ ảnh upload, cũng như các ngưỡng xử lý như confidence threshold và IOU threshold. Cách tổ chức này giúp tăng tính linh hoạt và thuận tiện trong việc thay đổi cấu hình giữa các môi trường phát triển và triển khai thực tế.

Để hỗ trợ giao tiếp giữa frontend và backend, hệ thống được cấu hình CORS (Cross-Origin Resource Sharing), cho phép các yêu cầu từ phía client được thực hiện một cách an toàn. Bên cạnh đó, các thiết lập liên quan đến việc upload file cũng được định nghĩa rõ ràng, bao gồm kích thước tối đa của file, định dạng ảnh cho phép (JPEG, PNG) và thư mục lưu trữ tạm thời. Điều này giúp đảm bảo tính bảo mật và ổn định trong quá trình xử lý dữ liệu đầu vào.

Hệ thống cũng được cấu hình để xử lý lỗi một cách nhất quán thông qua các cơ chế bắt lỗi (error handlers), với các mã lỗi phổ biến như 400 (Bad Request) và 500 (Internal Server Error). Các thông báo lỗi được chuẩn hóa giúp người dùng dễ dàng nhận biết vấn đề, đồng thời hỗ trợ quá trình kiểm thử và gỡ lỗi hệ thống.

Trong quá trình phát triển, ứng dụng được chạy ở chế độ debug, cho phép tự động tải lại khi có thay đổi trong mã nguồn và cung cấp thông tin chi tiết khi xảy ra lỗi. Đối với môi trường triển khai thực tế, hệ thống có thể được vận hành thông qua các web server như Gunicorn nhằm nâng cao khả năng xử lý đồng thời và tăng tính ổn định.

Nhìn chung, cấu hình Flask trong hệ thống được thiết kế theo hướng đơn giản nhưng hiệu quả, đảm bảo khả năng tích hợp với các mô hình học sâu, hỗ trợ xử lý ảnh và cung cấp API ổn định cho frontend. Đây là nền tảng quan trọng giúp hệ thống hoạt động trơn tru và có khả năng mở rộng trong tương lai.

5.2.2. Các API endpoint chính

Trong hệ thống backend sử dụng Flask, các API endpoint được thiết kế theo kiến trúc RESTful nhằm phục vụ các chức năng cốt lõi của hệ thống phát hiện và phân loại sâu răng trên ảnh X-quang nha khoa. Các endpoint sử dụng các phương

thức HTTP phù hợp và trả về dữ liệu dưới dạng JSON, giúp dễ dàng tích hợp với frontend cũng như các hệ thống khác trong tương lai.

Endpoint quan trọng nhất của hệ thống là `/api/analyze`, sử dụng phương thức POST để tiếp nhận ảnh X-quang từ phía người dùng. Khi nhận được yêu cầu, backend sẽ thực hiện toàn bộ pipeline xử lý, bao gồm kiểm tra định dạng và kích thước file, lưu trữ tạm thời, tiền xử lý ảnh, phát hiện vùng nghi ngờ sâu răng bằng mô hình YOLOv8 và phân loại mức độ sâu bằng mô hình CNN. Sau đó, kết quả được tổng hợp và trả về dưới dạng JSON, bao gồm thông tin về các bounding box, mức độ sâu răng, độ tin cậy, thống kê tổng quan và đường dẫn tới ảnh kết quả đã được gắn nhãn (annotated).

Endpoint thứ hai là `/api/health`, sử dụng phương thức GET để kiểm tra trạng thái hoạt động của hệ thống. Endpoint này trả về các thông tin cơ bản như trạng thái server, tình trạng tải mô hình và thời gian hoạt động (uptime), nhằm phục vụ mục đích giám sát và đảm bảo hệ thống luôn sẵn sàng xử lý yêu cầu.

Endpoint `/api/test-models`, cũng sử dụng phương thức GET, được thiết kế để kiểm tra nhanh hoạt động của các mô hình học sâu. Hệ thống sẽ thực hiện một phép suy luận mẫu trên dữ liệu kiểm thử và trả về kết quả, bao gồm trạng thái của mô hình YOLOv8 và CNN cũng như thời gian xử lý, giúp xác nhận rằng các mô hình đã được tải và hoạt động chính xác.

Tất cả các endpoint đều được thiết kế với cơ chế xử lý lỗi nhất quán, trả về các mã trạng thái HTTP phù hợp như 200 (thành công), 400 (yêu cầu không hợp lệ) và 500 (lỗi hệ thống), kèm theo thông báo rõ ràng. Điều này giúp tăng tính ổn định và hỗ trợ quá trình kiểm thử hệ thống.

Nhìn chung, việc thiết kế các API endpoint theo chuẩn RESTful không chỉ giúp hệ thống hoạt động hiệu quả mà còn tạo điều kiện thuận lợi cho việc mở rộng và tích hợp trong các ứng dụng thực tế.

5.2.3. Tích hợp mô hình ML

Trong hệ thống backend sử dụng Flask, việc tích hợp các mô hình học sâu đóng vai trò cốt lõi trong việc thực hiện chức năng phát hiện và phân loại sâu răng trên ảnh X-quang nha khoa. Hai mô hình chính được sử dụng trong hệ thống là YOLOv8 cho bài toán phát hiện đối tượng và mạng nơ-ron tích chập (CNN) cho bài toán phân loại mức độ sâu răng.

Để tối ưu hiệu năng, các mô hình được tải một lần duy nhất khi hệ thống khởi động, thay vì tải lại trong mỗi yêu cầu. Cụ thể, mô hình YOLOv8 được tải từ file trọng số `best.pt` trong thư mục `models` thông qua thư viện `Ultralytics`, trong khi mô hình CNN được tải từ file `cnn_caries_model.h5` bằng `TensorFlow/Keras`. Việc

khởi tạo này được thực hiện trong giai đoạn khởi động ứng dụng nhằm đảm bảo các mô hình luôn sẵn sàng phục vụ cho quá trình suy luận.

Khi endpoint `/api/analyze` được gọi, hệ thống sẽ kích hoạt pipeline xử lý thông qua module `utils/inference.py`. Đầu tiên, ảnh đầu vào được tiền xử lý và đưa vào mô hình YOLOv8 để phát hiện các vùng nghi ngờ sâu răng dưới dạng các bounding box. Sau đó, các vùng ảnh (ROI) tương ứng được trích xuất và đưa vào mô hình CNN để phân loại mức độ sâu răng. Kết quả từ hai mô hình được kết hợp lại để tạo thành đầu ra cuối cùng.

Kết quả trả về được chuẩn hóa dưới dạng JSON, bao gồm các thông tin như tọa độ bounding box, độ tin cậy của YOLO, nhãn phân loại từ CNN và các thông kê tổng quan. Đồng thời, hệ thống áp dụng các ngưỡng confidence được định nghĩa trong file `config.py` để loại bỏ các dự đoán có độ tin cậy thấp, từ đó nâng cao độ chính xác của kết quả.

Ngoài ra, hệ thống cũng được thiết kế với cơ chế xử lý lỗi nhằm đảm bảo tính ổn định trong quá trình vận hành. Các trường hợp như mô hình không được tải thành công hoặc lỗi trong quá trình suy luận đều được xử lý và trả về thông báo phù hợp cho phía client.

Nhìn chung, việc tích hợp các mô hình học sâu vào backend giúp hệ thống đóng vai trò như một cầu nối giữa giao diện người dùng và các thuật toán trí tuệ nhân tạo. Pipeline xử lý được thực hiện một cách tự động, mượt mà và hiệu quả, góp phần nâng cao khả năng ứng dụng thực tế của hệ thống.

5.2.4. Xử lý file ảnh đầu vào

Trong hệ thống backend sử dụng Flask, việc xử lý file ảnh đầu vào là bước khởi đầu quan trọng trong pipeline phân tích, nhằm đảm bảo dữ liệu được kiểm tra, chuẩn hóa và sẵn sàng trước khi đưa vào các mô hình học sâu.

Khi nhận được yêu cầu POST từ endpoint `/api/analyze`, hệ thống tiến hành kiểm tra tính hợp lệ của file ảnh. Cụ thể, backend xác nhận sự tồn tại của file, kiểm tra định dạng cho phép (JPEG, PNG) và giới hạn kích thước không vượt quá 5MB. Trong trường hợp file không hợp lệ, hệ thống trả về mã lỗi 400 (Bad Request) kèm theo thông báo chi tiết, giúp người dùng dễ dàng nhận biết và khắc phục.

Đối với các file hợp lệ, hệ thống thực hiện lưu trữ tạm thời trong thư mục `uploads/input`. Để tránh trùng lặp và đảm bảo tính duy nhất, tên file được tạo bằng cách sử dụng UUID kết hợp với phần mở rộng của file gốc. Sau đó, ảnh được đọc vào bộ nhớ bằng các thư viện xử lý ảnh như OpenCV hoặc PIL để phục vụ cho các bước xử lý tiếp theo.

Ảnh sau khi được đọc sẽ trải qua quá trình tiền xử lý, bao gồm việc thay đổi kích thước về kích thước chuẩn (ví dụ 640×640 pixel) phù hợp với mô hình

YOLOv8, chuẩn hóa giá trị pixel về khoảng $[0,1]$ bằng cách chia cho 255, và chuyển đổi định dạng dữ liệu nếu cần thiết để phù hợp với đầu vào của mô hình. Các bước xử lý này được đóng gói trong module `utils/image_processing.py` nhằm đảm bảo tính tái sử dụng và tách biệt với logic chính của hệ thống.

Sau khi hoàn tất quá trình suy luận, file ảnh đầu vào sẽ được xóa khỏi hệ thống hoặc được quản lý theo cơ chế thời gian sống (TTL – Time To Live) để tránh việc tích lũy dữ liệu không cần thiết và tiết kiệm tài nguyên lưu trữ.

Nhìn chung, quy trình xử lý ảnh đầu vào được thiết kế chặt chẽ nhằm đảm bảo tính an toàn, hiệu quả và phù hợp với yêu cầu của hệ thống, đồng thời tạo nền tảng ổn định cho các bước xử lý tiếp theo trong pipeline.

5.2.5. Kiểm thử API bằng Postman

Để đảm bảo các API trong hệ thống backend hoạt động chính xác và ổn định, quá trình kiểm thử được thay bằng công cụ Postman – một ứng dụng phổ biến trong việc kiểm tra và đánh giá các dịch vụ RESTful API. Việc kiểm thử giúp xác minh tính đúng đắn của dữ liệu trả về, đồng thời kiểm tra khả năng xử lý lỗi của hệ thống.

Trước tiên, hệ thống backend được khởi động trên địa chỉ `http://localhost:5000`. Trong Postman, một yêu cầu mới được tạo với phương thức POST và endpoint `/api/analyze`. Phần nội dung yêu cầu (Body) được thiết lập dưới dạng form-data, trong đó key `image` được chọn với kiểu dữ liệu là file và gán một ảnh X-quang nha khoa làm dữ liệu đầu vào.

Sau khi gửi yêu cầu, hệ thống trả về phản hồi dưới dạng JSON. Trong trường hợp thành công, mã trạng thái HTTP là 200 (OK), và dữ liệu trả về bao gồm các thông tin quan trọng như danh sách các vùng phát hiện (detections), trong đó mỗi phần tử chứa tọa độ bounding box, độ tin cậy của mô hình YOLO và nhãn phân loại từ CNN. Ngoài ra, phần summary cung cấp thông kê tổng quan về số lượng vùng sâu răng theo từng mức độ, và trường `image_url` chứa đường dẫn đến ảnh kết quả đã được gán nhãn.

Ngược lại, trong các trường hợp dữ liệu đầu vào không hợp lệ (ví dụ sai định dạng hoặc vượt quá kích thước cho phép), hệ thống trả về mã lỗi 400 (Bad Request) kèm theo thông báo chi tiết. Điều này giúp người dùng dễ dàng nhận biết và xử lý lỗi.

Quá trình kiểm thử bằng Postman cho thấy các API hoạt động ổn định, trả về dữ liệu đúng định dạng và xử lý lỗi một cách nhất quán. Đây là bước quan trọng trước khi tích hợp backend với frontend, đảm bảo toàn bộ hệ thống vận hành trơn tru và đáng tin cậy trong môi trường thực tế.

5.3 FRONTEND

5.3.1. Trang chủ

Trong hệ thống phát hiện sâu răng trên ảnh X-quang nha khoa, phần frontend được xây dựng bằng các công nghệ web cơ bản bao gồm HTML, CSS và JavaScript thuần. Việc lựa chọn các công nghệ này nhằm đảm bảo hệ thống có giao diện nhẹ, dễ triển khai và tương thích tốt với nhiều trình duyệt khác nhau. Giao diện được thiết kế theo hướng đơn giản, trực quan, giúp người dùng dễ dàng thao tác mà không cần kiến thức kỹ thuật chuyên sâu.

Trang chủ của hệ thống, được xây dựng trong file index.html, đóng vai trò là điểm truy cập chính, nơi người dùng thực hiện toàn bộ quá trình tương tác với hệ thống. Phần đầu trang (header) hiển thị tiêu đề “Hệ thống phát hiện sâu răng trên ảnh X-quang” nhằm cung cấp ngữ cảnh rõ ràng cho người dùng, đồng thời có thể tích hợp logo để tăng tính nhận diện.

Phần nội dung chính của giao diện là khu vực tải ảnh, bao gồm một form cho phép người dùng lựa chọn file ảnh X-quang từ máy tính cá nhân. Thành phần input được thiết lập với thuộc tính `accept=".jpg,.png,.jpeg"` nhằm giới hạn định dạng file hợp lệ. Ngay sau khi người dùng chọn ảnh, hệ thống sẽ hiển thị bản xem trước (preview) thông qua thẻ `img` hoặc `canvas`, giúp người dùng kiểm tra lại dữ liệu trước khi gửi đi phân tích.

Khi người dùng nhấn nút “Upload & Analyze”, một yêu cầu sẽ được gửi tới backend thông qua API `/api/analyze`. Trong quá trình xử lý, giao diện hiển thị biểu tượng loading (spinner) và tạm thời vô hiệu hóa nút gửi để tránh việc gửi nhiều yêu cầu liên tiếp, từ đó đảm bảo hiệu năng hệ thống.

Sau khi nhận được kết quả từ backend, giao diện sẽ hiển thị ảnh kết quả với các bounding box được vẽ chồng lên vùng phát hiện sâu răng. Màu sắc của các bounding box được phân biệt theo mức độ tổn thương (nhẹ, trung bình, nặng), giúp người dùng dễ dàng quan sát. Đồng thời, một bảng thống kê cũng được hiển thị, cung cấp thông tin về tổng số vùng sâu răng và phân loại theo từng mức độ.

Ngoài ra, hệ thống còn hỗ trợ chức năng tải ảnh kết quả đã được chú thích, giúp người dùng lưu trữ hoặc sử dụng cho mục đích tham khảo. Phần cuối trang (footer) cung cấp thông tin về tác giả, phiên bản hệ thống và các thông tin liên quan khác.

Về mặt thiết kế, giao diện sử dụng các kỹ thuật như Flexbox để xây dựng bố cục linh hoạt và responsive, đảm bảo khả năng hiển thị tốt trên nhiều thiết bị khác nhau như máy tính, máy tính bảng và điện thoại di động. Nhờ đó, hệ thống mang lại trải nghiệm người dùng mượt mà và thân thiện.

5.3.2. Phần upload ảnh

Trong hệ thống frontend, chức năng upload ảnh đóng vai trò là điểm tương tác đầu tiên giữa người dùng và hệ thống, đồng thời là bước khởi đầu của toàn bộ pipeline phân tích sâu răng. Do đó, thành phần này được thiết kế theo hướng đơn giản, trực quan và cung cấp phản hồi nhanh chóng nhằm nâng cao trải nghiệm người dùng.

Người dùng có thể lựa chọn ảnh X-quang nha khoa thông qua hai phương thức chính: chọn file trực tiếp từ thiết bị thông qua thành phần input type="file", hoặc kéo và thả (drag-and-drop) ảnh vào khu vực upload. Thành phần input được cấu hình chỉ chấp nhận các định dạng phổ biến như JPEG và PNG, đồng thời giới hạn kích thước tối đa của file là 5MB nhằm đảm bảo hiệu năng và tính an toàn của hệ thống.

Ngay sau khi người dùng chọn ảnh, hệ thống sử dụng JavaScript để thực hiện kiểm tra dữ liệu đầu vào. Các điều kiện như định dạng file và kích thước sẽ được xác thực ngay trên phía client. Trong trường hợp dữ liệu không hợp lệ, hệ thống sẽ hiển thị thông báo lỗi rõ ràng và thân thiện, giúp người dùng dễ dàng điều chỉnh.

Khi ảnh hợp lệ, giao diện sẽ hiển thị bản xem trước (preview) thông qua thẻ img hoặc canvas với kích thước phù hợp, cho phép người dùng kiểm tra lại nội dung trước khi thực hiện phân tích. Đồng thời, nút chức năng “Upload & Analyze” được kích hoạt để cho phép gửi dữ liệu lên backend.

Khi người dùng nhấn nút này, hệ thống sẽ tạo một đối tượng FormData chứa file ảnh và gửi yêu cầu POST đến endpoint /api/analyze. Trong quá trình xử lý, giao diện hiển thị biểu tượng loading kèm theo thông báo “Đang phân tích...”, đồng thời vô hiệu hóa các thao tác tương tác để tránh gửi nhiều yêu cầu liên tiếp.

Sau khi nhận được phản hồi từ backend, hệ thống sẽ ẩn trạng thái loading và hiển thị kết quả phân tích hoặc thông báo lỗi tương ứng. Ngoài ra, giao diện còn cung cấp nút “Clear” cho phép người dùng xóa ảnh đã chọn và kết quả hiện tại, từ đó dễ dàng thực hiện lại quá trình với dữ liệu mới.

Về mặt thiết kế, chức năng upload được xây dựng theo hướng responsive, đảm bảo hiển thị tốt trên nhiều thiết bị khác nhau. Trên các thiết bị di động, bố cục giao diện sẽ được điều chỉnh linh hoạt để phù hợp với kích thước màn hình nhỏ, giúp duy trì trải nghiệm người dùng nhất quán.

5.3.3. Hiển thị kết quả phân tích

Chức năng hiển thị kết quả phân tích đóng vai trò quan trọng trong việc cung cấp thông tin trực quan cho người dùng sau khi hệ thống hoàn tất quá trình xử lý ảnh X-quang nha khoa. Kết quả được cập nhật động dựa trên dữ liệu JSON trả về từ backend, đảm bảo tính chính xác và phản hồi theo thời gian thực.

Khi hệ thống nhận được phản hồi thành công từ endpoint `/api/analyze`, khu vực hiển thị kết quả sẽ được kích hoạt. Thành phần chính là hình ảnh X-quang đã được xử lý, trong đó các vùng nghi ngờ sâu răng được đánh dấu bằng các bounding box vẽ chồng lên ảnh gốc. Màu sắc của các bounding box được phân biệt theo mức độ tổn thương, cụ thể: màu xanh lá cây biểu thị mức độ nhẹ, màu vàng biểu thị mức độ trung bình và màu đỏ biểu thị mức độ nặng. Bên cạnh mỗi vùng phát hiện, hệ thống hiển thị nhãn phân loại cùng với giá trị độ tin cậy (confidence score), giúp người dùng dễ dàng đánh giá mức độ chính xác của kết quả.

Bên dưới hình ảnh, hệ thống cung cấp một bảng thống kê tổng quan, bao gồm tổng số vùng sâu răng được phát hiện và phân loại chi tiết theo từng mức độ. Thông tin này giúp người dùng nhanh chóng nắm bắt tình trạng tổng thể mà không cần quan sát từng vùng riêng lẻ.

Ngoài ra, hệ thống còn hiển thị danh sách chi tiết các vùng phát hiện dưới dạng bảng hoặc danh sách. Mỗi phần tử trong danh sách bao gồm các thông tin như mã định danh (box ID), tọa độ bounding box ($x1, y1, x2, y2$), mức độ sâu răng, độ tin cậy của mô hình YOLOv8 và độ tin cậy của mô hình CNN. Điều này hỗ trợ người dùng có nhu cầu phân tích sâu hơn hoặc kiểm tra từng kết quả cụ thể.

Hệ thống cũng cung cấp chức năng tải xuống ảnh kết quả đã được chú thích, cho phép người dùng lưu trữ hoặc sử dụng trong các mục đích tham khảo và báo cáo. Trong trường hợp xảy ra lỗi từ phía backend, khu vực hiển thị kết quả sẽ chuyển sang trạng thái thông báo lỗi với nội dung rõ ràng, giúp người dùng nhận biết và xử lý vấn đề kịp thời.

Nhìn chung, chức năng hiển thị kết quả được thiết kế theo hướng trực quan, đầy đủ thông tin và dễ sử dụng, góp phần nâng cao hiệu quả tương tác giữa người dùng và hệ thống.

5.3.4. Xuất báo cáo PDF

Nhằm nâng cao giá trị ứng dụng và khả năng lưu trữ kết quả phân tích, hệ thống được tích hợp chức năng xuất báo cáo dưới định dạng PDF. Tính năng này cho phép người dùng lưu lại toàn bộ thông tin phân tích một cách có hệ thống, phục vụ cho việc theo dõi, chia sẻ hoặc sử dụng trong các mục đích chuyên môn.

Khi người dùng lựa chọn chức năng “Xuất PDF”, hệ thống frontend sẽ tiến hành thu thập toàn bộ dữ liệu liên quan đến kết quả phân tích. Các thông tin này bao gồm hình ảnh X-quang gốc, hình ảnh đã được annotate với các bounding box, bảng thống kê tổng quan (tổng số vùng sâu răng và phân loại theo mức độ), danh sách chi tiết các vùng phát hiện kèm theo độ tin cậy của từng mô hình, cũng như thời điểm thực hiện phân tích.

Quá trình tạo file PDF được thực hiện thông qua các thư viện JavaScript như jsPDF hoặc html2pdf, cho phép chuyển đổi nội dung HTML và canvas trên giao diện thành tài liệu PDF hoàn chỉnh. Báo cáo được thiết kế với bố cục rõ ràng, bao gồm phần tiêu đề (header) chứa tên hệ thống, logo (nếu có) và thông tin thời gian.

Nội dung chính của báo cáo được chia thành hai phần. Phần thứ nhất trình bày hình ảnh trực quan, trong đó ảnh X-quang gốc và ảnh đã được đánh dấu được hiển thị song song nhằm hỗ trợ so sánh. Phần thứ hai là bảng thống kê chi tiết, liệt kê đầy đủ các vùng phát hiện cùng với các thông tin liên quan như tọa độ, mức độ tổn thương và độ tin cậy.

Sau khi hoàn tất quá trình tạo báo cáo, hệ thống tự động tải file PDF về thiết bị của người dùng với tên file được định dạng theo thời gian, ví dụ: report_YYYY-MM-DD_HH-MM-SS.pdf. Điều này giúp người dùng dễ dàng quản lý và tra cứu các báo cáo đã tạo.


Chức năng xuất PDF không chỉ giúp giảm thiểu thao tác thủ công trong việc ghi nhận kết quả, mà còn tạo ra tài liệu có tính chuẩn hóa, hỗ trợ hiệu quả cho việc lưu trữ hồ sơ và trao đổi thông tin với bác sĩ hoặc chuyên gia trong lĩnh vực nha khoa. Đây là một bước tiến quan trọng trong việc hướng tới xây dựng hệ thống hỗ trợ chẩn đoán hiện đại và có tính ứng dụng cao.

5.4 MINH HỌA GIAO DIỆN

5.4.1. Ảnh chụp các màn hình chính

Phần minh họa giao diện cung cấp cái nhìn trực quan về các màn hình chính của ứng dụng web phát hiện sâu răng “AI Dental”. Các hình ảnh minh họa này giúp người đọc dễ dàng hình dung trải nghiệm người dùng cũng như cách thức hệ thống vận hành trong thực tế.

Giao diện đầu tiên là giao diện trang chủ (Hero Section), đóng vai trò giới thiệu tổng quan về hệ thống. Phía trên là thanh điều hướng (navbar) bao gồm logo “AI Dental” với biểu tượng chiếc răng, cùng các mục menu như “Trang Chủ”, “Phân Tích”, “Về Chúng Tôi” và “Liên Hệ”. Phần nội dung chính hiển thị tiêu đề nổi bật “Chẩn Đoán Sâu Răng Tự Động”, kèm theo dòng mô tả “Sử dụng Trí Tuệ Nhân Tạo và Công Nghệ Machine Learning”. Ngoài ra, nút “Bắt Đầu Phân Tích” được thiết kế nổi bật với màu xanh dương, cho phép người dùng chuyển nhanh đến khu vực phân tích.



Hình 5.3: Giao diện trang chủ

Giao diện thứ hai là khu vực phân tích (Analysis Section), được hiển thị khi người dùng cuộn trang hoặc nhấn nút điều hướng. Phần này bao gồm tiêu đề “Phân Tích Ảnh Răng” kèm biểu tượng minh họa. Bên dưới là form upload ảnh, cho phép người dùng chọn hoặc kéo thả ảnh X-quang. Nút “Upload & Analyze” ban đầu được vô hiệu hóa cho đến khi có dữ liệu hợp lệ.

Phân Tích Ảnh Răng

Thông Tin Bệnh Nhân

Họ và Tên:

Ngày Sinh:

Giới Tính:

Địa Chỉ:

Tải Ảnh Lên

Kéo thả ảnh hoặc click để chọn

PNG, JPG, JPEG, GIF (Tối đa 16MB)

Ảnh đã upload

Chọn ảnh sẽ hiển thị ở đây.


Hình 5.4: Giao diện upload ảnh

Giao diện thứ ba hệ thống được thiết kế theo phong cách hiện đại, trực quan và thân thiện với người dùng, nhằm giúp người dùng dễ dàng tiếp cận và sử dụng các chức năng chính của hệ thống.

Như minh họa trong hình, phần trung tâm của giao diện hiển thị tiêu đề “Tính năng chính”, bên dưới là các khối chức năng được bố trí theo dạng lưới gồm nhiều thẻ (card) trực quan. Mỗi thẻ đại diện cho một chức năng cụ thể của hệ thống, bao gồm biểu tượng minh họa, tiêu đề và mô tả ngắn gọn.

Các chức năng chính được thể hiện trên giao diện bao gồm: sử dụng trí tuệ nhân tạo (AI) với mô hình CNN và YOLO để phát hiện và phân loại sâu răng, xử lý dữ liệu nhanh chóng với khả năng phân tích trong thời gian ngắn, và cung cấp thông kê chi tiết về tình trạng răng miệng. Ngoài ra, hệ thống còn đảm bảo bảo mật dữ liệu người dùng, hỗ trợ thiết kế responsive tương thích với nhiều thiết bị khác nhau như máy tính và điện thoại, cũng như cho phép xuất báo cáo kết quả dưới dạng file ảnh hoặc PDF.

Về mặt thiết kế, giao diện sử dụng tông màu sáng kết hợp với các biểu tượng trực quan giúp tăng khả năng nhận diện chức năng. Bố cục dạng lưới giúp phân chia nội dung rõ ràng, tạo cảm giác gọn gàng và dễ quan sát. Các thành phần được căn chỉnh cân đối, khoảng cách hợp lý, giúp nâng cao trải nghiệm người dùng.



Hình 5.5: Giao diện các chức năng chính của hệ thống

Giao diện thứ tư được thiết kế nhằm cung cấp thông tin tổng quan về công nghệ sử dụng và cách thức hoạt động của hệ thống phân tích sâu răng trên ảnh X-

quang nha khoa. Giao diện được bố cục theo dạng hai cột song song, giúp người dùng dễ dàng theo dõi và nắm bắt thông tin một cách trực quan.

Ở phía bên trái, phần “Công nghệ sử dụng” trình bày các thành phần kỹ thuật chính của hệ thống. Cụ thể, frontend được xây dựng bằng HTML5, CSS3 và JavaScript, trong khi backend sử dụng Python với framework Flask. Ngoài ra, hệ thống áp dụng các mô hình học sâu như CNN và YOLOv8 để thực hiện phát hiện và phân loại sâu răng. Các thư viện xử lý ảnh như OpenCV và Pillow cũng được sử dụng nhằm hỗ trợ quá trình tiền xử lý và xử lý dữ liệu hình ảnh.

Ở phía bên phải, phần “Cách hoạt động” mô tả quy trình xử lý của hệ thống theo từng bước. Quá trình bắt đầu từ việc người dùng tải ảnh X-quang lên hệ thống. Sau đó, mô hình YOLO thực hiện phát hiện vị trí các vùng nghi ngờ sâu răng trên ảnh. Tiếp theo, các vùng ảnh này được đưa vào mô hình CNN để phân loại mức độ tổn thương. Cuối cùng, hệ thống tổng hợp kết quả và xuất báo cáo phân tích cho người dùng.

Về mặt thiết kế, giao diện sử dụng tông màu sáng kết hợp với các khối nội dung dạng thẻ (card) được bo góc nhẹ, tạo cảm giác hiện đại và thân thiện. Các mục thông tin được trình bày rõ ràng với tiêu đề nổi bật và nội dung ngắn gọn, giúp người dùng dễ dàng tiếp cận và hiểu được cách hệ thống hoạt động.

Nhìn chung, giao diện không chỉ cung cấp thông tin kỹ thuật một cách đầy đủ mà còn giúp người dùng hiểu rõ quy trình xử lý của hệ thống, từ đó nâng cao trải nghiệm và mức độ tin cậy khi sử dụng.



Hình 5.6: Giao diện “Về chúng tôi” của hệ thống

Giao diện thứ năm được thiết kế nhằm cung cấp thông tin liên lạc cần thiết, giúp người dùng dễ dàng kết nối với nhóm phát triển hoặc nhận hỗ trợ trong quá


trình sử dụng hệ thống. Giao diện được bố trí đơn giản, rõ ràng, tập trung vào việc hiển thị các thông tin liên hệ quan trọng.

Như minh họa trong hình, phần tiêu đề “Liên hệ & Hỗ trợ” được đặt ở vị trí trung tâm phía trên, tạo điểm nhấn và giúp người dùng dễ dàng nhận biết chức năng của trang. Bên dưới là các khối thông tin được trình bày theo dạng thẻ (card), mỗi thẻ tương ứng với một phương thức liên hệ cụ thể.

Cụ thể, hệ thống cung cấp ba hình thức liên hệ chính bao gồm email, số điện thoại và địa chỉ. Thông tin email cho phép người dùng gửi yêu cầu hỗ trợ trực tuyến, số điện thoại hỗ trợ liên hệ trực tiếp, và địa chỉ cung cấp thông tin về đơn vị phát triển hệ thống. Mỗi mục đều được minh họa bằng biểu tượng trực quan, giúp tăng khả năng nhận diện và cải thiện trải nghiệm người dùng.

Về mặt thiết kế, giao diện sử dụng tông màu sáng, kết hợp với các khối nội dung bo góc nhẹ và khoảng cách hợp lý giữa các thành phần. Các biểu tượng được sử dụng đồng nhất về phong cách, góp phần tạo nên sự chuyên nghiệp và nhất quán trong toàn bộ hệ thống.

Nhìn chung, giao diện “Liên hệ & Hỗ trợ” không chỉ đảm bảo cung cấp đầy đủ thông tin liên lạc mà còn được thiết kế thân thiện, dễ sử dụng, góp phần nâng cao mức độ hỗ trợ và tương tác giữa người dùng và hệ thống.



Hình 5.7. Giao diện “Liên hệ & Hỗ trợ” của hệ thống

Giao diện thứ sáu là giao diện hiển thị kết quả phân tích. Hình ảnh X-quang gốc được hiển thị ở phía trên, bên dưới là hình ảnh đã được annotate với các bounding box đánh dấu vùng nghi ngờ sâu răng. Màu sắc của các bounding box được phân biệt theo mức độ tổn thương. Bên cạnh đó là bảng thống kê chi tiết về số lượng vùng sâu răng và phân loại theo từng mức độ. Ở cuối giao diện, hệ thống cung cấp các chức năng bổ sung như “Tải Báo Cáo PDF” và “Phân Tích Ảnh Khác”.

Kết Quả Phân Tích

Họ và tên: Võ Nguyễn | Giới tính: Nam | Ngày sinh: 30/04/2004

Địa chỉ: Cà mau

Ngày phân tích: 21/03/2026 21:52:03

Ảnh gốc

Ngày sinh: 30/04/2004

Ảnh phân tích

Không phát hiện răng trong ảnh

⚠️ Khuyến Cáo

Vui lòng tải lên ảnh răng để phân tích

Tải PDF

Phân Tích Lại

BÁO CÁO PHÂN TÍCH SÂU RĂNG

Họ và tên: Võ Nguyễn
 Ngày sinh: 2004-04-30
 Giới tính: Nam
 Địa chỉ: Cà mau
 Ngày phân tích: 21/03/2026 22:04:13

Kết quả

- Tổng số răng: 3
- Số răng bị sâu: 3

Hình 5.8. Giao diện hiển thị kết quả phân tích và xuất PDF

Các màn hình giao diện được thiết kế theo hướng responsive, sử dụng các kỹ thuật như Flexbox và media queries để đảm bảo khả năng hiển thị tốt trên nhiều loại

97

thiết bị, từ máy tính cá nhân đến thiết bị di động. Điều này góp phần nâng cao trải nghiệm người dùng và tính linh hoạt của hệ thống trong thực tế.

5.4.2. Luồng thao tác người dùng

Luồng thao tác người dùng mô tả chi tiết các bước tương tác giữa người dùng và hệ thống phát hiện sâu răng trên ảnh X-quang, từ khi truy cập ứng dụng cho đến khi nhận được kết quả phân tích. Quy trình này được thiết kế theo hướng đơn giản, trực quan nhằm tối ưu trải nghiệm người dùng.

Ở bước đầu tiên, người dùng truy cập hệ thống thông qua trình duyệt web. Trang chủ được tải và hiển thị giao diện chính (Hero Section), bao gồm tiêu đề giới thiệu hệ thống và nút chức năng “Bắt Đầu Phân Tích”. Người dùng có thể nhấn vào nút này hoặc cuộn trang để chuyển đến khu vực phân tích.

Tiếp theo, tại phần Analysis Section, người dùng thực hiện lựa chọn ảnh X-quang nha khoa từ thiết bị cá nhân thông qua thao tác chọn file hoặc kéo thả trực tiếp vào khu vực upload. Hệ thống frontend sử dụng JavaScript để kiểm tra định dạng (JPG/PNG) và kích thước file (không vượt quá 5MB). Nếu dữ liệu không hợp lệ, hệ thống sẽ hiển thị thông báo lỗi rõ ràng để người dùng điều chỉnh.

Khi ảnh hợp lệ, hệ thống hiển thị bản xem trước (preview), đồng thời kích hoạt nút “Upload & Analyze”. Người dùng có thể kiểm tra lại ảnh trước khi thực hiện phân tích. Khi nhấn nút, frontend sẽ tạo đối tượng FormData chứa file ảnh và gửi yêu cầu POST đến endpoint /api/analyze.

Trong quá trình xử lý, giao diện hiển thị biểu tượng loading kèm thông báo “Đang phân tích...”, đồng thời vô hiệu hóa các thao tác tương tác để tránh gửi nhiều yêu cầu liên tiếp. Ở phía backend, hệ thống tiếp nhận ảnh, thực hiện các bước tiền xử lý, sử dụng mô hình YOLOv8 để phát hiện vùng nghi ngờ sâu răng và mô hình CNN để phân loại mức độ tổn thương. Kết quả sau đó được tổng hợp và trả về dưới dạng JSON.

Sau khi nhận phản hồi, frontend tiến hành phân tích dữ liệu và hiển thị kết quả bao gồm hình ảnh đã được annotate, bảng thống kê tổng quan và danh sách chi tiết các vùng phát hiện. Trạng thái loading được tắt và người dùng có thể quan sát kết quả một cách trực quan.

Cuối cùng, người dùng có thể thực hiện các thao tác bổ sung như tải báo cáo PDF hoặc tiếp tục phân tích ảnh khác thông qua nút chức năng tương ứng. Trong trường hợp xảy ra lỗi (ví dụ lỗi mạng hoặc lỗi xử lý mô hình), hệ thống sẽ hiển thị thông báo lỗi rõ ràng nhằm hỗ trợ người dùng xử lý kịp thời.

Nhìn chung, luồng thao tác được thiết kế tối giản số bước, đảm bảo tính liên tục và dễ sử dụng, giúp người dùng nhanh chóng nhận được kết quả phân tích một cách hiệu quả.

CHƯƠNG 6

KIỂM THỬ VÀ ĐÁNH GIÁ

6.1 KIỂM THỬ CHỨC NĂNG

6.1.1. Kế hoạch kiểm thử

Kế hoạch kiểm thử được xây dựng nhằm đảm bảo hệ thống phát hiện sâu răng trên ảnh X-quang nha khoa hoạt động đúng theo các yêu cầu chức năng đã đề ra. Quá trình kiểm thử tập trung vào việc xác minh tính chính xác, độ ổn định và khả năng xử lý của hệ thống trong các điều kiện khác nhau.

Phạm vi kiểm thử bao gồm toàn bộ các thành phần của hệ thống, từ giao diện người dùng (frontend), các API backend cho đến các mô hình học sâu (YOLOv8 và CNN). Các chức năng chính được kiểm thử gồm: upload ảnh, xử lý phân tích, hiển thị kết quả, xuất báo cáo PDF và kiểm tra trạng thái hệ thống thông qua các endpoint API.

Phương pháp kiểm thử được áp dụng là kiểm thử hộp đen (black-box testing), trong đó tập trung vào việc kiểm tra dữ liệu đầu vào và kết quả đầu ra mà không đi sâu vào cấu trúc bên trong của hệ thống. Các kịch bản kiểm thử được xây dựng dựa trên các tình huống sử dụng thực tế, bao gồm cả trường hợp hợp lệ và không hợp lệ.

Môi trường kiểm thử được thiết lập trên máy tính cá nhân với trình duyệt web hiện đại, kết nối với backend Flask chạy cục bộ. Dữ liệu kiểm thử bao gồm các ảnh X-quang nha khoa với nhiều mức độ sâu răng khác nhau nhằm đánh giá khả năng xử lý của hệ thống trong thực tế.

Kết quả của quá trình kiểm thử sẽ được sử dụng để đánh giá mức độ hoàn thiện của hệ thống, đồng thời làm cơ sở cho việc cải tiến và tối ưu trong các bước tiếp theo.

6.1.2. Các test case chính

Các test case được thiết kế nhằm kiểm tra toàn bộ chức năng của hệ thống, bao gồm cả backend API và giao diện frontend. Mỗi test case được xây dựng với các thành phần rõ ràng như dữ liệu đầu vào (input), kết quả mong đợi (expected output) và tiêu chí đánh giá (pass/fail), nhằm đảm bảo hệ thống hoạt động đúng theo yêu cầu đã đề ra.

Đối với chức năng tải ảnh, hệ thống được kiểm thử với nhiều trường hợp khác nhau nhằm đảm bảo tính ổn định và khả năng xử lý dữ liệu đầu vào. Khi người dùng tải lên ảnh hợp lệ với định dạng JPG hoặc PNG và kích thước nhỏ hơn 5MB, hệ thống có thể tiếp nhận, lưu trữ tạm thời và thực hiện phân tích thành công. Kết quả trả về bao gồm dữ liệu JSON chứa trạng thái xử lý, danh sách các vùng phát hiện, thông tin thống kê và đường dẫn đến ảnh kết quả, đồng thời phản hồi HTTP

200. Ngược lại, trong các trường hợp dữ liệu không hợp lệ như file sai định dạng hoặc vượt quá kích thước cho phép, hệ thống sẽ từ chối xử lý và trả về mã lỗi tương ứng như HTTP 400 hoặc HTTP 413 kèm theo thông báo cụ thể, đảm bảo tính an toàn và kiểm soát dữ liệu đầu vào.

Bên cạnh đó, các endpoint của hệ thống cũng được kiểm thử nhằm đảm bảo khả năng vận hành ổn định. Endpoint `/api/health` được sử dụng để kiểm tra trạng thái hoạt động của hệ thống, với kết quả mong đợi là phản hồi HTTP 200 cùng thông tin xác nhận hệ thống đang hoạt động bình thường và các mô hình đã được tải thành công. Tương tự, endpoint `/api/test-models` được kiểm thử nhằm đánh giá khả năng hoạt động của các mô hình học sâu thông qua việc thực hiện suy luận mẫu, đảm bảo hệ thống sẵn sàng phục vụ yêu cầu phân tích.

Đối với giao diện người dùng, các test case tập trung vào việc kiểm tra trải nghiệm và khả năng tương tác. Khi người dùng thực hiện thao tác gửi yêu cầu mà chưa chọn ảnh, hệ thống sẽ hiển thị thông báo yêu cầu chọn file và không gửi request đến backend. Ngoài ra, khi người dùng chọn ảnh hợp lệ, hệ thống hiển thị ảnh preview một cách chính xác trên giao diện, giúp người dùng kiểm tra dữ liệu trước khi phân tích. Trong trường hợp xảy ra lỗi kết nối mạng hoặc backend không phản hồi, giao diện sẽ hiển thị thông báo lỗi phù hợp, đảm bảo hệ thống không bị treo và vẫn duy trì trải nghiệm người dùng ổn định.

Hệ thống cũng được kiểm thử theo kịch bản end-to-end nhằm đánh giá toàn bộ pipeline xử lý. Khi người dùng tải lên ảnh hợp lệ và thực hiện phân tích, hệ thống sẽ thực hiện đầy đủ các bước từ tiền xử lý, phát hiện vùng sâu răng bằng mô hình YOLOv8, phân loại mức độ bằng CNN cho đến tổng hợp kết quả. Kết quả trả về bao gồm ảnh đã được chú thích, bảng thống kê và danh sách chi tiết các vùng phát hiện, với thời gian xử lý đảm bảo dưới 3 giây.

Ngoài ra, chức năng xuất báo cáo cũng được kiểm tra nhằm đảm bảo tính hoàn chỉnh của hệ thống. Khi người dùng thực hiện tải báo cáo, hệ thống sẽ tạo file PDF chứa đầy đủ thông tin phân tích và cho phép tải xuống thành công.

Như vậy, các test case đã bao phủ toàn bộ các chức năng quan trọng của hệ thống, từ kiểm tra dữ liệu đầu vào, xử lý mô hình, kiểm tra API cho đến giao diện người dùng và các chức năng mở rộng. Kết quả kiểm thử cho thấy hệ thống hoạt động ổn định, đáp ứng tốt các yêu cầu đặt ra và sẵn sàng cho việc triển khai trong thực tế.

6.1.3. Kết quả kiểm thử

Kết quả kiểm thử cho thấy hệ thống phát hiện sâu răng trên ảnh X-quang nha khoa hoạt động ổn định và đáp ứng tốt các yêu cầu chức năng ở mức prototype.

Kết quả kiểm thử backend API

Đối với endpoint `/api/analyze`, hệ thống xử lý chính xác các trường hợp đầu vào. Khi gửi ảnh hợp lệ (định dạng JPG/PNG, kích thước nhỏ hơn 5MB), hệ thống trả về HTTP 200 cùng với dữ liệu JSON chứa đầy đủ thông tin như `detections`, `summary` và `image_url`. Trong các trường hợp dữ liệu không hợp lệ, hệ thống phản hồi đúng theo thiết kế: với file sai định dạng (BMP, TXT), trả về HTTP 400 kèm thông báo lỗi; với file vượt quá kích thước cho phép, trả về HTTP 413 hoặc HTTP 400 với thông báo “file quá lớn”.

Endpoint `/api/health` hoạt động ổn định, trả về HTTP 200 cùng với thông tin trạng thái hệ thống, bao gồm tình trạng tải của các mô hình (YOLOv8 và CNN) và thời gian hoạt động (uptime). Endpoint `/api/test-models` cũng cho kết quả chính xác, xác nhận các mô hình đã được tải thành công và có thể thực hiện suy luận, với thời gian xử lý trung bình khoảng 500–800 ms.

Kết quả kiểm thử frontend:

Giao diện người dùng phản hồi đúng trong các tình huống kiểm thử. Khi người dùng không chọn file và thực hiện upload, hệ thống hiển thị thông báo “Vui lòng chọn ảnh” và không gửi yêu cầu đến backend. Khi chọn file hợp lệ, ảnh preview được hiển thị chính xác và nút “Upload & Analyze” được kích hoạt.

Trong luồng xử lý end-to-end, hệ thống thể hiện sự ổn định: trạng thái loading được hiển thị trong quá trình xử lý, sau đó kết quả được hiển thị đầy đủ bao gồm ảnh annotated, các bounding box, nhãn phân loại và bảng thống kê. Thời gian xử lý trung bình dao động khoảng 1–2 giây trên môi trường có GPU.

Trong trường hợp xảy ra lỗi kết nối hoặc backend không hoạt động, hệ thống hiển thị thông báo lỗi rõ ràng như “Không kết nối server”, đảm bảo trải nghiệm người dùng không bị gián đoạn.

Kết quả kiểm thử các chức năng mở rộng:

Chức năng xuất báo cáo PDF hoạt động chính xác, cho phép tạo và tải file báo cáo với định dạng tên theo thời gian (ví dụ: `report_YYYYMMDD_HHMMSS.pdf`). Nội dung file bao gồm đầy đủ thông tin như tiêu đề, hình ảnh gốc, hình ảnh annotated, bảng thống kê và danh sách các vùng phát hiện.

Ngoài ra, chức năng reset (Clear) cũng hoạt động đúng, cho phép người dùng xóa dữ liệu hiện tại và thực hiện lại quá trình phân tích.

Đánh giá tổng thể:

Toàn bộ 10/10 test case chính đều đạt yêu cầu (PASS). Các API backend hoạt động ổn định với 3/3 endpoint kiểm thử thành công. Cơ chế xử lý lỗi được triển khai đầy đủ và hoạt động đúng trong các tình huống kiểm thử.

Nhận xét và đề xuất

Mặc dù hệ thống đạt hiệu năng tốt, vẫn tồn tại một số sai sót như false positive và false negative trong một số trường hợp ảnh thực tế, chủ yếu do hạn chế của mô hình YOLOv8 và chất lượng dữ liệu đầu vào.

Trong tương lai, cần bổ sung thêm các kịch bản kiểm thử nâng cao như ảnh có nhiều vùng sâu răng hoặc ảnh có chất lượng thấp (ánh sáng kém, nhiễu) nhằm đánh giá độ robust của hệ thống. Đồng thời, việc mở rộng dataset và cải tiến mô hình sẽ giúp nâng cao độ chính xác tổng thể.

6.2 KIỂM THỬ HIỆU NĂNG

6.2.1. Hiệu suất mô hình trên dữ liệu thực

Phần này trình bày việc đánh giá hiệu suất của các mô hình học sâu trên tập dữ liệu kiểm thử độc lập (test set), nhằm xác định mức độ phù hợp của hệ thống khi áp dụng vào bài toán phát hiện sâu răng trên ảnh X-quang nha khoa trong điều kiện thực tế.

Mục tiêu chính của quá trình đánh giá là đo lường hiệu suất của hai mô hình cốt lõi trong hệ thống, bao gồm mô hình YOLOv8 cho bài toán phát hiện vùng sâu răng và mô hình CNN cho bài toán phân loại mức độ tổn thương. Các chỉ số đánh giá được sử dụng đối với YOLOv8 bao gồm mAP, precision, recall và F1-score; trong khi đó đối với CNN bao gồm accuracy, precision, recall và F1-score nhằm đảm bảo đánh giá toàn diện hiệu suất của từng mô hình.

Tập dữ liệu kiểm thử được trích xuất từ bộ dữ liệu sử dụng trong toàn bộ đề tài, bao gồm 80 ảnh X-quang (chiếm khoảng 10% tổng dataset), với khoảng 120 bounding box được gán nhãn. Dữ liệu được chia thành ba mức độ phân loại gồm sâu nhẹ, sâu trung bình và sâu nặng. Các ảnh trong tập test mang đặc điểm gần với thực tế, bao gồm sự đa dạng về độ tương phản, nhiễu và một số trường hợp bị mờ nhẹ, từ đó giúp đánh giá khả năng tổng quát hóa của mô hình trong môi trường thực tế.

Về phương pháp đánh giá, mô hình YOLOv8 được kiểm thử bằng thư viện Ultralytics thông qua hàm `model.val()`, sử dụng các chỉ số `mAP@0.5` và `mAP@0.5:0.95`. Mô hình CNN được đánh giá bằng TensorFlow/Keras thông qua hàm `model.evaluate()` kết hợp với ma trận nhầm lẫn (confusion matrix) để phân tích chi tiết khả năng phân loại. Trong quá trình đánh giá, các ngưỡng được thiết lập gồm `confidence threshold = 0.25` và `IoU threshold = 0.45`.

Kết quả thực nghiệm cho thấy mô hình YOLOv8 đạt hiệu suất tốt với `mAP@0.5` đạt 0.85 và `mAP@0.5:0.95` đạt 0.72. Chỉ số precision đạt 0.88 và recall đạt 0.82, tương ứng với F1-score xấp xỉ 0.83. Thời gian phát hiện trung bình của mô hình khoảng 350–500 ms cho mỗi ảnh trên môi trường GPU, cho thấy khả năng xử lý nhanh và phù hợp với các ứng dụng thời gian thực.

Đối với mô hình CNN, kết quả đánh giá cho thấy độ chính xác (accuracy) đạt khoảng 0.85–0.87, với precision đạt 0.84, recall đạt 0.87 và F1-score đạt khoảng 0.85. Các sai số phân loại chủ yếu xảy ra giữa các lớp có đặc điểm hình ảnh gần nhau, trong đó tỷ lệ nhầm lẫn giữa mức độ sâu nhẹ và trung bình khoảng 5%, và giữa trung bình và nặng khoảng 7%.

Phân tích tổng thể cho thấy hệ thống đạt hiệu suất tốt đối với mục tiêu của một mô hình prototype, đặc biệt với chỉ số recall cao, giúp giảm thiểu khả năng bỏ sót các vùng sâu răng. Tuy nhiên, mô hình vẫn còn hạn chế trong việc phân biệt ranh giới giữa các mức độ tổn thương gần nhau, nguyên nhân chủ yếu đến từ sự mất cân bằng dữ liệu và đặc điểm ảnh X-quang chưa rõ ràng trong một số trường hợp.

Về hiệu năng, thời gian suy luận của toàn bộ hệ thống dưới 1 giây cho mỗi ảnh, đáp ứng yêu cầu về tốc độ trong các ứng dụng web thời gian thực hoặc gần thời gian thực.

Tóm lại, dựa trên kết quả đánh giá trên dữ liệu thực tế, hệ thống kết hợp YOLOv8 và CNN đạt độ tin cậy cao, với độ chính xác tổng thể của pipeline ước tính khoảng 80%. Kết quả này phù hợp với mục tiêu hỗ trợ chẩn đoán ban đầu trong nha khoa. Trong tương lai, để nâng cao hiệu suất, cần mở rộng tập dữ liệu, áp dụng các kỹ thuật tăng cường dữ liệu như thay đổi ánh sáng và làm mờ, cũng như tối ưu các ngưỡng dự đoán hoặc sử dụng phương pháp kết hợp nhiều mô hình nhằm giảm thiểu sai sót.

6.2.2. Thời gian xử lý

Phần này trình bày đánh giá về thời gian xử lý (latency) của hệ thống dựa trên kết quả thử nghiệm thực tế trong môi trường triển khai của dự án. Việc đo lường thời gian xử lý giúp xác định khả năng đáp ứng của hệ thống đối với các ứng dụng gần thời gian thực, đặc biệt trong bối cảnh phân tích ảnh y tế yêu cầu tốc độ và độ chính xác cao.

Các thí nghiệm được thực hiện trên môi trường phát triển với cấu hình gồm GPU NVIDIA RTX 3060 (hoặc tương đương), CPU Intel Core i5 và RAM 16GB. Tập dữ liệu kiểm thử bao gồm 4700 ảnh X-quang nha khoa đã được chuẩn hóa về kích thước 640×640 pixel. Để đảm bảo độ tin cậy của kết quả, mỗi thí nghiệm được lặp lại ba lần và sử dụng giá trị trung vị (median) làm đại diện cho thời gian xử lý.

Kết quả đo lường cho thấy thời gian xử lý được phân bổ theo từng giai đoạn trong pipeline một cách hợp lý. Cụ thể, quá trình nhận và lưu file đầu vào mất khoảng 20–30 ms, trong khi bước tiền xử lý ảnh, bao gồm đọc ảnh, thay đổi kích thước và chuẩn hóa dữ liệu, dao động trong khoảng 40–70 ms. Phần chiếm nhiều thời gian nhất là bước suy luận bằng mô hình YOLOv8 để phát hiện vùng nghi ngờ sâu răng, với thời gian khoảng 320–440 ms. Sau đó, các vùng ảnh được đưa vào mô

hình CNN để phân loại mức độ tổn thương với thời gian trung bình khoảng 80–120 ms cho mỗi ảnh (tương ứng với trung bình 1.5 vùng quan tâm trên mỗi ảnh). Các bước còn lại như vẽ bounding box, tổng hợp kết quả dưới dạng JSON và lưu ảnh đầu ra chỉ chiếm khoảng 25–40 ms, trong khi việc trả response về phía client mất khoảng 20–35 ms.

Tổng thời gian xử lý end-to-end của hệ thống dao động trong khoảng từ 520 đến 675 ms cho mỗi ảnh, với giá trị P95 đạt khoảng 820 ms và giá trị lớn nhất khoảng 1.1 giây trong các trường hợp ảnh có nhiều vùng sâu răng. Kết quả này cho thấy hệ thống có khả năng xử lý nhanh, đáp ứng yêu cầu dưới 1 giây cho phần lớn các trường hợp, phù hợp với các ứng dụng web tương tác và hỗ trợ chẩn đoán gần thời gian thực.

Xét từ góc độ người dùng, thời gian phản hồi tổng thể bao gồm thời gian gửi yêu cầu, chờ xử lý và hiển thị kết quả trên giao diện. Cụ thể, thời gian gửi request và nhận response dao động từ 650 đến 950 ms, trong khi thời gian cập nhật giao diện và hiển thị kết quả nằm trong khoảng 60–110 ms. Như vậy, tổng thời gian người dùng cảm nhận khi sử dụng hệ thống vào khoảng 0.8 đến 1.1 giây, đảm bảo trải nghiệm mượt mà và không gây gián đoạn trong quá trình sử dụng.

Từ các kết quả trên có thể nhận thấy hệ thống đạt hiệu năng tốt và ổn định, đáp ứng yêu cầu của các ứng dụng tiền triển khai hoặc hỗ trợ chẩn đoán ngoại trú. Tuy nhiên, trong trường hợp triển khai ở quy mô lớn hoặc phục vụ nhiều người dùng đồng thời, cần xem xét các giải pháp tối ưu như sử dụng batch inference, triển khai trên hạ tầng GPU chuyên dụng hoặc áp dụng cơ chế hàng đợi như Celery để nâng cao khả năng xử lý song song.

Nhìn chung, hiệu năng về thời gian của hệ thống là khả quan, phù hợp với mục tiêu của đề tài và có tiềm năng mở rộng trong các ứng dụng thực tế.

6.2.3. Nhận xét hiệu suất mô hình

Dựa trên các kết quả thực nghiệm đã trình bày, có thể nhận thấy hệ thống phát hiện sâu răng trên ảnh X-quang nha khoa đạt hiệu suất tốt trong phạm vi mục tiêu của đề tài. Mô hình YOLOv8 thể hiện khả năng phát hiện các vùng nghi ngờ sâu răng với độ nhạy cao, giúp hạn chế việc bỏ sót các tổn thương quan trọng. Đồng thời, mô hình CNN cho thấy hiệu quả trong việc phân loại mức độ sâu răng với độ chính xác tương đối cao, góp phần hỗ trợ quá trình đánh giá chi tiết tình trạng bệnh lý. Khi kết hợp hai mô hình trong cùng một pipeline, hệ thống có thể hoàn thành toàn bộ quá trình phân tích trong thời gian dưới một giây, đáp ứng tốt yêu cầu về hiệu năng trong các ứng dụng web tương tác.

Bên cạnh những kết quả tích cực, hệ thống vẫn tồn tại một số hạn chế nhất định. Cụ thể, sai sót trong phân loại vẫn xuất hiện ở các trường hợp có ranh giới

không rõ ràng giữa các mức độ, đặc biệt là giữa mức nhẹ và trung bình. Ngoài ra, một số vùng không phải tổn thương cũng có thể bị nhận diện nhầm do đặc điểm hình ảnh tương đồng, dẫn đến hiện tượng false positive. Nguyên nhân chính của những hạn chế này xuất phát từ sự đa dạng chưa đầy đủ của dữ liệu huấn luyện, đặc biệt là các ảnh có chất lượng thấp, ánh sáng không đồng đều hoặc bị nhiễu. Đồng thời, hệ thống hiện tại phụ thuộc vào GPU để đạt hiệu năng tối ưu, do đó khi triển khai trên các thiết bị có cấu hình thấp, thời gian xử lý có thể bị ảnh hưởng.

Độ chính xác tổng thể của pipeline, bao gồm cả bước phát hiện và phân loại, hiện đạt khoảng 80%, phù hợp với mục tiêu xây dựng một hệ thống hỗ trợ chẩn đoán ở mức prototype. Tuy nhiên, để tiến tới ứng dụng trong môi trường thực tế hoặc thương mại, hệ thống cần được cải thiện thêm về độ chính xác và tính ổn định. Một số hướng phát triển có thể được xem xét bao gồm việc áp dụng các mô hình học sâu mạnh hơn dựa trên transfer learning, mở rộng và cân bằng lại tập dữ liệu huấn luyện, cũng như bổ sung dữ liệu được gán nhãn bởi chuyên gia nhằm nâng cao chất lượng ground truth. Ngoài ra, việc tích hợp cơ chế phản hồi từ người dùng thực tế cũng có thể giúp hệ thống tự cải thiện theo thời gian.

Nhìn chung, với hiệu suất hiện tại, hệ thống đã đáp ứng tốt yêu cầu của một đề tài nghiên cứu và có khả năng triển khai trong các kịch bản thử nghiệm hoặc hỗ trợ chẩn đoán ban đầu. Nếu tiếp tục được tối ưu và mở rộng, hệ thống hoàn toàn có tiềm năng phát triển thành một giải pháp ứng dụng thực tiễn trong lĩnh vực nha khoa.

6.3 ĐÁNH GIÁ TỔNG THỂ HỆ THỐNG

6.3.1. Những điểm mạnh

Hệ thống phát hiện sâu răng trên ảnh X-quang nha khoa trong đề tài thể hiện nhiều điểm mạnh nổi bật cả về mặt kỹ thuật lẫn khả năng ứng dụng thực tế. Trước hết, kiến trúc hệ thống được thiết kế theo hướng phân tách rõ ràng giữa các thành phần, bao gồm frontend đảm nhiệm giao diện và tương tác người dùng, backend xây dựng trên nền tảng Flask để xử lý API, và phần mô hình học sâu với YOLOv8 và CNN. Cách tổ chức này giúp hệ thống dễ dàng bảo trì, mở rộng cũng như thuận tiện trong quá trình kiểm thử.

Bên cạnh đó, pipeline xử lý end-to-end của hệ thống đạt hiệu năng cao và ổn định, với thời gian xử lý trung bình dưới một giây cho mỗi ảnh trên môi trường có GPU. Điều này cho phép hệ thống đáp ứng tốt các kịch bản tương tác trực tiếp trong ứng dụng web. Về mặt chất lượng, mô hình YOLOv8 đạt độ chính xác cao trong việc phát hiện vùng sâu răng, với chỉ số mAP@0.5 khoảng 0.83, giúp đảm bảo khả năng bao phủ tốt các vùng tổn thương và giảm thiểu nguy cơ bỏ sót các trường hợp quan trọng.

Ngoài ra, mô hình CNN được sử dụng cho bài toán phân loại mức độ sâu răng cũng cho kết quả đáng tin cậy, với độ chính xác khoảng 85%. Việc phân loại thành các mức độ nhẹ, trung bình và nặng mang ý nghĩa lâm sàng rõ rệt, hỗ trợ quá trình đánh giá và ra quyết định của bác sĩ. Giao diện người dùng được thiết kế thân thiện và mượt mà, với đầy đủ các chức năng như upload ảnh, xem trước, hiển thị trạng thái xử lý, trình bày kết quả trực quan và xuất báo cáo PDF, giúp người dùng thực hiện toàn bộ quy trình một cách nhanh chóng và thuận tiện.

Hệ thống cũng được xây dựng với khả năng xử lý lỗi tốt, bao gồm các trường hợp dữ liệu đầu vào không hợp lệ, lỗi kết nối hoặc sự cố backend, đảm bảo không gây gián đoạn trải nghiệm người dùng. Cuối cùng, hệ thống có tính mở rộng cao, sẵn sàng tích hợp thêm các chức năng nâng cao như xác thực người dùng, ghi log, hoặc triển khai trên môi trường production thông qua các công nghệ như Docker, Unicorn và Docker Compose. Những yếu tố này cho thấy hệ thống không chỉ dừng lại ở mức nghiên cứu mà còn có tiềm năng phát triển thành một ứng dụng thực tiễn hoàn chỉnh.

6.3.2. Hạn chế còn tồn tại

Bên cạnh những điểm mạnh đã đạt được, hệ thống vẫn tồn tại một số hạn chế cần được xem xét và cải thiện trong các nghiên cứu tiếp theo. Trước hết, về mặt dữ liệu, bộ dataset sử dụng trong đề tài còn tương đối hạn chế về quy mô (khoảng 41900 ảnh) và chưa đảm bảo sự cân bằng giữa các lớp, đặc biệt là lớp “nặng”. Điều này có thể dẫn đến hiện tượng mô hình bị lệch (bias) và làm giảm độ chính xác trong các trường hợp ít dữ liệu. Ngoài ra, hệ thống chưa được kiểm thử đầy đủ trên các biến thể thực tế của ảnh X-quang như điều kiện ánh sáng khác nhau, ảnh bị nhiễu hoặc góc chụp không chuẩn, ảnh hưởng đến khả năng tổng quát hóa của mô hình.

Về mặt độ chính xác, hệ thống vẫn còn tồn tại sai số trong cả hai giai đoạn phát hiện và phân loại. Mô hình YOLOv8 đôi khi phát hiện nhầm các vùng có cấu trúc tương tự sâu răng, dẫn đến hiện tượng false positive hoặc bỏ sót một số vùng nhỏ (false negative). Đồng thời, mô hình CNN vẫn gặp khó khăn trong việc phân biệt các mức độ gần nhau, đặc biệt là giữa mức nhẹ và trung bình hoặc trung bình và nặng, với tỷ lệ nhầm lẫn khoảng 5–10%. Nguyên nhân chủ yếu đến từ chất lượng ROI chưa rõ ràng và sự chồng lấp đặc trưng giữa các lớp.

Một hạn chế khác liên quan đến hiệu năng là sự phụ thuộc vào phần cứng GPU. Mặc dù hệ thống đạt tốc độ xử lý tốt trên môi trường có GPU, nhưng khi triển khai trên CPU cấu hình thấp, thời gian xử lý có thể tăng lên trên 2 giây cho mỗi ảnh, gây ảnh hưởng đến trải nghiệm người dùng trong các hệ thống yêu cầu phản hồi nhanh.

Về khả năng mở rộng, hệ thống hiện tại chủ yếu được thiết kế theo mô hình đơn (single-instance), chưa hỗ trợ các cơ chế xử lý tải cao như hàng đợi (queue), worker pool hay cân bằng tải (load balancing). Đồng thời, hệ thống cũng chưa tích hợp cơ chế tự động cập nhật mô hình dựa trên dữ liệu mới (model retraining hoặc drift detection), điều này có thể làm giảm hiệu quả khi áp dụng lâu dài trong môi trường thực tế.

Cuối cùng, công tác kiểm thử tự động còn hạn chế. Hệ thống chủ yếu được kiểm thử thủ công và thông qua một số script cục bộ, chưa xây dựng được bộ test coverage đầy đủ. Điều này có thể gây khó khăn trong việc phát hiện lỗi hồi quy (regression) khi hệ thống được mở rộng hoặc nâng cấp trong tương lai.

Những hạn chế trên là cơ sở quan trọng để định hướng các cải tiến trong các giai đoạn phát triển tiếp theo của hệ thống.

6.3.3. Nhận xét chung

Dựa trên toàn bộ quá trình kiểm thử và đánh giá, có thể nhận định rằng hệ thống phát hiện sâu răng trên ảnh X-quang nha khoa mang lại hiệu quả rõ rệt so với phương pháp phân tích thủ công truyền thống. Về mặt tốc độ, hệ thống có khả năng xử lý và trả kết quả trong khoảng 0.8 đến 1.1 giây cho mỗi ảnh, nhanh hơn đáng kể so với thời gian quan sát và đánh giá thủ công thường kéo dài từ 3 đến 5 phút. Điều này giúp tiết kiệm thời gian và nâng cao hiệu suất làm việc trong môi trường thực tế.

Bên cạnh đó, việc ứng dụng các mô hình học sâu như YOLOv8 và CNN giúp tự động hóa quá trình phát hiện và phân loại mức độ sâu răng, từ đó giảm thiểu nguy cơ bỏ sót các tổn thương nhỏ hoặc nhầm lẫn giữa các giai đoạn bệnh. Hệ thống cũng góp phần hạn chế ảnh hưởng của các yếu tố chủ quan như sự mệt mỏi hoặc căng thẳng của người phân tích, đặc biệt trong trường hợp phải xử lý số lượng lớn ảnh trong thời gian dài.

Một ưu điểm quan trọng khác là tính nhất quán của kết quả. Không giống như đánh giá thủ công có thể thay đổi giữa các cá nhân, mô hình học máy đưa ra kết quả dựa trên các tiêu chí định lượng và ổn định, giúp đảm bảo tính đồng nhất trong quá trình phân tích. Với những đặc điểm này, hệ thống có thể đóng vai trò như một công cụ hỗ trợ chẩn đoán (second opinion), đặc biệt hữu ích trong các phòng khám nha khoa hoặc các cơ sở y tế có nguồn nhân lực chuyên môn còn hạn chế.

Tổng thể, hệ thống đã đáp ứng tốt các yêu cầu của đề tài, thể hiện tiềm năng ứng dụng thực tế trong việc nâng cao hiệu quả chẩn đoán, giảm sai sót và tiết kiệm thời gian so với phương pháp truyền thống. Đây là nền tảng quan trọng để tiếp tục phát triển và hoàn thiện hệ thống trong các nghiên cứu tiếp theo.

CHƯƠNG 7

KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

7.1 KẾT LUẬN

7.1.1. Tóm tắt những kết quả đạt được

Trong quá trình thực hiện đề tài, hệ thống phát hiện sâu răng trên ảnh X-quang nha khoa đã được xây dựng và hoàn thiện với đầy đủ các thành phần từ backend, frontend đến các mô hình trí tuệ nhân tạo. Cụ thể, hệ thống được phát triển theo mô hình client-server với backend sử dụng Flask để cung cấp các API xử lý ảnh và frontend xây dựng bằng HTML, CSS và JavaScript nhằm tạo giao diện tương tác trực quan cho người dùng.

Về mặt mô hình học sâu, đề tài đã tích hợp thành công hai mô hình chính, bao gồm YOLOv8 cho nhiệm vụ phát hiện vùng nghi ngờ sâu răng và CNN cho nhiệm vụ phân loại mức độ tổn thương. Kết quả thực nghiệm cho thấy mô hình YOLOv8 đạt chỉ số mAP@0.5 khoảng 0.83, trong khi mô hình CNN đạt độ chính xác khoảng 85% trong việc phân loại ba mức độ sâu răng (nhẹ, trung bình và nặng). Việc kết hợp hai mô hình trong cùng một pipeline đã cho phép hệ thống thực hiện phân tích một cách toàn diện và hiệu quả.

Hệ thống đã hoàn thiện pipeline xử lý end-to-end, bao gồm các bước từ tiếp nhận ảnh đầu vào (định dạng JPG/PNG), tiền xử lý dữ liệu, thực hiện suy luận với các mô hình YOLOv8 và CNN, tổng hợp kết quả và vẽ annotation lên ảnh. Kết quả được trả về dưới dạng JSON, bao gồm thông tin về bounding box, nhãn phân loại và các thống kê tổng hợp, đồng thời cung cấp ảnh kết quả đã được đánh dấu.

Ngoài ra, hệ thống đã được kiểm thử toàn diện với nhiều kịch bản khác nhau. Toàn bộ các test case chính đều đạt yêu cầu, bao gồm cả các trường hợp dữ liệu không hợp lệ hoặc lỗi hệ thống như file sai định dạng, vượt quá kích thước cho phép hoặc mất kết nối backend. Các endpoint API như /api/health và /api/test-models hoạt động ổn định, đảm bảo khả năng giám sát và kiểm tra trạng thái hệ thống.

Về hiệu năng, hệ thống đạt thời gian xử lý end-to-end khoảng 0.8 đến 1.1 giây cho mỗi ảnh trong môi trường có GPU, đáp ứng tốt yêu cầu của một hệ thống prototype. Giao diện frontend được thiết kế hoàn chỉnh với các chức năng như upload ảnh, hiển thị preview, trạng thái loading, trình bày kết quả và xuất báo cáo PDF, mang lại trải nghiệm người dùng mượt mà và thuận tiện.

Bên cạnh đó, dự án đã xây dựng được nền tảng kỹ thuật có tính modular cao, với cấu trúc rõ ràng và dễ mở rộng, cho phép triển khai trong môi trường production thông qua các công nghệ như Unicorn hoặc Docker. Nhìn chung, hệ thống đã đạt

được độ tin cậy tốt, giúp giảm sai sót so với phương pháp phân tích thủ công, đồng thời nâng cao tốc độ và tính nhất quán trong quá trình chẩn đoán.

Tóm lại, đề tài đã hoàn thành mục tiêu đặt ra, đó là xây dựng một hệ thống phát hiện sâu răng trên ảnh X-quang nha khoa sử dụng học sâu, tích hợp giao diện web và thực hiện đánh giá hiệu năng một cách đầy đủ.

7.1.2. Đánh giá mức độ đạt mục tiêu

Dựa trên các kết quả triển khai, kiểm thử và đánh giá đã trình bày, có thể khẳng định rằng đề tài đã đạt được phần lớn các mục tiêu đã đề ra ban đầu. Mục tiêu chính của đề tài là xây dựng một hệ thống phát hiện sâu răng trên ảnh X-quang nha khoa kết hợp giữa nền tảng web và các mô hình học sâu. Thực tế triển khai cho thấy hệ thống đã hoàn thiện đầy đủ các thành phần, bao gồm backend REST API, giao diện frontend tương tác và pipeline xử lý sử dụng kết hợp mô hình YOLOv8 và CNN, đáp ứng đúng định hướng ban đầu.

Về mặt hiệu năng, hệ thống đạt thời gian suy luận dưới 1 giây cho mỗi ảnh trong môi trường có GPU, cụ thể dao động trong khoảng 0.8 đến 1.1 giây. Kết quả này phù hợp với mục tiêu đề ra và đảm bảo khả năng ứng dụng trong các hệ thống tương tác gần thời gian thực. Về độ chính xác, mô hình YOLOv8 đạt chỉ số mAP@0.5 khoảng 0.83, trong khi mô hình CNN đạt độ chính xác khoảng 85% trong bài toán phân loại mức độ sâu răng. Đây là mức hiệu suất tốt đối với một hệ thống ở giai đoạn prototype, đủ để hỗ trợ chẩn đoán ban đầu.

Hệ thống cũng đã đáp ứng tốt mục tiêu về kiểm thử, với toàn bộ các test case chính đều đạt yêu cầu. Các tình huống lỗi như dữ liệu đầu vào không hợp lệ, file quá kích thước hoặc sự cố kết nối đều được xử lý hợp lý, đảm bảo tính ổn định của hệ thống. Về trải nghiệm người dùng, giao diện frontend đã được xây dựng hoàn chỉnh với các chức năng như upload ảnh, hiển thị preview, trạng thái xử lý, trình bày kết quả và xuất báo cáo PDF, mang lại trải nghiệm thân thiện và dễ sử dụng.

Ngoài ra, hệ thống được thiết kế theo kiến trúc mô-đun, giúp dễ dàng bảo trì và mở rộng. Điều này cho phép bổ sung các chức năng nâng cao như xác thực người dùng, ghi log hoặc triển khai cơ chế xử lý song song trong tương lai. Đồng thời, nền tảng hiện tại cũng sẵn sàng cho việc triển khai trong môi trường production với các công nghệ như Docker hoặc Gunicorn.

Mặc dù vẫn còn một số hạn chế về độ chính xác và khả năng tổng quát hóa trong các điều kiện dữ liệu phức tạp, hệ thống vẫn đáp ứng tốt mục tiêu của một đề tài nghiên cứu, bao gồm việc triển khai chức năng, đánh giá hiệu năng và đề xuất hướng cải tiến.

Tổng thể, có thể đánh giá rằng đề tài đã đạt mức hoàn thành cao, đủ điều kiện để nghiệm thu và bảo vệ, đồng thời tạo nền tảng vững chắc cho các nghiên cứu và phát triển tiếp theo hướng tới một sản phẩm ứng dụng thực tế.

7.2 HẠN CHẾ HIỆN TẠI

7.2.1. Các hạn chế về mô hình và dữ liệu

Mặc dù hệ thống đã đạt được hiệu suất tương đối tốt, vẫn tồn tại một số hạn chế liên quan đến mô hình học sâu và dữ liệu huấn luyện. Trước hết, bộ dữ liệu sử dụng trong đề tài còn hạn chế về quy mô (khoảng 41900 ảnh) và chưa đảm bảo tính cân bằng giữa các lớp, đặc biệt là lớp “nặng”. Điều này có thể dẫn đến hiện tượng mô hình bị lệch (bias) và làm giảm độ chính xác trong một số trường hợp. Ngoài ra, dữ liệu chưa bao phủ đầy đủ các điều kiện thực tế như ảnh có nhiễu, ánh sáng không đồng đều hoặc góc chụp phức tạp, ảnh hưởng đến khả năng tổng quát hóa của mô hình.

Bên cạnh đó, mô hình YOLOv8 vẫn có thể gặp hiện tượng phát hiện sai (false positive) hoặc bỏ sót (false negative) ở các vùng có cấu trúc tương tự sâu răng. Mô hình CNN cũng còn nhầm lẫn giữa các mức độ gần nhau như nhẹ và trung bình hoặc trung bình và nặng, với tỷ lệ khoảng 5–10%. Ngoài ra, pipeline hiện tại sử dụng kiến trúc nối tiếp (YOLO → CNN), do đó sai sót ở bước phát hiện có thể ảnh hưởng trực tiếp đến kết quả phân loại, làm giảm hiệu quả tổng thể của hệ thống.

Một hạn chế quan trọng khác là hệ thống chưa được kiểm chứng trên dữ liệu lâm sàng thực tế hoặc đánh giá bởi các chuyên gia nha khoa, do đó chưa thể khẳng định độ tin cậy tuyệt đối trong môi trường ứng dụng thực tiễn. Ngoài ra, hệ thống chưa tích hợp các phương pháp giải thích mô hình (Explainable AI), khiến người dùng khó hiểu rõ cơ sở đưa ra quyết định của mô hình.

7.2.2. Các hạn chế về hệ thống và triển khai

Về mặt hệ thống, hiệu năng hiện tại vẫn phụ thuộc nhiều vào phần cứng GPU. Mặc dù thời gian xử lý nhanh trên môi trường có GPU, nhưng khi triển khai trên các thiết bị có cấu hình thấp, thời gian suy luận có thể tăng đáng kể, ảnh hưởng đến trải nghiệm người dùng. Đồng thời, hệ thống chưa được tối ưu cho các kịch bản xử lý đồng thời nhiều yêu cầu, chưa triển khai các cơ chế như hàng đợi (queue), worker pool hoặc cân bằng tải (load balancing).

Ngoài ra, hệ thống chưa tích hợp đầy đủ các cơ chế bảo mật như xác thực người dùng (authentication), phân quyền truy cập (authorization) hoặc bảo vệ dữ liệu nhạy cảm. Việc ghi log và theo dõi hoạt động cũng chưa được hoàn thiện, gây khó khăn trong việc giám sát và phát hiện lỗi khi triển khai thực tế.

Một hạn chế khác là công tác kiểm thử tự động chưa được triển khai đầy đủ. Hệ thống chủ yếu được kiểm thử thủ công và thông qua các script đơn lẻ, chưa có bộ test coverage toàn diện để đảm bảo tính ổn định khi nâng cấp hoặc mở rộng. Ngoài ra, hệ thống cũng chưa có cơ chế quản lý phiên bản mô hình hoặc cập nhật mô hình tự động khi có dữ liệu mới, điều này có thể ảnh hưởng đến hiệu quả hoạt động lâu dài.

Những hạn chế trên là cơ sở quan trọng để định hướng các cải tiến trong tương lai nhằm nâng cao hiệu suất, độ tin cậy và khả năng triển khai thực tế của hệ thống.

7.3 HƯỚNG PHÁT TRIỂN

7.3.1. Cải thiện độ chính xác mô hình

Mặc dù hệ thống đã đạt được hiệu suất tốt ở mức prototype, độ chính xác của mô hình vẫn có thể được cải thiện để hướng tới việc triển khai trong môi trường thực tế. Trước hết, một trong những yếu tố quan trọng nhất là mở rộng và cân bằng bộ dữ liệu huấn luyện. Việc tăng số lượng ảnh từ khoảng 41900 lên 60000–70000 ảnh, đồng thời thu thập dữ liệu từ nhiều nguồn khác nhau như bệnh viện và phòng khám nha khoa, sẽ giúp mô hình học được nhiều đặc trưng đa dạng hơn. Bên cạnh đó, cần chú trọng cân bằng lại phân phối các lớp, đặc biệt là bổ sung thêm các mẫu thuộc mức độ “nặng” nhằm hạn chế hiện tượng lệch dữ liệu (data imbalance). Việc đa dạng hóa dữ liệu theo các điều kiện chụp khác nhau như độ tương phản, góc chụp hoặc thiết bị X-quang cũng đóng vai trò quan trọng trong việc nâng cao khả năng tổng quát hóa của mô hình.

Ngoài dữ liệu, việc nâng cấp kiến trúc mô hình cũng là một hướng cải tiến hiệu quả. Đối với mô hình YOLO, có thể sử dụng các phiên bản lớn hơn như YOLOv8m hoặc YOLOv8x để cải thiện khả năng phát hiện các vùng sâu nhỏ và phức tạp. Đối với bài toán phân loại, thay vì sử dụng mô hình CNN đơn giản, có thể áp dụng các kiến trúc học sâu hiện đại dựa trên transfer learning như ResNet50 hoặc EfficientNet, được huấn luyện trước trên các tập dữ liệu lớn như ImageNet và sau đó fine-tune với dữ liệu nha khoa. Ngoài ra, việc kết hợp nhiều mô hình (ensemble learning) thông qua các phương pháp như voting hoặc averaging cũng có thể giúp tăng độ ổn định và độ chính xác tổng thể của hệ thống.

Bên cạnh đó, quá trình huấn luyện cần được tối ưu hóa thông qua các kỹ thuật tăng cường dữ liệu (data augmentation) mạnh hơn, bao gồm xoay ảnh, điều chỉnh độ sáng và độ tương phản, thêm nhiễu hoặc làm mờ để mô phỏng các điều kiện ảnh thực tế. Việc áp dụng các hàm mất mát nâng cao như focal loss hoặc label smoothing cũng có thể giúp cải thiện khả năng học của mô hình trong các trường hợp dữ liệu mất cân bằng hoặc khó phân biệt. Đồng thời, các ngưỡng dự đoán

(threshold) của YOLO và CNN cần được tinh chỉnh dựa trên các đường cong ROC nhằm giảm thiểu sai sót, đặc biệt là hạn chế false negative trong bối cảnh y tế.

Ngoài ra, các kỹ thuật xử lý ảnh đầu vào cũng có thể góp phần nâng cao chất lượng dự đoán. Việc áp dụng các phương pháp như CLAHE để cân bằng độ tương phản, hoặc các bộ lọc như bilateral filter nhằm giảm nhiễu nhưng vẫn giữ được biên ảnh, sẽ giúp cải thiện chất lượng dữ liệu đầu vào. Bên cạnh đó, việc sử dụng multi-scale inference, tức là thực hiện suy luận trên nhiều kích thước ảnh khác nhau và kết hợp kết quả, có thể giúp tăng khả năng phát hiện các vùng sâu nhỏ.

Một hướng cải tiến quan trọng khác là khai thác phản hồi từ thực tế. Việc triển khai thử nghiệm trên dữ liệu thực từ bác sĩ và thu thập các trường hợp dự đoán sai sẽ giúp xây dựng tập dữ liệu “hard examples” để tái huấn luyện mô hình. Đồng thời, cần theo dõi liên tục các chỉ số hiệu suất như accuracy, precision và recall để phát hiện sớm hiện tượng suy giảm hiệu năng (data drift) theo thời gian.

Với các cải tiến nêu trên, kỳ vọng hiệu suất của hệ thống sẽ được nâng cao đáng kể. Cụ thể, mô hình YOLO có thể đạt mAP trong khoảng 0.88–0.90, mô hình CNN có thể đạt độ chính xác trên 90%, và độ chính xác tổng thể của pipeline có thể tăng từ khoảng 80% lên mức 85–87%. Những cải tiến này sẽ đưa hệ thống tiến gần hơn tới mức chất lượng của một sản phẩm có thể ứng dụng trong thực tế.

7.3.2. Mở rộng chức năng

Bên cạnh việc cải thiện độ chính xác của mô hình, hệ thống còn có nhiều tiềm năng mở rộng chức năng nhằm nâng cao giá trị ứng dụng trong thực tế. Trước hết, hệ thống có thể được phát triển theo hướng mở rộng phạm vi phát hiện sang nhiều bệnh lý nha khoa khác ngoài sâu răng. Cụ thể, mô hình có thể được huấn luyện để nhận diện các tình trạng như viêm tủy, bệnh nha chu, mất xương hàm, hoặc các cấu trúc như implant, mắc cài và cầu răng. Việc áp dụng mô hình YOLO đa lớp (multi-class) sẽ cho phép phát hiện đồng thời nhiều loại tổn thương, trong khi giao diện người dùng có thể được cải tiến để hiển thị các loại bệnh với màu sắc và ký hiệu khác nhau nhằm tăng khả năng phân biệt trực quan.

Ngoài ra, hệ thống có thể tích hợp chức năng lưu trữ và quản lý thông tin bệnh nhân thông qua cơ sở dữ liệu. Mỗi lần phân tích có thể được lưu lại cùng với các thông tin như mã bệnh nhân, thời gian thực hiện, ảnh đầu vào, ảnh kết quả và đánh giá của bác sĩ. Điều này cho phép theo dõi tiến triển bệnh theo thời gian, hỗ trợ so sánh các lần khám khác nhau và tạo các báo cáo chi tiết phục vụ công tác điều trị hoặc tư vấn. Việc xây dựng dashboard quản trị cũng là một hướng phát triển quan trọng, giúp hiển thị các thống kê tổng quan như số lượng ca phân tích, phân bố bệnh lý hoặc hiệu suất của mô hình theo thời gian.

Một hướng mở rộng khác là tích hợp cơ chế tương tác và phản hồi từ bác sĩ. Hệ thống có thể cho phép người dùng chỉnh sửa kết quả dự đoán của mô hình, bao gồm việc điều chỉnh bounding box hoặc thay đổi mức độ phân loại. Các dữ liệu chỉnh sửa này có thể được lưu lại và sử dụng để tái huấn luyện mô hình trong tương lai theo hướng học tăng cường (active learning), từ đó nâng cao độ chính xác theo thời gian. Đồng thời, việc hiển thị độ tin cậy (confidence score) cho từng dự đoán cũng giúp người dùng dễ dàng đánh giá và quyết định chấp nhận hoặc chỉnh sửa kết quả.

Bên cạnh đó, hệ thống có thể được nâng cấp để hỗ trợ xử lý hàng loạt (batch processing), cho phép người dùng tải lên nhiều ảnh cùng lúc và thực hiện phân tích song song. Sau khi hoàn tất, hệ thống có thể tự động tạo báo cáo tổng hợp dưới dạng PDF hoặc Excel, giúp tiết kiệm thời gian trong các môi trường có khối lượng công việc lớn. Ngoài ra, việc tích hợp với các hệ thống y tế như DICOM, RIS/PACS hoặc các chuẩn trao đổi dữ liệu như HL7/FHIR sẽ giúp hệ thống dễ dàng kết nối với hạ tầng bệnh viện và nâng cao khả năng triển khai thực tế.

Hệ thống cũng có thể được mở rộng sang nền tảng di động thông qua việc tối ưu giao diện web (responsive hoặc Progressive Web App) hoặc phát triển ứng dụng native trên iOS và Android. Điều này giúp tăng tính linh hoạt và khả năng tiếp cận của người dùng. Ngoài ra, các tính năng bổ trợ như hỗ trợ đa ngôn ngữ, chế độ giao diện tối (dark mode), xuất dữ liệu dưới nhiều định dạng khác nhau hoặc cung cấp công cụ annotation cho bác sĩ cũng góp phần nâng cao trải nghiệm người dùng và tính chuyên nghiệp của hệ thống.

Nhìn chung, với các hướng mở rộng nêu trên, hệ thống không chỉ dừng lại ở một công cụ nghiên cứu mà còn có tiềm năng phát triển thành một nền tảng hỗ trợ chẩn đoán nha khoa toàn diện, đáp ứng nhu cầu thực tiễn trong lĩnh vực y tế

7.3.3. Triển khai thực tế

Để đưa hệ thống từ giai đoạn prototype sang triển khai thực tế trong môi trường bệnh viện hoặc phòng khám, cần thực hiện một quy trình triển khai toàn diện bao gồm nhiều khía cạnh từ hạ tầng, bảo mật đến vận hành và bảo trì. Trước hết, hệ thống cần được đóng gói bằng công nghệ container hóa như Docker nhằm đảm bảo tính nhất quán và khả năng tái sử dụng trong các môi trường khác nhau. Backend Flask cùng với các mô hình học sâu và thư viện phụ thuộc được đóng gói trong Docker image, cho phép triển khai nhanh chóng và dễ dàng. Trong giai đoạn phát triển và kiểm thử, có thể sử dụng Docker Compose để chạy đồng thời các dịch vụ như backend, frontend và cơ sở dữ liệu. Đối với các hệ thống có quy mô lớn, việc áp dụng Kubernetes sẽ giúp tự động hóa quá trình mở rộng và đảm bảo tính sẵn sàng cao.

Về mặt vận hành, hệ thống cần sử dụng web server chuyên dụng như Gunicorn để thay thế server phát triển của Flask, kết hợp với Nginx đóng vai trò reverse proxy nhằm phân phối tải, xử lý SSL/TLS và phục vụ các tài nguyên tĩnh. Nginx cũng có thể được cấu hình để tối ưu hiệu năng thông qua cơ chế cache và nén dữ liệu. Bên cạnh đó, hệ thống cần chuyển từ cơ chế lưu trữ tạm thời sang sử dụng cơ sở dữ liệu quan hệ như PostgreSQL hoặc MySQL để quản lý thông tin bệnh nhân, kết quả phân tích và phản hồi từ người dùng. Việc sử dụng ORM như SQLAlchemy sẽ giúp đơn giản hóa quá trình thao tác với dữ liệu và tăng tính linh hoạt trong phát triển.

Một yếu tố quan trọng khác là bảo mật hệ thống. Toàn bộ hệ thống cần được triển khai trên nền tảng HTTPS với chứng chỉ SSL/TLS để đảm bảo an toàn truyền dữ liệu. Đồng thời, cần tích hợp các cơ chế xác thực và phân quyền người dùng như JWT hoặc OAuth2 nhằm kiểm soát truy cập API. Các biện pháp kiểm tra dữ liệu đầu vào, mã hóa thông tin nhạy cảm và giới hạn tần suất truy cập (rate limiting) cũng cần được áp dụng để phòng chống các nguy cơ tấn công.

Ngoài ra, hệ thống cần được trang bị các công cụ giám sát và ghi log để đảm bảo hoạt động ổn định. Các thông tin như request, lỗi hệ thống và thời gian xử lý cần được ghi lại đầy đủ, đồng thời các chỉ số về tài nguyên như CPU, bộ nhớ và lưu lượng mạng cần được theo dõi liên tục thông qua các công cụ như Prometheus và Grafana. Việc xây dựng pipeline CI/CD cũng đóng vai trò quan trọng trong việc tự động hóa kiểm thử, xây dựng và triển khai hệ thống, giúp giảm thiểu lỗi và tăng tốc độ phát triển.

Trong môi trường triển khai thực tế, hệ thống có thể được đặt trên các nền tảng điện toán đám mây như AWS, Google Cloud hoặc Azure để tận dụng khả năng mở rộng linh hoạt và các dịch vụ hỗ trợ như load balancing, lưu trữ và cơ sở dữ liệu quản lý. Đồng thời, cần xây dựng các kế hoạch sao lưu và phục hồi dữ liệu nhằm đảm bảo hệ thống có thể hoạt động liên tục ngay cả khi xảy ra sự cố.

Bên cạnh các yếu tố kỹ thuật, việc tuân thủ các quy định liên quan đến dữ liệu y tế và bảo mật thông tin cá nhân cũng là yêu cầu bắt buộc. Hệ thống cần đảm bảo các tiêu chuẩn về bảo vệ dữ liệu và có cơ chế ghi nhận lịch sử truy cập để phục vụ kiểm toán. Ngoài ra, việc đào tạo người dùng cuối, bao gồm bác sĩ và nhân viên y tế, cũng cần được thực hiện để đảm bảo hệ thống được sử dụng hiệu quả và đúng mục đích.

Cuối cùng, hệ thống cần được vận hành theo các tiêu chí dịch vụ rõ ràng, bao gồm thời gian hoạt động (uptime), thời gian phản hồi và độ ổn định của mô hình. Một lộ trình triển khai cụ thể từ giai đoạn thiết lập hạ tầng, kiểm thử, thử nghiệm thực tế đến khi đưa vào vận hành chính thức sẽ giúp đảm bảo quá trình chuyển đổi từ prototype sang sản phẩm diễn ra một cách hiệu quả và an toàn. Với các bước

triển khai này, hệ thống có thể phát triển thành một giải pháp hoàn chỉnh, sẵn sàng ứng dụng trong môi trường thực tế.

7.3.4. Tích hợp các tính năng bổ sung

Bên cạnh các hướng phát triển về mô hình và hệ thống, việc tích hợp các tính năng bổ sung (soft features) đóng vai trò quan trọng trong việc nâng cao giá trị sử dụng và trải nghiệm người dùng của hệ thống. Trước hết, một trong những hướng phát triển đáng chú ý là khả năng giải thích mô hình (Explainable AI). Hệ thống có thể tích hợp các kỹ thuật trực quan hóa như Grad-CAM để hiển thị vùng ảnh mà mô hình tập trung khi đưa ra dự đoán, từ đó giúp bác sĩ hiểu rõ cơ sở của kết quả và tăng độ tin cậy khi sử dụng. Ngoài ra, việc xây dựng bản đồ nhiệt (heatmap) thể hiện mức độ tin cậy trên toàn bộ ảnh X-quang, kết hợp với các mô tả bằng ngôn ngữ tự nhiên về kết quả phân tích, sẽ giúp hệ thống trở nên trực quan và dễ tiếp cận hơn đối với người dùng không chuyên về kỹ thuật.

Bên cạnh đó, chức năng tạo báo cáo tự động là một thành phần quan trọng trong việc hỗ trợ công tác chuyên môn. Hệ thống có thể xây dựng các mẫu báo cáo chuẩn bao gồm thông tin bệnh nhân, hình ảnh trước và sau khi xử lý, kết quả phân tích và đề xuất điều trị. Báo cáo có thể được xuất dưới nhiều định dạng như PDF hoặc Word, đồng thời hỗ trợ đa ngôn ngữ nhằm phục vụ nhiều đối tượng người dùng khác nhau. Việc so sánh kết quả giữa các lần khám trước và sau cũng giúp bác sĩ theo dõi tiến triển bệnh một cách hiệu quả.

Ngoài ra, hệ thống có thể được mở rộng với các tính năng cộng tác theo thời gian thực, cho phép bác sĩ chia sẻ kết quả với đồng nghiệp hoặc chuyên gia để nhận ý kiến thứ hai. Các chức năng như bình luận, ghi chú trực tiếp trên ảnh và lưu lịch sử chỉnh sửa sẽ hỗ trợ quá trình làm việc nhóm và đảm bảo tính minh bạch trong quá trình chẩn đoán. Đồng thời, khả năng hoạt động ngoại tuyến thông qua các công nghệ như Progressive Web App cũng giúp hệ thống linh hoạt hơn trong các môi trường hạn chế kết nối mạng.

Hệ thống cũng có thể được nâng cấp với các chức năng tìm kiếm và phân tích dữ liệu nâng cao. Người dùng có thể tìm kiếm thông tin bệnh nhân theo nhiều tiêu chí khác nhau và lọc dữ liệu theo thời gian, loại bệnh hoặc mức độ nghiêm trọng. Các công cụ trực quan hóa dữ liệu như biểu đồ và dashboard sẽ giúp cung cấp cái nhìn tổng quan về tình hình bệnh lý, hỗ trợ việc ra quyết định trong quản lý và điều trị.

Một hướng phát triển quan trọng khác là tích hợp với các thiết bị và hệ thống y tế hiện có. Việc hỗ trợ định dạng DICOM và kết nối với các hệ thống RIS/PACS hoặc hồ sơ bệnh án điện tử (EHR) sẽ giúp hệ thống dễ dàng hòa nhập vào quy trình vận hành của bệnh viện. Đồng thời, các tính năng như thông báo thời gian thực,

cảnh báo các trường hợp nghiêm trọng và tính điểm rủi ro cũng giúp ưu tiên xử lý các ca bệnh quan trọng.

Ngoài ra, hệ thống cần chú trọng đến khả năng quốc tế hóa và khả năng truy cập. Việc hỗ trợ đa ngôn ngữ, chế độ giao diện tối, điều chỉnh kích thước chữ và hỗ trợ các công cụ trợ năng sẽ giúp mở rộng phạm vi người dùng. Các cơ chế phản hồi từ người dùng và học liên tục cũng đóng vai trò quan trọng trong việc cải thiện chất lượng hệ thống theo thời gian thông qua việc thu thập và tái sử dụng các trường hợp dự đoán sai.

Cuối cùng, việc theo dõi chi phí và tài nguyên sử dụng, cùng với các công cụ hỗ trợ tuân thủ quy định về dữ liệu y tế, sẽ giúp hệ thống vận hành bền vững và phù hợp với các tiêu chuẩn pháp lý. Nhìn chung, việc tích hợp các tính năng bổ sung không chỉ nâng cao trải nghiệm người dùng mà còn góp phần đưa hệ thống trở thành một nền tảng toàn diện, hỗ trợ hiệu quả trong lĩnh vực chẩn đoán nha khoa hiện đại.

TÀI LIỆU THAM KHẢO

1. Lee, S., Oh, S.-I., Jo, J., Kang, S., Shin, Y., & Park, J.-W. (2021). Deep learning for early dental caries detection in bitewing radiographs. *Scientific Reports*, 11(1), Article 16807. <https://doi.org/10.1038/s41598-021-96368-7>
2. Panyarak, W., Suttapak, W., Wantanajittikul, K., Charuakkra, A., & Prapayasatok, S. (2023). Assessment of YOLOv3 for caries detection in bitewing radiographs based on the ICCMS radiographic scoring system. *Clinical Oral Investigations*, 27(4), 1731–1742. <https://doi.org/10.1007/s00784-022-04801-6>
3. anyarak, W., Wantanajittikul, K., Charuakkra, A., Prapayasatok, S., & Suttapak, W. (2023). Enhancing caries detection in bitewing radiographs using YOLOv7. *Journal of Digital Imaging*, 36(6), 2635–2647. <https://doi.org/10.1007/s10278-023-00871-4>
4. Karakuş, R., Öziç, M. Ü., & Tassoker, M. (2024). AI-assisted detection of interproximal, occlusal, and secondary caries on bite-wing radiographs: A single-shot deep learning approach. *Journal of Imaging Informatics in Medicine*, 37(6), 3146–3159. <https://doi.org/10.1007/s10278-024-01113-x>
5. Asci, E., Kilic, M., Celik, O., Cantekin, K., Bircan, H. B., Bayrakdar, İ. S., & Orhan, K. (2024). A deep learning approach to automatic tooth caries segmentation in panoramic radiographs of children in primary dentition, mixed dentition, and permanent dentition. *Children*, 11(6), Article 690. <https://www.mdpi.com/2227-9067/11/6/690>